

ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

DISTRIBUCIONES DE PROBABILIDAD

Unidad 3 · Asignatura E8102 — Exploración de datos

Docentes: Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

Asignatura: E8102 — Exploración de datos

Cohorte o comisión: Cohorte 2026




Figura 1. Enumerar los casos deja de ser posible enseguida. Una distribución con nombre es esa enumeración, ya resuelta.

1. INTRODUCCIÓN

1.1 De contar los casos a usar una fórmula que ya los contó

La unidad 2 terminó con un problema abierto. El bolillero con dos extracciones se resolvió contando: tres valores posibles, tres probabilidades, una tabla de dos columnas. Después la sección 3.6 de esa unidad cambió el número de extracciones de dos a veinte, con reposición, y preguntó cuál es la probabilidad de sacar exactamente siete blancas.

Esa pregunta no se contesta contando. El experimento tiene 1.048.576 resultados posibles, y los caminos que dan exactamente siete blancas son 77.520.

Lo que resuelve el problema es notar que ese experimento no tiene nada de particular. Repetir algo muchas veces en las mismas condiciones y contar cuántas salieron bien es una situación que aparece en todos lados: piezas que pasan o no pasan un control, hogares que aceptan o rechazan una encuesta, clientes que renuevan o no renuevan. Si la cuenta se hace una sola vez y en general, sirve para todas.

Eso es una **distribución de probabilidad con nombre**: la cuenta de la unidad 2, ya hecha, para una situación que se repite. Esta unidad presenta nueve.

1.2 Lo que se supone

- Las unidades 1 y 2 completas. Sobre todo la probabilidad compuesta con y sin independencia, la distribución de probabilidad, la esperanza, la varianza y el desvío standard.
- La **estandarización** de la sección 5.7 de la unidad 2, $Z = (X - \mu) / \sigma$. Es la operación más usada de la unidad y vuelve en toda la asignatura.
- El **relevamiento de hogares** del [T8001](#), que ya se usó en las dos unidades anteriores. Acá aparece en las secciones 7.2 y 8.5.
- El **factorial**: $5! = 5 \times 4 \times 3 \times 2 \times 1 = 120$, y por convención $0! = 1$. Aparece en la sección 3.3 y no se usa para nada más.
- Potencias con exponente natural, y raíz cuadrada.

Aparecen dos símbolos nuevos. La e es el número 2,71828..., la base de los logaritmos naturales, y la π es 3,14159.... Las dos son constantes: aparecen dentro de dos fórmulas y no hay que hacer nada con ellas salvo dejar que la calculadora las use.

No hace falta saber integrar. Las áreas bajo las curvas de la sección 6 se obtienen de una tabla o de una función, y el apunte explica cómo se leen las dos.

1.3 El alcance de esta unidad

Tres aclaraciones que ordenan la lectura.

Acá no se estima nada. Todas las distribuciones de esta unidad llegan con sus parámetros dados: el bolillero tiene cinco blancas de ocho, y eso se sabe. En un problema real los parámetros no se conocen y hay que estimarlos a partir de una muestra, que es el trabajo de las unidades 5 y 6. Esta unidad arma la herramienta; las siguientes la usan sobre datos.

Las tres últimas distribuciones se presentan y no se usan. La chi cuadrado, la t de Student y la F de Fisher-Snedecor no describen fenómenos: describen cuentas hechas sobre muestras. Acá se presentan para que las unidades 6, 7, 8 y 9 puedan usarlas sin detenerse a explicarlas. Si al leer la sección 9 te parece que falta el motivo, es porque el motivo llega después.

La notación es la de la cátedra. Los éxitos se cuentan con s , el fracaso se anota $q = 1 - p$, la población de la hipergeométrica se parte en Np y Nq , y los grados de libertad son $g.l.$ La sección 2.4 tiene la tabla de equivalencias con la notación de las unidades 1 y 2 y con la de la bibliografía en inglés.

Las tablas impresas se explican y no se usan. Hasta hace treinta años, calcular el área bajo una curva normal exigía una tabla en el apéndice de un libro. Hoy se obtiene con una línea de código. La sección 6.6 muestra las dos vías, porque la tabla sigue apareciendo en la bibliografía y en los exámenes de otras materias, pero los ejercicios de esta asignatura se resuelven con `scipy.stats`.

1.4 Los cinco ejemplos que recorren la unidad

El bolillero. El mismo de las unidades 1 y 2: ocho bolillas, cinco blancas y tres negras. Con reposición produce una binomial, y sin reposición una hipergeométrica. Es el ejemplo que permite comparar las dos fórmulas nuevas contra una tabla que ya está calculada a mano.

Los rechazos del relevamiento. Un encuestador hace una jornada de visitas y algunos hogares se niegan a contestar. La cantidad de rechazos por jornada es un conteo de eventos poco frecuentes en un intervalo, y esa es la situación de la Poisson. En promedio hay 2 rechazos por jornada.

La duración de la entrevista. Cuánto tarda una visita del relevamiento, en minutos. Es una variable continua, con una media de 35 minutos y un desvío de 8, y sirve para la normal.

Las facturas del auditor. Un lote de facturas donde cada una puede estar bien registrada, tener un error formal o tener un error material. Son tres grupos y no dos, y esa es la situación de la multinomial de la sección 3.8 y de la polinomial de la sección 4.5.

El ingreso de los hogares. Los 35 ingresos declarados del relevamiento, muy estirados hacia la derecha. Sirven para el teorema central del límite de la sección 8: el promedio de una muestra se vuelve simétrico aunque la variable de origen no lo sea.

2. QUÉ ES UN MODELO DE DISTRIBUCIÓN

2.1 Una familia de distribuciones, y sus parámetros

Hasta acá, "distribución" era una tabla concreta: estos valores, estas probabilidades. Lo que aparece en esta unidad es otra cosa, y conviene nombrarla bien.

Una **distribución con nombre** no es una distribución: es una **familia** de distribuciones que comparten la misma fórmula. Cuál de todas es depende de unos pocos números que se llaman **parámetros**.

La binomial tiene dos parámetros, n y p . Con $n = 20$ y $p = 0,625$ es una distribución; con $n = 20$ y $p = 0,5$ es otra distinta, y las dos son binomiales. Elegir el modelo y elegir los parámetros son dos decisiones separadas: la primera dice qué fórmula se aplica, y la segunda cuál de todas las de esa fórmula.

Por eso el nombre completo de una distribución siempre incluye sus parámetros. "Una binomial" no identifica nada; "una binomial con $n = 20$ y $p = 0,625$ " sí.




Figura 2. La fórmula es una sola. El parámetro elige cuál de todas las distribuciones de esa familia es.

2.2 El modelo se elige por el mecanismo, no por la forma de los datos

Acá está la decisión que más se equivoca, y conviene decirla antes de ver ninguna fórmula.

Un modelo de distribución se elige preguntando **cómo se genera el dato**, no mirando si el histograma se parece a una campana. Las preguntas son cinco:

1. **¿Se cuenta o se mide?** Contar da una variable discreta, medir da una continua.
2. **¿Hay una cantidad fija de repeticiones?** Veinte extracciones, cien piezas, treinta visitas.
3. **¿Las repeticiones cambian las condiciones de las que siguen?** Es la pregunta de la reposición, y es la que separa la binomial de la hipergeométrica.
4. **¿Cada repetición tiene dos resultados posibles, o más de dos?** Es la que separa la binomial de la multinomial, y la hipergeométrica de la polinomial.
5. **Si no hay repeticiones fijas, ¿lo que se cuenta son eventos en un intervalo?** Llamadas por hora, fallas por mes, rechazos por jornada.

Un histograma con forma de campana no prueba que la variable sea normal, y una variable normal puede dar un histograma feo con veinte datos.

Elegir el modelo es parte del análisis, y hay que justificarlo. Es la misma exigencia que la unidad 1 puso sobre el enfoque de probabilidad y que el T8001 ponía sobre el tratamiento de un faltante. Un modelo mal elegido da números correctos que contestan otra pregunta.

2.3 Lo que no cambia

Las dos condiciones de la sección 3.2 de la unidad 2 siguen valiendo para todas las distribuciones de esta unidad, y son el control que conviene hacer siempre.

Cada probabilidad está entre 0 y 1. Y la suma de todas vale exactamente 1, que en las distribuciones continuas de la sección 6 se lee como un área total igual a 1.

Las seis medidas de la unidad 2 también siguen valiendo. Lo único que cambia es cómo se calculan: donde antes había que sumar valor por valor, ahora hay una expresión cerrada. La esperanza de una binomial es $n \times p$, y eso ahorra la suma de veintiún términos.

2.4 Los símbolos de esta unidad

Las unidades 1 y 2 anotaron la variable con mayúscula y sus valores con minúscula: $P(X = x)$. Esta unidad mantiene eso y agrega los símbolos propios de cada modelo, que son los de la cátedra.

Símbolo	Qué es	Dónde aparece
s	la cantidad de éxitos, que es el valor de la variable	binomial, hipergeométrica, Poisson
n	la cantidad de ensayos o de extracciones	binomial, hipergeométrica, multinomial, polinomial
p	la probabilidad de éxito en un ensayo	binomial, multinomial
q	la probabilidad de fracaso, $q = 1 - p$	binomial, multinomial
N	el total de elementos de la población	hipergeométrica, polinomial
Np	cuántos de esos N son éxitos	hipergeométrica
Nq	cuántos de esos N son fracasos	hipergeométrica
λ	la cantidad promedio de eventos por intervalo	Poisson

Símbolo	Qué es	Dónde aparece
μ, σ	la media y el desvío standard, de la unidad 2	normal
gl	los grados de libertad	chi cuadrado, t de Student, F

Dos aclaraciones que evitan confusiones.

N_p y N_q son un símbolo cada uno, no una multiplicación pendiente. Son la cantidad de éxitos y la de fracasos que hay en la población, y se leen de corrido. Que N_p / N dé la probabilidad de éxito en la primera extracción es la razón del nombre.

La s de los éxitos no es la s de la varianza muestral. Esta última aparece recién en la sección 9, y siempre escrita s^2 o $s / \sqrt{n}$, dentro de una fórmula de inferencia. El contexto las separa sin ambigüedad.

Y la equivalencia con la bibliografía en inglés y con `scipy.stats`, que vas a encontrar en cuanto busques fuera del apunte: ahí los éxitos son k , el fracaso es $1 - p$, los éxitos de la población son K y los grados de libertad son df o k .

3. LA DISTRIBUCIÓN BINOMIAL

3.1 El ensayo de Bernoulli

La binomial se construye sobre el experimento más simple que hay: uno con **dos resultados posibles**. Se llama **ensayo de Bernoulli**, por [Jacob Bernoulli](#), el mismo de la sección 3.5 de la unidad 1.

A uno de los dos resultados se lo llama **éxito** y al otro **fracaso**. Los nombres son convencionales y no traen ningún juicio: en un control de calidad, el "éxito" suele ser la pieza defectuosa, porque es lo que se está contando. Lo que define cuál es cuál es la pregunta, no lo deseable.

$$P(\text{éxito}) = p$$

$$P(\text{fracaso}) = q = 1 - p$$

Sacar una bolilla del bolillero y mirar si es blanca es un ensayo de Bernoulli con $p = 5/8 = 0,625$ y $q = 3/8 = 0,375$. Visitar un hogar y registrar si acepta la encuesta, también.

3.2 Las cinco condiciones de la binomial

La **distribución binomial** cuenta cuántos éxitos hay en una cantidad fija de ensayos de Bernoulli. El valor s es esa cantidad, y puede valer $0, 1, 2, \dots, n$.

Aplica cuando se cumplen las cinco condiciones:

1. **El experimento se repite n veces.** La cantidad está fijada de antemano y no depende de lo que vaya saliendo.
2. **La variable es discreta.** Toma los valores enteros de 0 a n y ninguno intermedio.
3. **La variable es dicotómica.** Cada ensayo termina en éxito o en fracaso, y no hay una tercera posibilidad.
4. **La probabilidad de éxito p y la de fracaso $q = 1 - p$ son constantes** en todos los ensayos.
5. **Los sucesos son independientes.** Lo que sale en uno no modifica la probabilidad de los otros.

Las dos últimas son la misma exigencia vista de dos lados, y las dos se rompen juntas cuando la extracción es sin reposición. Por eso el bolillero da una binomial con reposición y no la da sin reposición.

La condición 1 se olvida seguido. "Extraer bolillas hasta que salga la primera negra" no es binomial, porque la cantidad de ensayos es aleatoria. Esa situación tiene su propia distribución, la geométrica, que no está en el programa.

La condición 3 es la que levanta la sección 3.8, con la multinomial.

Para justificar el modelo hay que recorrer las cinco y verificar que se cumplen, una por una. Con el dado arrojado 5 veces, contando cuántas veces sale un 6:

6. **Se repite n veces:** el dado se arroja 5 veces.
7. **Variable discreta:** los valores posibles son los enteros de 0 a 5.
8. **Variable dicotómica:** en cada tiro sale un 6, o no sale.
9. **p y q constantes:** $p = 1/6$ y $q = 5/6$ en cada tiro.
10. **Sucesos independientes:** lo que salió en un tiro no cambia la probabilidad del siguiente.

3.3 En cuántos órdenes: el número combinatorio

Antes de la fórmula falta una cuenta, y es la que la unidad 1 dejó planteada en la sección 5.2.

Siete blancas en veinte extracciones pueden aparecer en muchos órdenes distintos: las siete primeras, una sí y una no, las siete últimas. Todos esos órdenes son resultados distintos del experimento y todos dan $s = 7$, así que hay que contarlos.

El **número combinatorio** cuenta de cuántas maneras se pueden elegir s posiciones entre n , sin que importe el orden en que se eligen. Se escribe $C(n, s)$, y también nCs :

$$C(n, s) = n! / [s! \times (n - s)!]$$

Para el caso de arriba:

$$C(20, 7) = 20! / (7! \times 13!) = 77.520$$

Hay 77.520 maneras de que las siete blancas caigan en veinte extracciones, y la fórmula las cuenta en un renglón.

Comprabá tres valores que sirven de control: $C(n, 0) = 1$, porque hay una sola forma de no elegir ninguna; $C(n, n) = 1$, por la misma razón; y $C(n, s) = C(n, n - s)$, porque elegir cuáles entran es lo mismo que elegir cuáles quedan afuera.




Figura 3. Cada orden es un resultado distinto del experimento, y ninguno se distingue de los otros una vez contados los éxitos.

3.4 La fórmula

La probabilidad de obtener exactamente s éxitos en n ensayos:

$$P(s) = C(n, s) \times p^s \times q^{(n-s)} \\ = n! / [s! \times (n-s)!] \times p^s \times q^{(n-s)}$$

Las dos expresiones son la misma: la segunda desarrolla el número combinatorio con factoriales.

Los tres factores se leen por separado, y cada uno sale de algo ya visto:

- p^s es la probabilidad de que salgan los s éxitos. Es la compuesta con independencia de la sección 7.5 de la unidad 1, aplicada s veces.
- $q^{(n-s)}$ es la probabilidad de que los demás ensayos sean fracasos.
- $C(n, s)$ es en cuántos órdenes distintos puede pasar eso. Los órdenes son excluyentes entre sí, así que sus probabilidades se suman, y sumar $C(n, s)$ veces lo mismo es multiplicar.

Para identificar con cuál de las infinitas binomiales se está trabajando hay que dar sus dos parámetros, y eso se anota así:

$$X \sim B(n, p)$$

Compró la fórmula con el bolillero de dos extracciones **con reposición**, que la unidad 1 ya resolvió en la sección 7.6. Con $X \sim B(2; 0,625)$:

$$P(2) = C(2, 2) \times (5/8)^2 \times (3/8)^0 = 1 \times 25/64 \times 1 = 0,3906$$

Es el mismo $25/64 = 0,3906$ que salió multiplicando $5/8 \times 5/8$. La distribución completa:

s	$P(s)$
0	0,1406
1	0,4688
2	0,3906
Total	1,0000

El mismo control, sobre el dado. Con $X \sim B(5; 1/6)$, la probabilidad de que salga un 6 exactamente dos veces:

$$P(2) = C(5, 2) \times (1/6)^2 \times (5/6)^3 = 10 \times 0,027778 \times 0,578704 = 0,16075$$

Ese 10 es $C(5, 2)$, y son las diez maneras de que los dos 6 caigan en cinco tiros: 66XXX, 6X6XX, 6XX6X, 6XXX6, X66XX, X6X6X, X6XX6, XX66X, XX6X6 y XXX66, donde X es cualquier cara que no sea 6. Cada una de las diez tiene la misma probabilidad $(1/6)^2 \times (5/6)^3$, por probabilidad compuesta, porque en todas hay dos tiros con 6 y tres sin 6. Y las diez son excluyentes entre sí, así que la probabilidad total es la suma de las diez, que es multiplicar por 10.

Ese es el trabajo que ahorra la fórmula: la cuenta larga y la corta dan el mismo 0,16075.

3.5 Las siete blancas de veinte extracciones

Ahora la pregunta que la unidad 2 dejó abierta. Veinte extracciones con reposición, $X \sim B(20; 0,625)$, y se busca $P(7)$:

$$\begin{aligned} P(7) &= C(20, 7) \times 0,625^7 \times 0,375^{13} \\ &= 77.520 \times 0,0373 \times 0,0000029 \\ &= 0,0084 = 0,84\% \end{aligned}$$

Menos de una vez cada cien. Y el resultado tiene sentido apenas se mira la esperanza de la sección siguiente: en veinte extracciones se esperan 12,5 blancas, así que siete es un resultado bajo.

Fíjate en lo que se ahorró. Sin la fórmula había que enumerar los 1.048.576 resultados del experimento, quedarse con los 77.520 que tienen siete blancas y sumar sus probabilidades. Con la fórmula son tres multiplicaciones.

3.6 Esperanza y varianza

Las dos salen en una línea, sin hacer la suma valor por valor de la unidad 2:

$$\begin{aligned} E(s) &= n \times p \\ \sigma(s)^2 &= n \times p \times q \\ \sigma(s) &= \sqrt{n \times p \times q} \end{aligned}$$

Para las veinte extracciones del bolillero:

$$\begin{aligned} E(s) &= 20 \times 0,625 = 12,5 \text{ blancas} \\ \sigma(s)^2 &= 20 \times 0,625 \times 0,375 = 4,6875 \\ \sigma(s) &= \sqrt{4,6875} = 2,1651 \text{ blancas} \end{aligned}$$

Y para el dado de cinco tiros, donde la cuenta es corta y se puede contrastar contra la de la unidad 2:

$$\begin{aligned} E(s) &= 5 \times 1/6 = 0,8333 \text{ seises} \\ \sigma(s)^2 &= 5 \times 1/6 \times 5/6 = 0,6944 \end{aligned}$$

Armá la tabla de s y $P(s)$ de ese dado, aplicá $\sum s \times P(s)$ y $\sum (s - E(s))^2 \times P(s)$ como en la unidad 2, y vas a llegar a los mismos 0,8333 y 0,6944. Las fórmulas del modelo no dan otra cosa: dan lo mismo, más rápido.

La esperanza es la que se adivina sin fórmula: si el 62,5% de las bolillas son blancas y se sacan veinte, se esperan doce y media. La varianza no se adivina, y tiene una propiedad que conviene mirar: el producto $p \times q$ es máximo cuando $p = 0,5$, donde vale 0,25, y se achica hacia los dos extremos. Con $p = 0,99$ vale 0,0099, y casi siempre salen casi todos éxitos.

3.7 Cómo cambia la forma

Dos parámetros, dos efectos, y conviene tenerlos separados.

p decide la asimetría. Con $p = 0,5$ la distribución es simétrica. Con p chico se estira hacia la derecha, porque los valores bajos son los probables y del lado alto queda una cola larga. Con p grande se estira hacia la izquierda. Es la asimetría de la sección 7 de la unidad 2, ahora producida por un parámetro.

n decide la simetría de a poco. Con p fijo y n creciendo, la binomial se vuelve cada vez más simétrica y más parecida a una campana, sea cual sea el p . Ese hecho es el que la sección 7.4 convierte en una aproximación, y es una consecuencia del teorema de la sección 8.2.




Figura 4. Una binomial está acotada entre 0 y n . La probabilidad de éxito decide contra cuál de las dos paredes se amontona.

3.8 La multinomial: cuando la variable no es dicotómica

La condición 3 de la sección 3.2 exige dos resultados por ensayo. La **distribución multinomial** es la binomial con esa condición levantada: la variable es **policotómica**, es decir que puede tomar más de dos valores. Todo lo demás se mantiene igual.

El camino a la fórmula es corto si se reescribe la binomial. Llamemos p_1 a p y p_2 a q , de modo que $p_1 + p_2 = 1$; y s_1 a s y s_2 a $n - s$, de modo que $s_1 + s_2 = n$:

$$P(s_1; s_2) = n! / (s_1! \times s_2!) \times p_1^{s_1} \times p_2^{s_2}$$

Con más de dos grupos la expresión se generaliza sola:

$$P(s_1; s_2; \dots; s_r) = n! / (s_1! \times s_2! \times \dots \times s_r!) \times p_1^{s_1} \times p_2^{s_2} \times \dots \times p_r^{s_r}$$

$$\text{con } \sum p_i = 1 \quad \text{y} \quad \sum s_i = n$$

El ejemplo. Una empresa sabe que el 10% de sus facturas tiene algún error formal de registración —falta el DNI del cliente, por ejemplo—, que el 1% tiene un error material —están contabilizadas por un importe distinto del real— y que el 89% no tiene ningún error. Un auditor elige 10 facturas al azar. ¿Cuál es la probabilidad de que haya 2 del primer grupo, 1 del segundo y 7 del tercero?

$$P(2; 1; 7) = 10! / (2! \times 1! \times 7!) \times 0,10^2 \times 0,01^1 \times 0,89^7 = 0,0159$$

Hay un 1,59% de probabilidad.

Todo problema multinomial se puede resolver con binomiales sucesivas, y hacerlo sirve de control. Primero hay que **dicotomizar**: facturas con error contra facturas sin error, con $p = 0,11$, y se pide $s = 3$:

$$P(3) = C(10, 3) \times 0,11^3 \times 0,89^7 = 0,070646$$

Después, dentro de esas 3 con error, la probabilidad de que 2 sean del tipo formal. La probabilidad condicional de que un error sea formal es $0,10 / 0,11 = 0,9091$, así que con $n = 3$ y $s = 2$:

$$P(2) = C(3, 2) \times 0,9091^2 \times 0,0909^1 = 0,2254$$

Las dos cosas tienen que pasar a la vez, así que se aplica probabilidad compuesta:

$$0,070646 \times 0,2254 = 0,0159$$

El mismo 1,59% de la fórmula multinomial. El camino largo confirma el corto, igual que en la sección 3.4.




Figura 5. Lo único que cambia respecto de la binomial es en cuántos grupos puede caer cada caso.

4. LA DISTRIBUCIÓN HIPERGEOMÉTRICA

4.1 La misma pregunta, sin reposición

La hipergeométrica comparte todos los supuestos de la binomial, con una diferencia: **los elementos no se devuelven**. Los sucesos son dependientes, así que la probabilidad de éxito no es constante y las condiciones 4 y 5 de la sección 3.2 no se cumplen.

Los parámetros son tres, y describen la población en lugar de la probabilidad. Hay N elementos, de los cuales N_p son éxitos y los N_q restantes son fracasos, y se hacen n extracciones. Para el bolillero sin reposición con dos extracciones, $N = 8$, $N_p = 5$, $N_q = 3$ y $n = 2$.

Los nombres N_p y N_q no son casuales: $p = N_p/N$ es la probabilidad de éxito en la **primera** extracción, la única que todavía no cambió nada.

4.2 La fórmula

$$P(s) = [C(N_p, s) \times C(N_q, n - s)] / C(N, n)$$

Es el enfoque clásico de la unidad 1, sin nada nuevo: casos favorables sobre casos posibles, contados con el número combinatorio.

El denominador $C(N, n)$ son todos los grupos de n elementos que se pueden formar con N . El numerador son los favorables, y se arma con el principio de multiplicación de la sección 5.1 de la unidad 1: elegir s éxitos entre los N_p disponibles, y a la vez elegir los $n - s$ restantes entre los N_q que no son éxitos.

4.3 La tabla de la unidad 2, ahora con fórmula

La sección 3.1 de la unidad 2 armó a mano la distribución del bolillero sin reposición. Hizo falta la probabilidad compuesta con dependencia para los extremos y la probabilidad total entre excluyentes para el caso del medio. Ahora sale de una fórmula:

$$P(0) = [C(5,0) \times C(3,2)] / C(8,2) = (1 \times 3) / 28 = 3/28 = 0,1071$$

$$P(1) = [C(5,1) \times C(3,1)] / C(8,2) = (5 \times 3) / 28 = 15/28 = 0,5357$$

$$P(2) = [C(5,2) \times C(3,0)] / C(8,2) = (10 \times 1) / 28 = 10/28 = 0,3571$$

Los tres números son exactamente los de la unidad 2: 0,1071, 0,5357 y 0,3571. Las fracciones se ven distintas porque allá el denominador era 56, que cuenta pares ordenados, y acá es 28, que cuenta pares sin orden. Es la distinción de la sección 5.2 de la unidad 1, y el cociente no cambia porque el numerador y el denominador cuentan lo mismo de los dos lados.

Compará las dos versiones del mismo bolillero:

s	Con reposición (binomial)	Sin reposición (hipergeométrica)
0	0,1406	0,1071
1	0,4688	0,5357
2	0,3906	0,3571

Sin reposición hay menos probabilidad en los extremos y más en el medio. Tiene una explicación directa: sacar una blanca deja menos blancas para la segunda extracción, así que los resultados repetidos se vuelven menos probables y los mixtos más.

4.4 Esperanza y varianza, y el factor de corrección

$$E(s) = n \times Np/N$$

$$\sigma(s)^2 = n \times (Np/N) \times (Nq/N) \times (N - n)/(N - 1)$$

La esperanza es igual a la de la binomial, con Np/N en el lugar de p : en el bolillero da $2 \times 5/8 = 1,25$, el mismo valor que la unidad 2 calculó sumando. **La reposición no cambia la esperanza.**

La varianza sí cambia, y el único término nuevo es el último. Se lo llama **factor de corrección por población finita**, y siempre vale entre 0 y 1, así que **la varianza sin reposición es menor**. Para el bolillero:

$$\sigma(s)^2 = 2 \times 0,625 \times 0,375 \times (8 - 2)/(8 - 1) = 0,46875 \times 6/7 = 0,4018$$

Ese 0,4018 es el mismo de la sección 5.2 de la unidad 2. Y la lectura del factor es la de la tabla de arriba: sacar sin reposición produce resultados más parecidos entre sí.

Mirá los dos casos extremos, porque aclaran el factor. Si $n = N$ se extrae toda la población, el factor vale 0 y la varianza también: no queda nada por azar. Y si N es enorme frente a n , el factor se acerca a 1 y la fórmula se vuelve la de la binomial, que es de lo que se ocupa la sección 7.2.




Figura 6. Lo que cambia sin reposición no es solamente cuánto queda: es en qué proporción queda.

4.5 La polinomial: la hipergeométrica con más de dos grupos

La relación entre la hipergeométrica y la **distribución polinomial** es la misma que hay entre la binomial y la multinomial de la sección 3.8: la variable pasa de dicotómica a policotómica, y todo lo demás queda igual.

La población de N elementos ya no se parte en éxitos y fracasos, sino en r grupos de tamaños $N_1, N_2, \dots, N_r$. Se extraen n elementos sin reposición y se pregunta por s_1 del primer grupo, s_2 del segundo, y así:

$$P(s_1; s_2; \dots; s_r) = [C(N_1, s_1) \times C(N_2, s_2) \times \dots \times C(N_r, s_r)] / C(N, n)$$

con $\sum N_i = N$ y $\sum s_i = n$

Con dos grupos, $N_1 = N_p$ y $N_2 = N_q$, y la fórmula vuelve a ser la de la sección 4.2.

5. LA DISTRIBUCIÓN DE POISSON

5.1 Contar eventos en un intervalo

Las dos distribuciones anteriores necesitan una cantidad fija de ensayos. Hay una situación muy común donde eso no existe.

Un encuestador sale una jornada y algunos hogares le rechazan la entrevista. ¿Cuántos ensayos hubo? No hay respuesta: el encuestador no hizo un número fijo de intentos, y tampoco se puede contar cuántos rechazos "no ocurrieron". Lo único que se observa es el conteo dentro de un intervalo.

Esa es la situación de la **distribución de Poisson**, por [Siméon Denis Poisson](#), que la publicó en 1837. Cuenta cuántas veces ocurre un evento en un intervalo de tiempo, de espacio o de material: llamadas por hora, fallas por mes, defectos por metro de tela, rechazos por jornada.

El parámetro es uno solo, la letra griega λ (lambda), y es la **cantidad promedio de eventos por intervalo**. Se anota $X \sim P(\lambda)$.

Retené un detalle que importa: λ está atado al tamaño del intervalo. Si son 2 rechazos por jornada, son 10 por semana de cinco jornadas, y usar el λ de un intervalo para preguntar por otro es un error de escala. La sección 5.4 lo trabaja con un caso.

5.2 La otra lectura: el límite de la binomial

Hay un segundo camino hacia la misma distribución, y la bibliografía lo usa tanto como el primero.

La Poisson aparece cuando se cumplen **todos los supuestos de la binomial**, pero la cantidad de experimentos es muy grande y la probabilidad de éxito en cada uno es muy baja. Por eso se la llama también **ley de los sucesos raros**, y por eso es una distribución límite de la binomial:

$$\lim B(n, p) = P(\lambda) \quad \text{cuando } n \rightarrow \infty, \quad p \rightarrow 0 \quad \text{y} \quad n \times p \rightarrow \lambda$$

Si n fuera estrictamente infinito y p exactamente 0, el producto $n \times p$ sería una indeterminación. Pero n no es infinito —ya se va a ver que una cantidad bastante chica alcanza— ni p es exactamente 0, sino cercana a 0, así que $n \times p$ tiende a un valor λ , que es la esperanza del modelo de Poisson. La sección 7.3 convierte esto en una aproximación con condiciones.

5.3 Las condiciones del proceso

1. **Los eventos ocurren de a uno.** Dos rechazos exactamente simultáneos no cuentan como un evento doble.
2. **La tasa es constante a lo largo del intervalo.** El promedio de rechazos por hora es el mismo a las 9 que a las 18.
3. **Los eventos son independientes.** Que un hogar rechace no cambia la probabilidad de que el siguiente rechace.

La segunda y la tercera se rompen seguido en datos reales. Si los rechazos se concentran al mediodía porque no hay nadie en casa, la tasa no es constante. Si un vecino le avisa a otro, los eventos no son independientes. Poisson sigue siendo un punto de partida razonable, y el apartamento hay que declararlo.

5.4 La fórmula, la media y la varianza

$$P(s) = (e^{(-\lambda)} \times \lambda^s) / s!$$

La variable puede valer 0, 1, 2, ... sin tope: no hay un máximo, aunque las probabilidades se vuelven despreciables enseguida. Es la primera distribución de la asignatura con infinitos valores posibles, y las probabilidades igual suman 1.

Las dos medidas coinciden, y eso es una particularidad de esta distribución:

$$\begin{aligned} E(s) &= \lambda \\ \sigma(s)^2 &= \lambda \\ \sigma(s) &= \sqrt{\lambda} \end{aligned}$$

La esperanza es λ por definición. Que la varianza también valga λ sirve de control rápido sobre datos reales: **si un conteo tiene una varianza muy distinta de su media, la Poisson no lo describe bien.**

Cuando la varianza observada es bastante mayor que la media, se habla de **sobredispersión**, y suele indicar que la tasa no es constante o que los eventos no son independientes: las dos condiciones de la sección 5.3 que más se rompen.

El cambio de escala, con un caso. Las estadísticas de los últimos cinco años de una empresa metalúrgica indican que hay en promedio un accidentado por cuatrimestre. ¿Cuál es la probabilidad de que no haya ningún accidentado el año próximo?

El λ que se tiene está expresado en cuatrimestres y la pregunta está en años, así que antes de aplicar la fórmula hay que homogeneizar las dos unidades. Un año son tres cuatrimestres, y entonces $\lambda = 3$ por año:

$$P(0) = (e^{(-3)} \times 3^0) / 0! = 0,0498$$

Hay un 4,98% de probabilidad de que no haya accidentados. Si se hubiera usado $\lambda = 1$ sin convertir, la respuesta habría sido 36,79%, siete veces más grande, y estaría contestando por un cuatrimestre y no por un año.

5.5 Los rechazos por jornada

Con $X \sim P(2)$, dos rechazos por jornada:

s	P(s)	F(s)
0	0,1353	0,1353
1	0,2707	0,4060
2	0,2707	0,6767
3	0,1804	0,8571
4	0,0902	0,9473
5	0,0361	0,9834
6 o más	0,0166	1,0000

La cuenta de la primera fila, para ver la fórmula funcionando:

$$P(0) = (e^{-2} \times 2^0) / 0! = 0,1353 / 1 = 0,1353$$

Una jornada sin ningún rechazo ocurre el 13,53% de las veces. Y la probabilidad de tener **tres o más** rechazos se calcula por el complemento de la unidad 1, usando la acumulada de la unidad 2:

$$P(s \geq 3) = 1 - F(2) = 1 - 0,6767 = 0,3233$$

Casi un tercio de las jornadas. Fijate que $P(1)$ y $P(2)$ son idénticas, y no es una casualidad ni un error de redondeo: cuando λ es un número entero, los valores $\lambda - 1$ y λ siempre tienen la misma probabilidad.




Figura 7. No hay una cantidad fija de intentos que se pueda contar. Hay un intervalo, y adentro unos pocos eventos.

6. LA DISTRIBUCIÓN NORMAL

6.1 Por qué hace falta una distribución continua

Las tres distribuciones anteriores son discretas: cuentan. La duración de una entrevista no se cuenta, se mide, y puede valer 34,7 minutos o 34,71.

La sección 3.4 de la unidad 2 explicó lo que pasa con una variable así. La probabilidad de un valor exacto es cero, y lo que tiene sentido es la probabilidad de un intervalo, que se lee como el **área** bajo una curva de densidad.

La **distribución normal** es la curva de densidad que más aparece en esta asignatura, y en la bibliografía. La descubrió [Abraham de Moivre](#) en 1733 y la desarrolló después [Laplace](#) en 1786. Muchos autores la llaman **campana de Gauss** o distribución gaussiana, aunque [Gauss](#) tuvo que ver con su uso y no con su definición.

6.2 La curva y sus dos parámetros

La normal tiene dos parámetros, y son las dos medidas de la unidad 2: $\mu = E(X)$, la media, dice dónde está el centro, y σ , el desvío standard, dice cuán ancha es. Se escribe $X \sim N(E(X); \sigma(X))$, que este apunte abrevia $X \sim N(\mu, \sigma)$, y para la duración de la entrevista es $N(35, 8)$.

Hay infinitas normales, una por cada combinación de μ y σ , igual que hay infinitas binomiales, una por cada combinación de n y p , e infinitas Poisson, una por cada λ . La media corre la curva sobre la recta numérica, a la izquierda o a la derecha. El desvío la hace más concentrada o más dispersa alrededor de esa media. Dos normales con el mismo σ y distinto μ tienen forma idéntica y posición distinta.

La fórmula de la densidad se incluye para que no resulte nueva si aparece en la bibliografía. No hay que usarla: en esta asignatura las áreas salen de una función o de una tabla.

$$f(x) = (1 / (\sigma \times \sqrt{2\pi})) \times e^{-(x - \mu)^2 / (2\sigma^2)}$$

6.3 Las propiedades de la campana

Tres propiedades se usan en todo lo que sigue. La curva es **simétrica respecto de μ** , así que su asimetría vale 0 y la media, la mediana y el modo coinciden en el mismo punto. Tiene **un solo pico**, ubicado en μ . Y su **kurtosis vale exactamente 3**: es el 3 de la sección 8.2 de la unidad 2, y ahora se ve de dónde sale, porque es el valor que da la cuenta aplicada a esta curva.

Otras dos importan menos para calcular y más para no equivocarse. El **área total bajo la curva vale 1**, como en cualquier densidad. Y la curva **se extiende sin fin hacia los dos lados**, sin tocar nunca el eje: una normal admite valores negativos por más que la variable real no los admita, y de eso se ocupa la sección 6.8.

6.4 La regla del 68, el 95 y el 99,7

Tres áreas que conviene saber de memoria, porque permiten leer cualquier normal sin calcular nada:

Intervalo	Área
$\mu \pm 1\sigma$	68,27%
$\mu \pm 2\sigma$	95,45%
$\mu \pm 3\sigma$	99,73%

Para las entrevistas de $N(35, 8)$: el 68,27% dura entre 27 y 43 minutos, el 95,45% entre 19 y 51, y el 99,73% entre 11 y 59.

La tercera fila explica de dónde sale el umbral habitual del z-score, que es 3. **Si la variable es normal**, fuera de $\mu \pm 3\sigma$ queda el 0,27% de los casos, unos 3 de cada 1.000. La sección 5.4 de la clase 3 del T8001 lo dice y usa 2 a propósito, para que los dos criterios de valor extremo tengan con qué discrepar. En una variable que no es normal ese porcentaje puede ser muy distinto, y la sección 6.8 vuelve sobre eso.




Figura 8. Dos desvíos alrededor del centro cubren el 95% de los casos. Es la regla que hace legible cualquier normal.

6.5 La normal standard, y la vuelta de Z

Hay infinitas normales, una por cada par (μ, σ) . Tabularlas todas es imposible, y no hace falta, porque todas se reducen a una sola con la estandarización de la sección 5.7 de la unidad 2:

$$Z = (X - \mu) / \sigma$$

Si X es normal con media μ y desvío σ , entonces Z es normal con media 0 y desvío 1. Esa es la **normal standard**, $N(0, 1)$, y es la única que hace falta conocer.

La cuenta traduce un valor de la variable a una distancia medida en desvíos. Una entrevista de 51 minutos tiene $Z = (51 - 35) / 8 = 2$: está dos desvíos por encima del promedio. Y la lectura no depende de la variable ni de la unidad, así que permite comparar un valor de duración contra un valor de ingreso.




Figura 9. Restar el centro y dividir por el ancho lleva cualquier campana a la misma. Por eso alcanza con conocer una.

6.6 Cómo se obtiene el área

Una vez estandarizado el valor, falta el área. Hay dos vías, y conviene conocer las dos.

La tabla impresa. Está en el apéndice de casi todos los manuales, y da $P(Z \leq z)$, el área acumulada a la izquierda de z . Se entra por la fila con el entero y el primer decimal, y por la columna con el segundo decimal. Muchas tablas solo traen los z positivos, porque la simetría permite deducir los negativos con $P(Z \leq -z) = 1 - P(Z \leq z)$.

La función. Es lo que se usa en esta asignatura. `scipy.stats.norm.cdf(51, 35, 8)` da el área a la izquierda de 51 en una $N(35, 8)$, y `scipy.stats.norm.cdf(2)` da la misma área ya estandarizada, sobre la $N(0, 1)$. Las dos devuelven 0,9772.

La función no necesita estandarizar, porque acepta μ y σ directamente. La estandarización sigue haciendo falta para **interpretar**, y ahí no la reemplaza ninguna herramienta.

Antes de usar cualquiera de las dos, tres traducciones que resuelven casi todos los casos:

$$\begin{aligned} P(X \leq a) &= F(a) \\ P(X > a) &= 1 - F(a) \\ P(a < X \leq b) &= F(b) - F(a) \end{aligned}$$

Son las mismas tres de la acumulada de la sección 3.3 de la unidad 2. Y acá vale lo que esa unidad señaló para las variables continuas: $P(X \leq a)$ y $P(X < a)$ dan el mismo número, porque el valor exacto aporta cero.

6.7 La duración de la entrevista

Con $X \sim N(35, 8)$, tres preguntas.

¿Qué porcentaje de entrevistas dura más de 45 minutos?

$$Z = (45 - 35) / 8 = 1,25$$

$$P(X > 45) = 1 - P(Z \leq 1,25) = 1 - 0,8944 = 0,1056 = 10,56\%$$

¿Qué porcentaje dura entre 30 y 40 minutos?

$$Z_1 = (30 - 35) / 8 = -0,625$$

$$Z_2 = (40 - 35) / 8 = 0,625$$

$$P(30 < X \leq 40) = 0,7340 - 0,2660 = 0,4680 = 46,80\%$$

¿Cuánto dura el 5% de entrevistas más largas? Esta va al revés: se conoce el área y se busca el valor. La operación se llama **cuantil**, y en la normal standard el valor que deja el 5% a la derecha es $z = 1,645$. Deshaciendo la estandarización:

$$x = \mu + z \times \sigma = 35 + 1,645 \times 8 = 48,16 \text{ minutos}$$

El 5% de las entrevistas dura más de 48 minutos. Reconocé este cálculo inverso cuando vuelva, porque es el que arma los intervalos de confianza de la unidad 6 y el que define los cuantiles de la unidad 4.




Figura 10. La misma curva se lee en las dos direcciones. Del valor al área, o del área al valor.

6.8 Cuando una variable no es normal

La normal es un modelo, y muchas variables no lo cumplen. Conviene saber qué señales lo delatan.

La variable tiene un tope de un lado. Un ingreso no baja de cero, una duración tampoco. Si la media está cerca de ese tope en relación con el desvío, la normal asigna probabilidad a valores imposibles. Con las entrevistas de $N(35, 8)$ el problema es despreciable, porque cero está a más de cuatro desvíos. Con una media de 10 y un desvío de 8, no lo sería.

La distribución es claramente asimétrica. Los 35 ingresos del relevamiento tienen una asimetría de 2,87 y una kurtosis de 16,66. No hay lectura razonable que los haga normales, y la sección 7.4 de la unidad 4 lo describe sobre el histograma.

Los datos son un conteo. Las personas por hogar valen 3 o 4, no 3,7. Una normal puede aproximar bien un conteo cuando los números son grandes, y la sección 7.4 dice bajo qué condiciones.

Que una variable no sea normal no invalida el análisis. Casi nada en esta asignatura exige normalidad de la variable original. Lo que la sección 8 va a mostrar es que el promedio de una muestra tiende a ser normal aunque la variable no lo sea, y eso es lo que la inferencia necesita.

7. LA APROXIMACIÓN DE DISTRIBUCIONES

7.1 Para qué sirve hoy

Las distribuciones de esta unidad se aproximan unas a otras cuando se cumplen ciertas condiciones. Eso quiere decir que, cumplidas esas condiciones, la probabilidad que se obtiene con una es muy parecida a la que se obtiene con la otra, y se puede usar la que resulte más sencilla de aplicar.

Antes de que existieran las computadoras, calcular $C(500, 180)$ era imposible a mano, y las aproximaciones eran la única salida. Hoy `scipy.stats` devuelve el valor exacto, así que la aproximación dejó de ser una necesidad de cálculo.

Sigue importando por dos razones. La primera es que las condiciones de cada aproximación dicen **cuándo dos modelos describen casi lo mismo**, y eso permite elegir el más simple sin perder nada. La segunda es que la bibliografía y los informes están llenos de aproximaciones, y hay que poder leerlos.

7.2 La hipergeométrica por la binomial

Cuándo: la muestra es chica frente a la población, $n / N \leq 0,05$.

Las dos distribuciones tienen la **misma esperanza**. En la binomial es $n \times p$ y en la hipergeométrica $n \times Np/N$, y ese cociente Np/N es justamente la probabilidad de éxito en la primera extracción, que es p si hay reposición.

Lo que las separa es la dispersión. El desvío de la binomial es $\sqrt{n p q}$ y el de la hipergeométrica es el mismo, multiplicado por la raíz del factor de corrección $(N - n) / (N - 1)$ de la sección 4.4. Ese factor es menor que 1, así que **la hipergeométrica siempre dispersa menos**. Y cuanto más chico es n frente a N , más cerca de 1 queda el factor y menos se distinguen las dos. El límite práctico habitual es el 5%.

Las tres localidades del relevamiento tienen 4.000 hogares. Supongamos, para el ejemplo, que la proporción sin gas de esos 4.000 es la que se observó en los 37 relevados, el 54%, lo que da $Np = 2.160$. Si se eligen 10 hogares al azar sin reposición, la probabilidad de que exactamente 5 no tengan gas:

Hipergeométrica, $N=4.000$, $Np=2.160$, $n=10$:	0,238602
Binomial, $n=10$, $p=0,54$:	0,238319

La diferencia aparece en el cuarto decimal, y $n/N = 0,0025$, muy por debajo del 5%.

Un segundo caso, esta vez justo en el límite. Un auditor elige 20 de las 500 facturas emitidas el último mes. De esas 500, 160 son facturas A y 340 son facturas B. ¿Cuál es la probabilidad de que la mitad de las elegidas sea de cada tipo?

Hipergeométrica, $N=500$, $Np=160$, $n=20$, $s=10$:	0,0424
Binomial, $n=20$, $p=0,32$, $s=10$:	0,0440

Acá $n/N = 20/500 = 0,04$, todavía por debajo del 5%, y la diferencia ya se ve en el segundo decimal. Cuanto más cerca del límite, más se separan las dos.

Es la regla que justifica algo que se hace todo el tiempo sin nombrarlo: **una encuesta se analiza como si el muestreo fuera con reposición**, aunque nadie encueste dos veces al mismo hogar. Vuelve en la unidad 5.

7.3 La binomial por la Poisson

Cuándo: muchos ensayos y probabilidad de éxito baja. La regla de la cátedra es $n \geq 30$ y $p \leq 0,1$, con $\lambda = n \times p$. Por simetría también vale con $p \geq 0,9$ y $n \geq 30$, tomando $\lambda = n \times q$.

Es la sección 5.2 convertida en una regla práctica: la Poisson es lo que queda de una binomial cuando los ensayos se hacen numerosos y cada uno muy improbable. Con p lejos de 0,1 —y de 0,9— la diferencia entre las dos se mantiene por más que crezca n , así que la aproximación nunca es buena. Con $p = 0,25$ mejora pero todavía discrepa. Con $p = 0,1$ los valores ya son muy parecidos, y la similitud crece con n .

Las dos distribuciones son discretas, así que acá no se aplica la corrección por continuidad.

El ejemplo. Se sabe que 1 de cada 100 facturas del último ejercicio tiene algún defecto formal de registración. ¿Cuál es la probabilidad de que en un lote de 50 facturas elegidas al azar con reposición haya menos de 3 con errores? Con $n = 50$ y $p = 0,01$, que da $\lambda = 0,5$:

s	Binomial	Poisson
0	0,6050	0,6065
1	0,3056	0,3033
2	0,0756	0,0758
Total	0,9862	0,9856

La binomial dice 98,62% y la Poisson 98,56%. La aproximación es muy buena, y $n = 50$ está lejos de cualquier infinito.

Y da la otra lectura del ejemplo de la sección 5.5: si una jornada tuviera 200 hogares con 1% de probabilidad de rechazo cada uno, los rechazos seguirían promediando 2. Por eso la Poisson describe bien los eventos raros sobre muchas oportunidades.

7.4 La binomial por la normal, y la corrección por continuidad

Cuándo: $n \geq 30$ y $0,1 \leq p \leq 0,9$. Se usa una normal con $\mu = n \times p$ y $\sigma = \sqrt{n \times p \times q}$.

$$\lim B(n, p) = N(n \times p, \sqrt{n \times p \times q}) \quad \text{cuando } n \rightarrow \infty \text{ y } 0,1 \leq p \leq 0,9$$

Las dos condiciones importan, y la segunda tanto como la primera. Con $p = 0,5$ la binomial se parece a la normal desde $n = 10$, y con $n = 40$ ya es prácticamente igual. Con $p = 0,2$ hace falta llegar a $n = 40$ para que se asemejen. Con $p = 0,1$, que es el límite, $n = 10$ no se parece

en nada y $n = 40$ recién empieza a aproximar. Y con $p = 0,05$, por debajo del límite, ni siquiera $n \geq 30$ alcanza: **la aproximación no depende solo de n , también depende de p .**

Esta aproximación tiene además una dificultad que las otras dos no tienen: **cambia una distribución discreta por una continua**. La binomial pone probabilidad en los enteros, y la normal reparte área de manera continua, así que hay que decidir dónde cortar.

La solución es la **corrección por continuidad**: cada entero se trata como el intervalo de media unidad a cada lado. Se resta 0,5 al límite inferior del intervalo buscado y se suma 0,5 al superior, para que los dos extremos queden incluidos.

El ejemplo. Se arroja un dado 100 veces. ¿Cuál es la probabilidad de obtener un 6 entre 10 y 22 veces? Acá $n = 100 \geq 30$ y $p = 0,1667$ está entre 0,1 y 0,9, así que las dos condiciones se cumplen:

$$\begin{aligned}\mu &= n \times p = 100 \times 1/6 = 16,6667 \\ \sigma &= \sqrt{(n \times p \times q)} = \sqrt{(100 \times 1/6 \times 5/6)} = 3,7268 \\ z_1 &= (9,5 - 16,6667) / 3,7268 = -1,92 \\ z_2 &= (22,5 - 16,6667) / 3,7268 = 1,57 \\ P(10 \leq s \leq 22) &\approx 0,9418 - 0,0274 = 0,9144\end{aligned}$$

Mirá cuánto importa la corrección:

Cálculo	Resultado
Binomial exacta, $P(10 \leq s \leq 22)$	0,9157
Normal sin corrección, área entre 10 y 22	0,8870
Normal con corrección, área entre 9,5 y 22,5	0,9140

Sin la corrección el error es de 2,9 puntos porcentuales. Con la corrección, el error aparece en el tercer decimal. **La corrección por continuidad no es un refinamiento opcional.**

Los 0,9144 de la cuenta de arriba y los 0,9140 de la tabla son el mismo número: la diferencia es que la cuenta redondeó z a dos decimales para entrar en la tabla impresa, y la tabla usó los z sin redondear.

La regla general, cuando el intervalo no viene dado por sus dos extremos: si el extremo entra, se corre medio hacia afuera; si no entra, medio hacia adentro.

$$\begin{aligned}P(s \leq k) &\rightarrow \text{área hasta } k + 0,5 \\ P(s < k) &\rightarrow \text{área hasta } k - 0,5 \\ P(s \geq k) &\rightarrow \text{área desde } k - 0,5 \\ P(s > k) &\rightarrow \text{área desde } k + 0,5 \\ P(s = k) &\rightarrow \text{área entre } k - 0,5 \text{ y } k + 0,5\end{aligned}$$




Figura 11. Cada columna ocupa media unidad a cada lado de su valor, y el corte va en el borde. Ahí se origina el medio que se suma o se resta.

7.5 La Poisson por la normal

Cuándo: $\lambda \geq 10$. Se usa una normal con $\mu = \lambda$ y $\sigma = \sqrt{\lambda}$, que son la esperanza y el desvío de la propia Poisson.

Con $\lambda = 1$ o $\lambda = 3$ la Poisson está muy estirada hacia la derecha. Con $\lambda = 10$ la forma ya se parece bastante a una campana, y con $\lambda = 15$ más todavía.

La Poisson es discreta y la normal es continua, así que acá sí corresponde la corrección por continuidad. Es la misma de la sección 7.4, por el mismo motivo.

El ejemplo. Una empresa industrial registra en promedio un accidente por mes entre sus operarios. ¿Cuál es la probabilidad de que haya más de 15 accidentes el próximo año?

Primero el cambio de escala de la sección 5.4: λ tiene que estar en la misma unidad que la pregunta. Un accidente por mes son 12 por año, así que $\lambda = 12$. Calculando término por término y sumando:

$$F(15) = 0,8444$$

$$P(s > 15) = 1 - 0,8444 = 0,1556$$

Y ahora por la normal, que aplica porque $\lambda = 12 \geq 10$. Se busca más de 15, así que el 15 no entra y el 16 sí: el corte va en 15,5.

$$\mu = \lambda = 12 \quad \sigma = \sqrt{12} = 3,4641$$

$$z = (15,5 - 12) / 3,4641 = 1,01$$

$$P(s > 15) \approx 1 - 0,8438 = 0,1562$$

Contra el 0,1556 exacto de la Poisson. Y la cuenta por la normal es una línea, mientras que la exacta pidió sumar dieciséis términos.

7.6 Las cuatro aproximaciones, juntas

De	A	Condición	Parámetros	¿Corrección por continuidad?
Hipergeométrica	Binomial	$n / N \leq 0,05$	$p = Np/N$	no, las dos son discretas
Binomial	Poisson	$n \geq 30$ y $p \leq 0,1$	$\lambda = n p$	no, las dos son discretas
Binomial	Poisson	$n \geq 30$ y $p \geq 0,9$	$\lambda = n q$	no, las dos son discretas
Binomial	Normal	$n \geq 30$ y $0,1 \leq p \leq 0,9$	$\mu = n p, \sigma = \sqrt{n p q}$	sí
Poisson	Normal	$\lambda \geq 10$	$\mu = \lambda, \sigma = \sqrt{\lambda}$	sí

Las condiciones de la binomial no se pisan: se reparten el rango de p . Por debajo de 0,1 y por encima de 0,9 sirve la Poisson; entre 0,1 y 0,9, la normal. Con $n = 200$ y $p = 0,5$ va la normal; con $n = 200$ y $p = 0,01$, la Poisson.

La regla es simple: **la corrección por continuidad hace falta cuando se pasa de una distribución discreta a una continua, y solo entonces**. Las dos últimas filas son los dos casos que terminan en la normal.

Los umbrales son convenciones prácticas, no teoremas, y salen de comparar las formas de las curvas. Otros manuales usan $n \times p \geq 5$ y $n \times q \geq 5$ para la normal, o $n \geq 20$ y $p \leq 0,05$ para la Poisson. Este apunte usa los de la cátedra. Cerca del límite, calculá las dos y compará.

8. LOS DOS TEOREMAS

8.1 El teorema de Bernoulli

La sección 3.5 de la unidad 1 presentó el principio de estabilidad de las frecuencias relativas sin fórmula. Ahora se puede enunciar, porque hace falta la binomial para hacerlo.

Si se repite n veces un ensayo con probabilidad de éxito p , la cantidad de éxitos X es binomial, y la **proporción de éxitos** es X/n . Aplicando las propiedades de las secciones 4.4 y 5.5 de la unidad 2 a la esperanza y la varianza de la sección 3.6 de esta unidad:

$$E(X/n) = p$$

$$V(X/n) = p \times (1 - p) / n$$

$$\sigma(X/n) = \sqrt{p \times (1 - p) / n}$$

La proporción muestral tiene como esperanza la probabilidad verdadera, y su desvío **se achica cuando n crece**. Eso es el teorema de Bernoulli: al aumentar las repeticiones, la probabilidad de que la frecuencia relativa se aparte de p más de una cantidad fija tiende a cero. El paso de la fórmula del desvío a esa afirmación sobre una probabilidad necesita una desigualdad que no se ve en esta asignatura.

Compró los números con una moneda, $p = 0,5$:

Tiros	Desvío de la proporción
10	0,1581
100	0,0500
10.000	0,0050

Y mirá que la primera de las dos advertencias de la unidad 1 queda ahora respaldada por un número. La **proporción** se estabiliza porque su desvío se divide por $\sqrt{n}$. La **cantidad** de éxitos, en cambio, tiene desvío $\sqrt{[n \times p \times (1-p)]}$, que crece con n : en 10.000 tiros el desvío de la cantidad de caras es 50 caras. El desbalance absoluto puede crecer mientras el proporcional se achica.

La segunda advertencia, la falacia del jugador, sale de la condición 5 de la sección 3.2: los ensayos son independientes, así que ningún resultado anterior cambia la probabilidad del próximo.

8.2 El teorema central del límite

El teorema de Bernoulli habla de proporciones. El **teorema central del límite** dice algo más general, y no le pide a la población ninguna forma en particular.

Si se toman muestras aleatorias de n observaciones independientes de una población con media μ y desvío σ finito, la distribución de la media muestral se aproxima a una normal a medida que n crece, cualquiera sea la forma de la población.

Las tres palabras que importan son **cualquiera sea la forma**. La población puede ser asimétrica, discreta, con dos picos o con una cola larguísima: el promedio de una muestra tiende a distribuirse normalmente igual.

No es un teorema sino una familia de teoremas. El primero es el de de Moivre, que demostró que en el límite la binomial se convierte en normal, y es el que está detrás de la sección 7.4. Después llegaron generalizaciones y demostraciones en el mismo sentido, y Polya las agrupó bajo este nombre en 1920. La palabra "central" señala eso: es el resultado central, el que no depende de la distribución que tenga cada variable que se suma.

El teorema vale para la suma tanto como para la media. El enunciado más general dice que **la suma de muchas variables aleatorias independientes e idénticamente distribuidas tiene aproximadamente una distribución normal**. Cuántas hacen falta depende de la precisión que se busque, y se suele aceptar que a partir de 30 la aproximación ya es suficientemente buena. La media es esa suma dividida por n , así que las dos lecturas son la misma.

Para la suma de n variables, la esperanza y el desvío salen de las propiedades de la unidad 2:

$$\begin{aligned}E(s) &= n \times E(X) \\ \sigma(s) &= \sqrt{n} \times \sigma(X)\end{aligned}$$

El ejemplo. En una caja se ponen 64 botellas de gaseosa de medio litro, y la máquina que las llena tiene una varianza de 0,0025 litros². ¿Cuál es la probabilidad de que en una caja haya entre 31,5 y 32,8 litros en total?

Se suman 64 botellas, muy por encima de las 30 que pide la regla práctica, así que el teorema aplica:

$$\begin{aligned}E(s) &= 64 \times 0,5 = 32 \text{ litros} \\ \sigma(s) &= \sqrt{64} \times \sqrt{0,0025} = 8 \times 0,05 = 0,4 \text{ litros} \\ z_1 &= (31,5 - 32) / 0,4 = -1,25 & z_2 &= (32,8 - 32) / 0,4 = 2 \\ P(31,5 < s < 32,8) &= 0,9772 - 0,1056 = 0,8716\end{aligned}$$

Un 87,16%. Y fijate qué se hizo acá: **no se sabe cómo se distribuye el contenido de una botella**. Puede ser uniforme, asimétrico o cualquier otra cosa. Alcanza con conocer su media y su varianza, porque lo que se pregunta es por la suma de 64 de ellas.

Cuidado con el desvío de la suma, que es la parte que más se equivoca. Es $\sqrt{n} \times \sigma(X)$, y **crece** con n . El que se achica con n es el de la media, $\sigma(X) / \sqrt{n}$, que es de lo que se ocupa la sección siguiente. Son las dos caras del mismo $\sqrt{n}$, y ya aparecieron enfrentadas en la sección 8.1.

8.3 La distribución de la media muestral

El teorema no solo dice la forma. Dice también el centro y el ancho:

$$\begin{aligned}E(\bar{X}) &= \mu \\ V(\bar{X}) &= \sigma^2 / n \\ \sigma(\bar{X}) &= \sigma / \sqrt{n}\end{aligned}$$

Las dos primeras salen de las propiedades de la unidad 2: la esperanza de una suma es la suma de las esperanzas, y la varianza de una suma de variables independientes es la suma de las varianzas, que es la sección 5.6. Lo que agrega el teorema es la **forma normal**, y eso no sale de ninguna propiedad anterior.

El $\sigma / \sqrt{n}$ tiene nombre propio: se llama **error standard de la media**. No es el desvío de la variable, es el desvío del promedio, y confundirlos es el error más frecuente de la unidad.

8.4 El error standard, y la raíz de n

El $\sqrt{n}$ del denominador tiene una consecuencia práctica que conviene entender antes de la unidad 6.

Como la reducción va con la raíz y no con n , **para partir el error standard al medio hay que cuadruplicar la muestra**. Pasar de 100 a 400 casos lo divide por 2. Pasar de 400 a 1.600 lo divide por 2 otra vez.

Esa es la razón de que las encuestas nacionales usen 1.000 o 1.500 casos y no 10.000. Multiplicar la muestra por diez cuesta diez veces más y mejora la precisión por un factor de $\sqrt{10} = 3,16$.

Y hay algo que el $\sqrt{n}$ **no** arregla, que la unidad 5 desarrolla: si la muestra está mal seleccionada, agrandarla no corrige el sesgo. Reduce la parte aleatoria del error y deja intacta la sistemática.



Figura 12. El último perfil es apenas más angosto que el anterior, y su barra es varias veces más larga.

8.5 El ingreso del relevamiento, con cuatro tamaños de muestra

El teorema se ve mejor con una población que no se parezca en nada a una campana, y los ingresos del relevamiento sirven: 35 valores con asimetría 2,87 y kurtosis 16,66, por el hogar de 620.000.

Tratando esos 35 valores como la población completa, $\mu = 203.471$ y $\sigma = 86.103$. El cuadro de abajo toma 200.000 muestras de cada tamaño, con reposición, y describe la distribución de sus medias:

Tamaño de muestra	Media de las medias	Desvío observado	$\sigma / \sqrt{n}$	Asimetría
2	203.515	60.937	60.884	2,03
5	203.482	38.583	38.506	1,28
30	203.521	15.729	15.720	0,52
100	203.456	8.608	8.610	0,29

Tres lecturas.

El centro no se mueve. Las cuatro medias de medias quedan a menos de 60 pesos de 203.471, que es la media de la población. El promedio de una muestra no tiende a ser más alto ni más bajo que el valor que estima.

El ancho se achica como dice la fórmula. La columna del desvío observado y la de $\sigma / \sqrt{n}$ coinciden en las cuatro filas. La segunda no se midió: se calculó con el teorema.

La asimetría se va. La población tiene 2,87 y las medias de a 100 tienen 0,29. La forma se vuelve simétrica aunque el ingreso siga estando tan estirado como siempre.




Figura 13. Arriba, la población estirada. Abajo, las medias de muestras cada vez más grandes. La cola se acorta fila por fila.

8.6 Qué no dice el teorema central del límite

Cuatro malentendidos, y los cuatro se corrigen con la tabla de arriba.

No dice que los datos se vuelvan normales. Los ingresos siguen teniendo asimetría 2,87 después de tomar todas las muestras. Lo que tiende a la normal es la distribución de la **media muestral**, que es otra variable.

No dice que $n \geq 30$ alcance siempre. Ese umbral es una regla práctica que sirve para poblaciones moderadamente asimétricas. Con los ingresos, $n = 30$ todavía deja una asimetría de 0,52, y hace falta $n = 100$ para bajarla a 0,29. **Cuanto más asimétrica es la población, más grande tiene que ser la muestra.**

No dice que una muestra grande arregle una muestra mala. El teorema supone observaciones independientes de la misma población. Si el encuestador visita solo los hogares que abren la puerta, ninguna cantidad de casos corrige eso.

No se aplica a cualquier población. Hace falta que la varianza sea finita. Hay distribuciones donde no lo es, y ahí el teorema no vale. No aparecen en esta asignatura, y el requisito se nombra porque forma parte del enunciado.

9. LAS TRES DISTRIBUCIONES DE LA INFERENCIA

9.1 Por qué hacen falta tres más

Las cuatro distribuciones anteriores describen fenómenos: bolillas, rechazos, duraciones. Las tres que siguen no describen ningún fenómeno. Describen **cuentas hechas sobre una muestra**.

El problema que resuelven es concreto. La sección 8.3 dice que la media muestral se distribuye alrededor de μ con desvío $\sigma / \sqrt{n}$. Para usar eso hay que conocer σ , el desvío de la población, y en un problema real no se conoce: se estima con la muestra. Y estimarlo agrega incertidumbre, que la normal no contempla.

Las tres distribuciones de esta sección son las que aparecen cuando esa incertidumbre se tiene en cuenta. Las tres suponen, además, que la población de la que sale la muestra es normal, y cada sección lo dice en su lugar.

9.2 Los grados de libertad

Las tres tienen un parámetro con este nombre, que se abrevia gl , y conviene entenderlo una vez.

Los **grados de libertad** son la cantidad de valores que pueden variar libremente después de imponer las restricciones del cálculo.

El ejemplo que lo aclara: cinco números cuya media es 20. Los primeros cuatro pueden valer cualquier cosa, pero una vez elegidos, el quinto queda determinado, porque la suma tiene que dar 100. Hay cuatro grados de libertad, no cinco.

Eso explica el $n - 1$ que va a aparecer en la varianza muestral de la unidad 4: calcular la varianza exige antes calcular la media, y esa media consume un grado de libertad. No es una corrección arbitraria.




Figura 14. Fijar la media clava el apoyo. Cuatro alturas quedan libres y la quinta se deduce de las otras.

9.3 La chi cuadrado

La **distribución chi cuadrado**, χ^2 , es la que sigue una suma de cuadrados de variables normales standard independientes:

$$\chi^2_{gl} = X_1^2 + X_2^2 + X_3^2 + \dots + X_{gl}^2$$

donde cada X_i es una normal standard, y gl son los grados de libertad, es decir cuántas se suman.

Nunca es negativa, porque es una suma de cuadrados, así que va de 0 a infinito. Es asimétrica a la derecha, y la asimetría se atenúa a medida que los grados de libertad crecen: con 1 o 2 grados de libertad está muy estirada, y con 20 ya se acerca a una campana. Su esperanza es gl y su varianza $2gl$.

El caso que importa para la unidad 6 es este: **si la población es normal**, la varianza muestral cumple

$$(n - 1) \times s^2 / \sigma^2 \quad \text{sigue una chi cuadrado con } n - 1 \text{ grados de libertad}$$

y de ahí salen los intervalos de confianza para la varianza. Ese $n - 1$ es el grado de libertad que consumió la media, y el supuesto de normalidad **no se relaja con n grande**: a diferencia de lo que pasa con la media, acá una muestra más grande no rescata a una población que no es normal.

Se usa también en el test chi cuadrado de la unidad 9, que compara frecuencias observadas contra frecuencias esperadas. La suma de cuadrados aparece ahí porque los apartamientos se

elevan al cuadrado para que no se cancelen, por la misma razón que en la varianza de la unidad 2.

9.4 La t de Student

La **distribución t de Student** se forma dividiendo una normal standard por la raíz cuadrada de una chi cuadrado promedio, es decir dividida por sus grados de libertad:

$$t_{gl} = X_0 / \sqrt{[(X_1^2 + X_2^2 + \dots + X_{gl}^2) / gl]}$$

Un ejemplo de la construcción, para ver que no hay nada escondido. Sean cuatro variables:

$$X_1 \sim N(0; 1) \quad X_2 \sim N(10; 3) \quad X_3 \sim N(50; 8) \quad X_4 \sim N(0; 1)$$

Estandarizando las tres primeras y sumando sus cuadrados se obtiene una chi cuadrado con 3 grados de libertad:

$$Y = X_1^2 + [(X_2 - 10)/3]^2 + [(X_3 - 50)/8]^2 \rightarrow Y \sim \chi^2_3$$

Y dividiendo la cuarta, que ya es normal standard, por la raíz de esa chi cuadrado promedio:

$$W = X_4 / \sqrt{(Y / 3)} \rightarrow W \sim t_3$$

Para qué sirve. Es la respuesta al problema de la sección 9.1: es la que sigue la media muestral estandarizada cuando σ se estima con la muestra. Si la población es normal,

$$t = (\bar{x} - \mu) / (s / \sqrt{n})$$

sigue una t con $n - 1$ grados de libertad. Compará esa expresión con la estandarización de la unidad 2: es la misma cuenta, con s en el lugar de σ y $\sqrt{n}$ dividiendo.

El nombre tiene una historia corta que ayuda a recordarlo: la publicó [William Gosset](#) en 1908, bajo el seudónimo *Student*, porque trabajaba en la cervecería Guinness y la empresa no permitía a sus empleados publicar con su nombre.

Se parece mucho a la normal standard: es simétrica respecto de su esperanza, tiene forma de campana, y cuando los grados de libertad crecen se vuelve indistinguible de ella. Con 30 grados de libertad ya es prácticamente igual. Lo que la separa son el **pico central más bajo** y las **colas más pesadas**, y esa es la razón de que exista: estimar σ agrega incertidumbre, y las colas más gruesas la reflejan.

Los grados de libertad valen $n - 1$ en el caso de una sola muestra. En otros usos cambian — dos muestras y regresión, entre ellos— y cada unidad va a decir cuáles son.

El valor que deja el 2,5% en la cola derecha, que es el que arma un intervalo del 95%:

Grados de libertad	Valor de t
5	2,5706
10	2,2281
30	2,0423
100	1,9840
Normal standard	1,9600

Leelo de arriba hacia abajo: con 5 grados de libertad hay que ir bastante más lejos que con la normal para dejar el mismo 2,5%, y con 100 la diferencia ya casi no existe. **Con muestras chicas, usar la normal en lugar de la t produce intervalos más angostos de lo que corresponde.**




Figura 15. La curva que mide su ancho con una regla incierta es la que levanta los extremos.

9.5 La F de Fisher-Snedecor

La **distribución F** es la que sigue el cociente de dos chi cuadrado independientes, cada una dividida por sus grados de libertad, es decir el cociente de dos chi cuadrado promedio. Si U sigue una χ^2 con d_1 grados de libertad y V sigue una χ^2 con d_2 , entonces

$$F = (U / d_1) / (V / d_2)$$

sigue una F con d_1 grados de libertad en el numerador y d_2 en el denominador.

En la práctica aparece al comparar dos varianzas muestrales: si las dos poblaciones son normales **y tienen la misma varianza**, el cociente s_1^2 / s_2^2 sigue una F. Sin ese supuesto de igualdad, lo que sigue una F es $(s_1^2 / \sigma_1^2) / (s_2^2 / \sigma_2^2)$.

La derivó [Ronald Fisher](#), y [George Snedecor](#) la tabuló en la forma del cociente de varianzas y le puso la letra F en honor al primero.

Nunca es negativa, porque el numerador y el denominador son chi cuadrado promedio, que siempre son positivas. Es asimétrica a la derecha, y **se vuelve cada vez más simétrica a medida que crecen los dos grados de libertad**. Tiene **dos parámetros de grados de libertad**, uno por cada varianza, y el orden importa: la F con 5 y 10 grados de libertad no es la misma que la F con 10 y 5.

Se usa para comparar la variabilidad de dos grupos, y en la prueba global de una regresión múltiple, que es la unidad 8. Aparece también en el análisis de varianza, que no está en el programa de la asignatura y se nombra acá para que el término no resulte nuevo.

9.6 Cómo se relacionan las cuatro

Las tres distribuciones de esta sección salen de la normal, y verlo junto ahorra memorizar:

Distribución	Qué es	Forma
Normal standard	el punto de partida	simétrica, centrada en 0
Chi cuadrado	suma de cuadrados de normales standard	positiva, asimétrica a la derecha
t de Student	una normal standard dividida por la raíz de una chi cuadrado sobre sus grados de libertad	simétrica, colas más pesadas
F	cociente de dos chi cuadrado, cada una sobre sus grados de libertad	positiva, asimétrica a la derecha

Dos relaciones que salen de esa construcción y sirven de control. Una **t elevada al cuadrado es una F** con 1 grado de libertad en el numerador, y una chi cuadrado con 1 grado de libertad es el cuadrado de una normal standard. La primera vuelve en la sección 7.4 de la unidad 8, donde los dos caminos de una regresión simple dan el mismo valor p.




Figura 16. Ninguna de las tres describe un fenómeno. Las tres se construyen a partir de la normal standard.

10. LAS NUEVE DISTRIBUCIONES, JUNTAS

Distribución	Tipo	Parámetros	Qué cuenta o mide	$E(s)$	$\sigma(s)^2$
Binomial	discreta	n, p	éxitos en n ensayos independientes	$n p$	$n p q$
Multinomial	discreta	$n, p_1 \dots p_r$	casos de cada grupo en n ensayos independientes	$n p_i$ en cada grupo	$n p_i (1 - p_i)$ en cada grupo
Hipergeométrica	discreta	N, Np, n	éxitos en n extracciones sin reposición	$n Np/N$	$n (Np/N) (Nq/N) (N-n)/(N-1)$
Polinomial	discreta	$N, N_1 \dots N_r, n$	casos de cada grupo en n extracciones sin reposición	$n N_i/N$ en cada grupo	como la hipergeométrica, grupo por grupo
Poisson	discreta	λ	eventos en un intervalo	λ	λ
Normal	continua	μ, σ	una medición alrededor de un centro	μ	σ^2
Chi cuadrado	continua	gl	suma de cuadrados de normales standard	gl	$2gl$
t de Student	continua	gl	media estandarizada con σ estimado	0 si $gl > 1$	$gl/(gl-2)$ si $gl > 2$
F	continua	d_1, d_2	cociente de dos chi cuadrado sobre sus grados de libertad	—	—

Y el orden en que conviene decidir, frente a un problema nuevo:

1. **¿Se cuenta o se mide?** Contar lleva a las cinco primeras, medir a la normal.
2. **Si se cuenta: ¿hay una cantidad fija de ensayos?** Si no la hay, y son eventos en un intervalo, es Poisson.
3. **Si la hay: ¿con o sin reposición?** Con reposición, binomial. Sin reposición, hipergeométrica, salvo que $n/N \leq 0,05$ y alcance la binomial.
4. **¿La variable es dicotómica o policotómica?** Con más de dos grupos, la binomial pasa a multinomial y la hipergeométrica a polinomial. La fórmula cambia; el mecanismo no.
5. **Si se mide: ¿la normal es razonable?** Revisá los topes, la asimetría y el mecanismo, no solamente el histograma.
6. **Si lo que se distribuye es un estadístico y no un dato,** mirá la sección 9.

11. OCHO ERRORES FRECUENTES

- 1. Elegir el modelo por la forma del histograma.** Lo que decide es el mecanismo: si se cuenta o se mide, si hay reposición, si los ensayos son fijos.
- 2. Usar la binomial cuando no hay reposición.** En el bolillero, $P(2)$ da 0,3906 con binomial y 0,3571 con hipergeométrica. El error es chico cuando la población es grande, y solo entonces.
- 3. Olvidar la corrección por continuidad.** En el ejemplo de la sección 7.4, 0,8870 en lugar de 0,9157: el error es de 2,9 puntos porcentuales.
- 4. Aplicar la corrección por continuidad donde no va.** Va cuando se pasa de discreta a continua: binomial por normal, y Poisson por normal. No va de binomial a Poisson ni de hipergeométrica a binomial, porque las dos son discretas de los dos lados.
- 5. Confundir el desvío de la variable con el error standard.** σ describe cuánto varía un dato; $\sigma / \sqrt{n}$ describe cuánto varía un promedio. Con $n = 100$ difieren en un factor de 10. Y el desvío de una **suma** es $\sqrt{n} \times \sigma$, que crece en lugar de achicarse.
- 6. Creer que el teorema central del límite normaliza los datos.** Normaliza la distribución de la media muestral. Los datos quedan como estaban.
- 7. Usar la normal en lugar de la t con muestras chicas.** Con 5 grados de libertad, 1,96 en lugar de 2,57 produce un intervalo bastante más angosto que lo que corresponde.
- 8. Cambiar el tamaño del intervalo sin tocar λ .** Si son 2 rechazos por jornada, en una semana de cinco jornadas son 10, no 2. Y un accidente por cuatrimestre son 3 por año, no 1. El parámetro de la Poisson depende del intervalo que se declara.

12. LISTA DE VERIFICACIÓN

Antes de dar por buena una distribución elegida:

1. **¿La variable se cuenta o se mide?** Es la primera bifurcación y descarta la mitad de las opciones.
2. **¿Se cumplen las condiciones del modelo?** Para la binomial son las cinco de la sección 3.2; para la Poisson, las tres de la sección 5.3; para las tres de la sección 9, la normalidad de la población.
3. **¿La variable es dicotómica?** Si tiene más de dos grupos, van la multinomial de la sección 3.8 o la polinomial de la sección 4.5.
4. **¿Los parámetros están en la escala correcta?** Que λ corresponda al intervalo de la pregunta, y que p sea la probabilidad de lo que se está contando como éxito.
5. **¿El resultado es coherente con la esperanza?** Si $E(s) = 12,5$, una probabilidad alta para $p = 7$ sería sospechosa.
6. **¿Las probabilidades suman 1?** Sigue siendo el control de la unidad 2, y sigue detectando errores sin dar ningún aviso.
7. **Si usaste una aproximación, ¿verificaste su condición?** Y si termina en la normal, ¿aplicaste la corrección por continuidad?
8. **Si hablas de una media muestral, ¿usaste $\sigma / \sqrt{n}$ y no σ ?**