

ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

ANÁLISIS DE DATOS

Unidad 4 · Asignatura E8102 — Exploración de datos

Docentes: Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

Asignatura: E8102 — Exploración de datos

Cohorte o comisión: Cohorte 2026




Figura 1. Los mismos datos, dos veces. Suetos no dicen nada; ordenados por cuántas veces se repite cada valor, sí.

1. INTRODUCCIÓN

1.1 Las mismas medidas, del otro lado

Las unidades 2 y 3 hablaron de lo que todavía no se midió. La esperanza del bolillero era el promedio al que tienden muchas repeticiones que nunca se hicieron, y la normal de la unidad 3 describía duraciones de entrevistas que nadie cronometró.

Esta unidad da vuelta la dirección. Los datos **ya están**: 37 hogares visitados, 140 personas contadas, 35 ingresos declarados. La pregunta deja de ser qué se espera y pasa a ser qué dice lo que hay.

Y acá aparece algo que conviene decir de entrada: **las medidas son las mismas**. La media de esta unidad es la esperanza de la unidad 2, calculada con frecuencias observadas en lugar de probabilidades. La varianza, el desvío, el coeficiente de variabilidad, la asimetría y la kurtosis son las seis medidas de esa unidad, aplicadas a una columna de una tabla.

Esta unidad agrega cuatro cosas: cómo se organiza un conjunto de datos antes de medirlo, tres medidas de posición que la unidad 2 usó de prestado y no explicó, la diferencia que aparece cuando los datos son una muestra y no la población entera, y cinco gráficos.

1.2 Lo que se supone

- Las unidades 1, 2 y 3. Sobre todo las seis medidas de la unidad 2, de la sección 4 a la 8.
- La **clasificación de variables** del [T8001](#): cualitativa y cuantitativa, discreta y continua. Es la sección 6.1 de la clase 2 de ese taller.
- Las **escalas de medición**: nominal, ordinal, de intervalo y de razón. Es la sección 6.2 de la misma clase, y decide qué medidas y qué gráficos tienen sentido.
- El tratamiento de los **faltantes** y de los **centinelas** de la sección 4.1 de la clase 3 del T8001. En esta unidad decide el denominador de casi todas las cuentas.
- Los **dos criterios de valor extremo** de la sección 5.4 de esa misma clase, el z-score y el IQR. Aquí se los reencuentra con los cuartiles ya definidos.

No hace falta nada de matemática nueva. La única fórmula que no estaba en la unidad 2 es la de la posición de un cuartil, y son una multiplicación y una división.

1.3 El alcance de esta unidad

Acá se describe, no se infiere. Todo lo de esta unidad habla de los datos que están sobre la mesa. Decir algo sobre los hogares que no se visitaron es inferencia, y empieza en la unidad 5. La distinción parece formal y cambia lo que se puede afirmar: la media de 3,78 personas es un hecho sobre 37 hogares, y no es una afirmación sobre los 4.000 de las tres localidades.

Los gráficos se explican y se hacen en el notebook. La sección 7 dice qué gráfico corresponde a qué variable, cómo se lee y qué errores se cometen al armarlo. El código de matplotlib está en el notebook de ejemplos de la unidad.

No se repiten las fórmulas de la unidad 2. La varianza, la asimetría y la kurtosis se dan por conocidas. Lo que se trata acá es lo que cambia al pasar de una distribución de probabilidad a un conjunto de datos medidos.

1.4 Los datos de esta unidad

El relevamiento del T8001 completo, y esta vez se usan casi todas sus columnas:

Variable	Tipo	Escala	Para qué sirve acá
personas	cuantitativa discreta	razón	serie de frecuencia sin agrupar
ingreso	cuantitativa continua	razón	serie de frecuencia con intervalos, e histograma
localidad	cualitativa	nominal	gráfico de barras y sectorial
satisfaccion	cualitativa	ordinal	gráfico de barras con orden propio
servicios	cualitativa	nominal múltiple	el caso que no entra en una serie común
fecha_visita	fecha	—	gráfico de líneas

Como en las unidades 1 y 2, se trabaja con la **primera visita de cada hogar**: 37 filas de las 45 del archivo.

2. LA SERIE

2.1 La serie simple, y el denominador que hay que declarar

Una **serie simple** es el conjunto de valores observados, tal como salieron, sin agrupar ni contar. Los ingresos del relevamiento, ordenados de menor a mayor, son una serie simple de 35 valores:

0	120.000	148.000	152.000	155.000	163.000	168.000	169.000
172.000							
175.000	176.000	179.000	181.000	185.000	186.000	188.000	190.000
193.000							
195.000	198.000	199.000	201.000	205.000	207.000	210.000	216.000
223.000							
225.000	232.000	236.000	240.500	244.000	260.000	310.000	620.000

Ordenarla no es un trámite: la mediana y los cuartiles de la sección 3 se definen sobre la serie ordenada, y sin ordenar no existen.

Y antes de seguir, el número 35, porque los hogares son 37. Dos no tienen el dato de ingreso, y ese 0 del principio **es un ingreso declarado**, no una ausencia. Es la lección de la sección 4.1 de la clase 3 del T8001, que separaba tres celdas que parecen lo mismo:

Hogar	Celda	Qué es	Qué se hace
3	vacía	una ausencia	se excluye
9	999999	un centinela : una ausencia disfrazada de dato	el T8001 lo convirtió en celda vacía, y se excluye
38	0	un ingreso real, que vale cero	se conserva

El centinela era el 999999, y el archivo de esta asignatura ya lo trae convertido: por eso hay dos celdas vacías y no una. El 0, en cambio, baja el promedio y tiene que bajarlo.

Mirá cuánto cuesta equivocarse en cada dirección. Si el 999999 se hubiera contado como un ingreso, la media de esos 36 valores daría 225.597. Si el 0 se descarta por parecerse a un faltante, la media de los 34 restantes da 209.456. La correcta, con los 35, es **203.471**.

El denominador es una decisión, y hay que declararla. Es la misma regla de la sección 6.5 de la unidad 1. Todas las cuentas de ingreso de esta unidad usan los 35 valores declarados.

2.2 La serie de frecuencia

Cuando los valores se repiten, la serie simple es incómoda: 37 personas por hogar, y muchas dicen lo mismo. La **serie de frecuencia** cuenta cuántas veces aparece cada valor.

Tiene cuatro columnas, y conviene nombrarlas bien porque la bibliografía usa estos símbolos. La **frecuencia absoluta** f_i es cuántas veces aparece el valor, y la **relativa** fr_i es esa cantidad dividida por el total, que es la frecuencia relativa de la sección 3.2 de la unidad 1. Las dos

acumuladas, F_i y Fr_i , dicen cuántos casos hay hasta ese valor, inclusive, en cantidad y en proporción.

Para las personas por hogar:

Personas	f_i	fr_i	F_i	Fr_i
1	2	0,0541	2	0,0541
2	9	0,2432	11	0,2973
3	8	0,2162	19	0,5135
4	8	0,2162	27	0,7297
5	4	0,1081	31	0,8378
6	3	0,0811	34	0,9189
7	2	0,0541	36	0,9730
12	1	0,0270	37	1,0000
Total	37	1,0000		

Es la misma tabla de la sección 3.5 de la unidad 2, con otro nombre. Allá la columna fr_i se llamó $P(X = x)$ y la Fr_i se llamó $F(x)$, porque el hogar se elegía al azar y la frecuencia relativa era la probabilidad. **La tabla es idéntica; lo que cambia es qué pregunta se le hace.**

Los dos controles de siempre: f_i suma el total, y fr_i suma 1.

Fijate en las columnas acumuladas, que contestan preguntas de "cuántos hasta". El $F_i = 19$ de la fila del 3 dice que 19 de los 37 hogares tienen 3 personas o menos, y por eso la mediana de la sección 3.3 va a ser 3.

2.3 La serie de frecuencia con intervalos

La tabla de arriba funciona porque las personas por hogar toman ocho valores distintos. Con el ingreso no funciona: los 35 valores son **todos distintos**, así que la serie de frecuencia tendría 35 filas con un 1 en cada una y no resumiría nada.

La salida es agrupar en **intervalos de clase**, también llamados intervalos o clases. Se parte el recorrido de la variable en tramos y se cuenta cuántos casos caen en cada uno.

Tres decisiones, y ninguna es automática.

Cuántos intervalos. Hay reglas orientativas. La más citada en la bibliografía es la de [Sturges](#), $k = 1 + 3,322 \times \log_{10}(n)$, que para 35 datos da 6,13. Otra es $k = \sqrt{n}$, que da 5,92. Las dos sugieren 6. Son sugerencias: el criterio final es que el resultado se lea.

Qué amplitud. El recorrido es $620.000 - 0 = 620.000$. Dividido en 6 da 103.333, un número incómodo. Conviene redondear a un valor legible, y 100.000 lo es, aunque eso lleve a siete clases en lugar de seis.

Dónde empieza el primero. En 0, que es el mínimo de la serie.

Intervalo	Marca de clase	f_i	fr_i	F_i	Fr_i
0 – 100.000	50.000	1	0,0286	1	0,0286
100.000 – 200.000	150.000	20	0,5714	21	0,6000
200.000 – 300.000	250.000	12	0,3429	33	0,9429
300.000 – 400.000	350.000	1	0,0286	34	0,9714
400.000 – 500.000	450.000	0	0,0000	34	0,9714
500.000 – 600.000	550.000	0	0,0000	34	0,9714
600.000 – 700.000	650.000	1	0,0286	35	1,0000
Total		35	1,0000		

La **marca de clase** es el punto medio del intervalo, y es el valor que representa a todo el tramo cuando hay que calcular algo.

Dos detalles de construcción que evitan errores.

Los límites no se pueden pisar. Un ingreso de 200.000 tiene que caer en un intervalo y en uno solo. La convención de esta asignatura es **cerrado a la izquierda y abierto a la derecha**: el intervalo 200.000 – 300.000 incluye a 200.000 y no incluye a 300.000. Es la que usan `numpy.histogram` y `matplotlib.hist`. Cuidado con `pandas.cut`, que por defecto hace lo contrario, `(a, b]`: para obtener esta tabla hay que pedirle `right=False`.

Las dos clases vacías se dejan. Tienen $f_i = 0$ y no se borran, porque el hueco es información: dice que entre 400.000 y 600.000 no hay ningún hogar. Sacarlas pondría al hogar de 620.000 pegado al de 310.000 y escondería que está lejos.

2.4 Qué se pierde al agrupar

Agrupar no es gratis. Una vez armados los intervalos, los valores individuales desaparecen: el intervalo de 100.000 a 200.000 dice que hay 20 hogares y no dice cuáles.

Si a partir de la tabla agrupada hay que calcular la media, se usan las marcas de clase, tratando a cada caso como si valiera el punto medio de su intervalo:

$$\text{media agrupada} = \sum (\text{marca de clase} \times f_i) / n = 201.429$$

La media real de los 35 datos es **203.471**. Hay 2.043 pesos de diferencia, un 1,0%, y es el precio de haber agrupado.

La regla práctica: **si tenés los datos sin agrupar, calculá sobre ellos**. Los intervalos existen para mirar la forma de la distribución y para presentarla, no para hacer cuentas que se pueden hacer mejor.




Figura 2. La forma se ve mejor, y adentro de cada bloque ya no se sabe dónde estaba cada caso.

3. LAS MEDIDAS DE POSICIÓN

Tres medidas dicen dónde está el centro, y no coinciden. La unidad 2 usó las tres en la sección 7.2 para leer el signo de la asimetría, y avisó que el tema propio venía después. Es acá.

3.1 La media aritmética

La **media aritmética** es la suma de todos los valores dividida por cuántos son:

$$\bar{x} = \sum x_i / n$$

Para las personas por hogar, $140 / 37 = 3,7838$. Para el ingreso, 203.471 .

Es la esperanza de la sección 4.1 de la unidad 2, con las frecuencias relativas observadas en lugar de las probabilidades. Sobre una serie de frecuencia se calcula igual, pesando cada valor por su frecuencia:

$$\bar{x} = \sum (x_i \times f_i) / n$$

Tiene dos propiedades que vienen de la unidad 2 y conviene tener presentes. Es el **punto de equilibrio** de la distribución, así que un valor lejano la corre. Y usa todos los datos, lo cual es una virtud y el origen de su debilidad: **un solo valor extremo la mueve**.

3.2 El modo

El **modo**, o moda, es el valor que más veces se repite.

En las personas por hogar es **2**, con 9 hogares. En el ingreso **no existe**: los 35 valores son distintos, así que ninguno se repite y la serie es **amodal**.

Esa es la limitación principal del modo, y aparece siempre que la variable es continua. Se resuelve agrupando: sobre la tabla de la sección 2.3, la **clase modal** es la de 100.000 a 200.000, que tiene 20 casos. El modo pasa a ser un intervalo y no un valor.

Otras dos cosas que conviene saber. Una serie puede tener **más de un modo**: si dos valores empatan en la frecuencia máxima es bimodal, y eso suele indicar que hay dos grupos mezclados, lo cual es un hallazgo y no un problema de cálculo. Y el modo es **la única medida de posición que sirve para una variable nominal**: la localidad más frecuente es Ramallo, con 15 hogares, y no tiene sentido pedir la media de una localidad.

3.3 La mediana

La **mediana** es el valor que parte la serie ordenada en dos mitades iguales. La mitad de los casos queda por debajo y la mitad por encima.

Se calcula en dos pasos. Primero se ordena. Después, si n es impar, la mediana es el valor de la posición $(n + 1) / 2$; si n es par, es el promedio de los dos valores centrales, en las posiciones $n/2$ y $n/2 + 1$.

Para las personas por hogar, con $n = 37$, la posición es $(37 + 1) / 2 = 19$. El hogar número 19 de la serie ordenada tiene **3 personas**, y la columna F_i de la sección 2.2 lo confirma sin necesidad de ordenar nada: F_i llega a 19 exactamente en la fila del 3.

Para el ingreso, con $n = 35$, la posición es $(35 + 1) / 2 = 18$, y el valor 18 de la serie es **193.000**.

La propiedad que la vuelve indispensable es la **resistencia**: la mediana depende del orden y no de la magnitud. Comprabalo. Si el hogar de 620.000 hubiera declarado 6.200.000, la media pasaría de 203.471 a 362.900 y **la mediana seguiría siendo 193.000**. Lo único que importa es que ese valor siga siendo el más alto, y lo sigue siendo.




Figura 3. Alejar el valor extremo corre el punto de equilibrio y no mueve el punto que parte la serie al medio.

3.4 Cuál informar

Medida	Sirve para	Se mueve con un valor extremo	Usa todos los datos
Media	escalas de intervalo y de razón	sí	sí
Mediana	escalas ordinal, de intervalo y de razón	no	no
Modo	cualquier escala, también la nominal	no	no

La regla corta: **si la distribución es aproximadamente simétrica, informá la media; si está estirada o tiene valores extremos, informá la mediana, y decí las dos.**

Con los ingresos del relevamiento, la media es 203.471 y la mediana 193.000. La diferencia de 10.471 pesos no es un error: la produce el hogar de 620.000. Informar solo la media sugiere que el hogar típico gana más de lo que gana; 22 de los 35 hogares están por debajo de 203.471.

Es la razón por la que los informes de ingresos suelen publicar la mediana además de la media.

3.5 Los cuartiles

La mediana parte la serie en dos. Los **cuartiles** la parten en cuatro, con tres cortes. Q_1 deja el 25% de los casos por debajo, Q_2 deja el 50% y **es la mediana** con otro nombre, y Q_3 deja el 75%.

La fórmula clásica para la posición del cuartil k en una serie ordenada de n datos:

$$\text{posición de } Q_k = k \times (n + 1) / 4$$

Con los 35 ingresos las tres posiciones caen justo en un número entero, así que no hace falta interpolar nada:

$$\begin{aligned} Q_1 &\rightarrow \text{posición } 1 \times 36 / 4 = 9 \rightarrow 172.000 \\ Q_2 &\rightarrow \text{posición } 2 \times 36 / 4 = 18 \rightarrow 193.000 \\ Q_3 &\rightarrow \text{posición } 3 \times 36 / 4 = 27 \rightarrow 223.000 \end{aligned}$$

Y acá hay que detenerse, porque **pandas y numpy devuelven otros números**: 173.500 y 219.500 para Q_1 y Q_3 . No es un error de ninguno de los dos. Hay varios métodos para ubicar un cuartil, y el que usan esas librerías por defecto reparte la posición sobre $n - 1$ en lugar de $n + 1$:

	Fórmula $k(n+1)/4$	pandas y numpy
Q_1	172.000	173.500
Q_2	193.000	193.000
Q_3	223.000	219.500
RIC	51.000	46.000

La mediana coincide siempre; los otros dos no tienen por qué. Las diferencias son chicas y no cambian ninguna conclusión, y lo que no se puede hacer es informar un cuartil sin decir con qué método se calculó.

Este apunte usa los valores de pandas y numpy, que son los que publicó el T8001 en la sección 5.4 de su clase 3, y los que van a salir en el notebook:

Cuartil	Ingreso	Personas por hogar
Q_1	173.500	2
Q_2 (mediana)	193.000	3
Q_3	219.500	5

Se lee: **la cuarta parte de los hogares gana menos de 173.500, y la cuarta parte más de 219.500**. La mitad del medio está entre esos dos valores.

La misma idea se extiende: los **deciles** parten en diez, y los **percentiles** en cien. El percentil 90 del ingreso deja al 90% de los hogares por debajo. Son todos **cuantiles**, la operación inversa que la sección 6.7 de la unidad 3 usó sobre la normal.




Figura 4. Donde los datos se amontonan, el tramo es angosto. Lo que los cuatro tramos igualan es la cantidad de casos, no el ancho.

4. LAS MEDIDAS DE VARIABILIDAD

4.1 El rango

El **rango**, o recorrido, es la diferencia entre el máximo y el mínimo:

$$\text{rango} = 620.000 - 0 = 620.000$$

Es la medida de dispersión más simple de esta unidad, y la que menos sirve, porque **depende de dos datos solos** y justamente de los dos más expuestos a ser extremos. Sin el hogar de 620.000, el rango del ingreso baja a 310.000: se parte exactamente al medio por sacar un caso.

Se informa como referencia rápida del recorrido de la variable, nunca como descripción de la dispersión.

4.2 La varianza y el desvío standard

Son las de la sección 5 de la unidad 2, calculadas sobre los datos:

$$s^2 = \sum (x_i - \bar{x})^2 / n$$
$$s = \sqrt{s^2}$$

Para las personas por hogar, $s^2 = 4,2776$ y $s = 2,0682$ personas. Para el ingreso, $s = 86.103$ pesos.

Vale la misma lectura de la unidad 2: el desvío está en las unidades originales y por eso es el que se informa; la varianza está en unidades al cuadrado y se usa para calcular.

4.3 El divisor n o $n - 1$

Acá está la única diferencia de fondo entre esta unidad y la unidad 2, y hay que entenderla porque las herramientas no hacen lo mismo.

La fórmula de arriba divide por n , y describe la dispersión **de los datos que están**. Es la correcta si esos datos son toda la población que interesa.

Cuando los datos son una **muestra** y lo que se quiere describir es la población de la que salieron, la cuenta cambia: se divide por $n - 1$.

$$s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

La razón es la de la sección 9.2 de la unidad 3. Las distancias se miden contra $\bar{x}$, que se calculó con los mismos datos, y la media muestral es el valor que hace mínima esa suma de cuadrados. Medir contra ella subestima la dispersión respecto de la media verdadera, que no se conoce. Dividir por $n - 1$ en lugar de n corrige esa subestimación. El grado de libertad que se pierde es el que consumió el cálculo de la media.

La diferencia, sobre los datos del relevamiento:

Variable	Divisor n	Divisor n - 1	Diferencia
Personas por hogar	2,0682	2,0968	1,38%
Ingreso	86.103	87.360	1,46%

Con estos tamaños la diferencia es de alrededor del 1,4%, y con 500 casos sería despreciable. Con 5 casos no lo es.

pandas divide por n - 1 y numpy divide por n. `x.std()` de una Series de pandas devuelve 2,0968 y `np.std(x)` devuelve 2,0682, sobre los mismos datos. No es un error de ninguna de las dos: son dos preguntas distintas. En numpy se pide la otra con `np.std(x, ddof=1)`, y en pandas con `x.std(ddof=0)`.

Las unidades 1 a 3 trataron siempre a los 37 hogares como la distribución completa, y por eso usaron n. Esta unidad hace lo mismo, salvo donde se indique. A partir de la unidad 5, cuando los 37 hogares pasen a ser una muestra de los 4.000, el divisor pasa a ser n - 1.

4.4 El recorrido intercuartílico

El **recorrido intercuartílico**, o RIC, es el ancho de la mitad central de los datos:

$$RIC = Q_3 - Q_1$$

Para el ingreso, $219.500 - 173.500 = 46.000$. Para las personas por hogar, $5 - 2 = 3$. Es la misma medida que el T8001 llama IQR, por sus siglas en inglés.

Es a la dispersión lo que la mediana es a la posición: **resistente**. Ignora el 25% más bajo y el 25% más alto, así que un valor extremo no lo mueve. Compará los dos números del ingreso: el desvío standard es 86.103 y el RIC es 46.000. El desvío es más grande porque el hogar de 620.000 lo infla; el RIC no lo usa para nada, porque queda fuera de la caja.

La regla de uso es la misma de la sección 3.4: **si hay valores extremos, la pareja mediana y RIC describe mejor que la pareja media y desvío.**

4.5 El coeficiente de variabilidad

El de la sección 6 de la unidad 2, sin cambios:

$$CV = s / \bar{x}$$

Variable	s	$\bar{x}$	CV
Personas por hogar	2,0682	3,7838	54,66%
Ingreso	86.103	203.471	42,32%

Lo que permite es la comparación que los desvíos no permiten: 2,07 personas y 86.103 pesos son incomparables, y 54,66% contra 42,32% dicen que **las personas por hogar varían relativamente más que el ingreso.**

Siguen valiendo las dos condiciones de la sección 6.2 de la unidad 2: la media tiene que ser positiva y alejada de cero, y la escala tiene que ser de razón. Las dos variables de la tabla cumplen.

5. LA ASIMETRÍA Y LA KURTOSIS

5.1 Las dos medidas, sobre datos

Se calculan como en las secciones 7 y 8 de la unidad 2, con las frecuencias observadas:

$$\alpha_3 = \sum (x_i - \bar{x})^3 / (n \times s^3)$$

$$\alpha_4 = \sum (x_i - \bar{x})^4 / (n \times s^4)$$

La s de estas dos fórmulas es la de divisor n , la misma que divide afuera. Usar la de $n - 1$ mezcla dos convenciones y produce un tercer número, que no es ninguno de los de la sección 5.3.

Variable	α_3	α_4	Lectura
Personas por hogar	1,7200	7,4836	estirada a la derecha, leptocúrtica
Ingreso	2,8714	16,6556	muy estirada a la derecha, muy leptocúrtica

El ingreso es el caso más marcado del relevamiento. Un α_4 de 16,66 contra el 3 de la normal es lo que hace que la unidad 3 lo use como ejemplo de población no normal en la sección 8.5.

5.2 Los coeficientes de asimetría de Pearson

Hay dos medidas alternativas de asimetría, mucho más simples de calcular, que aparecen en la bibliografía y en los exámenes. Son de [Karl Pearson](#), el mismo de la kurtosis de la sección 8.3 de la unidad 2:

$$Ap_1 = (\bar{x} - \text{modo}) / s$$

$$Ap_2 = 3 \times (\bar{x} - \text{mediana}) / s$$

Salen de la observación de la sección 7.2 de la unidad 2: cuando la cola larga va hacia la derecha, la media queda por encima de la mediana y del modo. La distancia entre ellas, medida en desvíos, es una forma directa de cuantificar ese corrimiento.

Variable	α_3	Ap_1	Ap_2
Personas por hogar	1,7200	0,8625	1,1369
Ingreso	2,8714	—	0,3648

Los tres coeficientes coinciden en el **signo** y no en la **magnitud**, así que no son intercambiables: un Ap_2 de 0,36 y un α_3 de 2,87 describen la misma distribución con escalas distintas. El Ap_1 del ingreso no existe, porque la serie es amodal, y esa es la razón para preferir el Ap_2 , que se puede calcular siempre.

La regla: informá cuál usaste, y no compares un coeficiente contra otro.

5.3 Qué convención informa cada herramienta

Es la advertencia de la sección 8.3 de la unidad 2, y ahora se puede explicar del todo, porque la sección 4.3 dio la otra mitad. Hay dos diferencias superpuestas: si se informa la kurtosis o el exceso, y si se aplica o no la corrección muestral.

Sobre las personas por hogar de los 37 hogares:

Cómo se pide	Resultado	Qué devuelve
<code>scipy.stats.skew(x)</code>	1,7200	α_3 , distribución completa
<code>pandas: x.skew()</code>	1,7936	α_3 , corregido
<code>scipy.stats.kurtosis(x, fisher=False)</code>	7,4836	α_4 , distribución completa
<code>scipy.stats.kurtosis(x)</code>	4,4836	exceso, distribución completa
<code>pandas: x.kurt()</code>	5,3357	exceso, corregido

Cinco llamadas, cinco números, los mismos datos. Los de este apunte y los de la unidad 2 son los de la primera y la tercera fila.

6. LOS VALORES EXTREMOS

6.1 Dos criterios que no coinciden

El T8001 ya comparó los dos criterios en la sección 5.4 de su clase 3. Acá se los reencuentra con los cuartiles ya definidos, que es lo que faltaba para entender el segundo.

Los números no van a coincidir exactamente con los de ese taller, y conviene saber por qué antes de compararlos. El T8001 calcula el z-score con el desvío de divisor $n - 1$ y usa umbral 2; esta unidad usa el de divisor n , que es el que corresponde al tratar los datos como la distribución completa, y el umbral habitual de 3. Con umbral 2 el 0 del hogar 38 queda marcado por los dos criterios, y con 3 lo marca solamente el RIC.

El z-score. Cuántos desvíos separan al valor de la media. Es la estandarización de la sección 5.7 de la unidad 2:

$$z = (x - \bar{x}) / s$$

El umbral habitual es $|z| > 3$. Sale de la regla de la sección 6.4 de la unidad 3: en una distribución normal, fuera de tres desvíos queda el 0,27% de los casos.

La regla del $1,5 \times \text{RIC}$, que viene de [*Exploratory Data Analysis* \(Tukey, 1977\)](#). Un valor es atípico si cae fuera del intervalo:

$$[Q_1 - 1,5 \times \text{RIC} , Q_3 + 1,5 \times \text{RIC}]$$

Para el ingreso, con $Q_1 = 173.500$, $Q_3 = 219.500$ y $\text{RIC} = 46.000$, los límites son **104.500 y 288.500**. Quedan afuera tres hogares:

Valor	Hogar	$1,5 \times \text{RIC}$	z-score
0	38	lo marca	no lo marca, $z = -2,36$
310.000	7	lo marca	no lo marca, $z = 1,24$
620.000	39	lo marca	lo marca, $z = 4,84$

Los dos criterios discrepan en dos de los tres. La razón es que el z-score usa la media y el desvío, y **los dos ya están corridos por el propio hogar de 620.000**: ese valor infló el desvío hasta 86.103, y contra un desvío tan grande el 310.000 queda a 1,24. El RIC no lo sufre, porque no usa ni la media ni el desvío.

El z-score tiene además un límite que conviene conocer antes de usarlo con pocos datos: con divisor n , el $|z|$ más grande que puede dar un dato es $\sqrt{(n - 1)}$. Con menos de once casos, **ningún** valor puede superar 3, por extremo que sea. Con los 35 ingresos el techo es 5,83, así que el problema no aparece acá.

Para las personas por hogar los dos criterios coinciden. Los límites son $2 - 4,5 = -2,5$ y $5 + 4,5 = 9,5$, y el único atípico es el hogar de **12**.




Figura 5. Los dos pares de límites se miden desde cosas distintas, y por eso atrapan una cantidad distinta de marcas.

6.2 Qué hacer con uno

Nada automático. Un valor atípico es una señal para mirar, no una instrucción para borrar.

Primero hay que revisar si es un error, y la única forma de saberlo es ir al dato de origen: un ingreso de 620.000 puede ser un error de tipeo por 62.000, o puede ser un hogar de altos ingresos. Si es un error, se corrige o se trata como faltante, que es lo que el T8001 hizo con el 999999 del hogar 9. Y si es un valor real, se conserva y se declara; si el análisis cambia mucho con y sin él, se informan los dos.

El 0 del hogar 38 muestra por qué la lista que devuelven estos criterios es de candidatos y no de errores. El $1,5 \times \text{RIC}$ lo marca, y no es un error: es un ingreso declarado de cero, que el T8001 revisó y conservó.

Descartar un valor porque afea un coeficiente es elegir el resultado. El T8001 revisó el hogar de 12 personas y lo conservó, porque un hogar de 12 personas existe. La sección 8.4 de la unidad 2 mostró que ese solo hogar lleva la kurtosis de 2,48 a 7,48. Las dos lecturas son correctas, y lo que no se puede hacer es informar una sin decir cuál.

7. LOS GRÁFICOS

7.1 Qué gráfico para qué variable

El gráfico se elige por el tipo de variable, igual que el modelo de la unidad 3 se elegía por el mecanismo. Elegirlo por gusto es lo que produce un gráfico que no se puede leer.

Gráfico	Para qué variable	Qué muestra
De barras	cualitativa, o cuantitativa discreta con pocos valores	cuánto vale cada categoría
Sectorial	cualitativa nominal, pocas categorías que suman un total	qué parte del total ocupa cada una
Histograma	cuantitativa continua	la forma de la distribución
De líneas	una variable sobre un eje ordenado, casi siempre el tiempo	cómo evoluciona
Boxplot	cuantitativa, sola o comparando grupos	posición, dispersión y valores atípicos



Figura 6. Cinco formas de mirar, y cada una responde a un tipo de variable. La elección no es estética.

7.2 El gráfico de barras

Una barra por categoría, con la altura proporcional a la frecuencia. Las barras van **separadas**, porque las categorías no son contiguas: entre Ramallo y Córdoba no hay nada.

Para la localidad: Ramallo 15, Córdoba 11, Concepción 11.

Dos reglas.

El eje de frecuencias empieza en cero. Truncarlo multiplica visualmente las diferencias. Con el eje empezando en 10, Ramallo parece cinco veces Córdoba en lugar de 1,4 veces.

El orden depende de la escala. En una variable **nominal** no hay orden natural, así que conviene ordenar por frecuencia, de mayor a menor, que es lo que se lee mejor. En una variable **ordinal** hay que respetar el orden propio de la variable. La satisfacción del relevamiento es ordinal, y sobre los 27 hogares que la declararon va mala 7, regular 11, buena 9: ordenarla por frecuencia rompería la escala y escondería que la mayoría está en el medio. Los otros 10 hogares no tienen el dato, y el gráfico tiene que decirlo.

La columna servicios no entra en este esquema, y conviene saber por qué. Cada hogar declara varios servicios a la vez, así que las categorías no son excluyentes: luz 35, agua 31, gas 17 y cloacas 5 suman 88 sobre 37 hogares. Se grafica con barras y **no** con un sectorial, porque no hay un total que repartir.



Figura 7. Recortar por abajo y volver a estirar lo que queda: los mismos datos admiten dos lecturas opuestas.

7.3 El gráfico sectorial

El de torta. Divide un disco en porciones proporcionales a cada categoría.

Sirve para una sola cosa: mostrar **qué parte del total** ocupa cada categoría, cuando las categorías son pocas, excluyentes y suman el total.

Y sirve menos seguido de lo que se lo usa, por una razón concreta: **el ojo compara longitudes mucho mejor que ángulos y áreas**. Con Córdoba y Concepción en 11 cada una, las dos porciones son idénticas y no hay problema. Con 11 y 12, la diferencia entre las dos porciones es de 4 grados sobre 360, y en un gráfico de barras se ve enseguida.

Conviene evitarlo con más de cinco o seis categorías, con categorías de valores parecidos — que es el caso donde más importa distinguirlas—, con cualquier variable ordinal o cuantitativa, porque el disco no tiene un orden que se lea, y con datos que no suman un total, como servicios.




Figura 8. Las mismas cantidades, dos codificaciones. Una se ordena a ojo y la otra no.

7.4 El histograma

Es el gráfico de la serie de frecuencia con intervalos de la sección 2.3. Una barra por intervalo, con la altura igual a la frecuencia, y las barras **pegadas**, porque los intervalos sí son contiguos.

Esa es la diferencia visual con el gráfico de barras, y no es decorativa: las barras pegadas dicen que el eje horizontal es una escala continua, y las separadas dicen que son categorías sueltas.

El histograma del ingreso, con los siete intervalos de la sección 2.3, muestra tres cosas de un vistazo: la masa de hogares concentrada abajo, la caída rápida, y el hogar de 620.000 solo, separado por dos clases vacías. Es la asimetría de 2,87 dibujada.

Dos cuidados al armarlo.

La cantidad de intervalos cambia lo que se ve. Con 3 intervalos el histograma del ingreso queda plano y el hogar de 620.000 desaparece dentro de una barra. Con 30 intervalos queda un peine de barras de altura 1 y no se ve ninguna forma. Probá dos o tres cantidades antes de elegir.

Con intervalos de distinta amplitud, la altura no es la frecuencia. En ese caso lo que representa la frecuencia es el **área** de la barra, así que la altura tiene que ser la frecuencia dividida por la amplitud. Es la misma idea de la densidad de la sección 3.4 de la unidad 2. Con intervalos de amplitud constante, que es el caso normal, el problema no existe.

7.5 El gráfico de líneas

Une los puntos de una variable a lo largo de un eje ordenado, casi siempre el tiempo. Sirve para ver la evolución: si sube, si baja, si tiene saltos.

La condición que lo autoriza es que **el eje horizontal tenga un orden real y continuo**. Unir con una línea los valores de tres localidades sugiere que hay algo entre Ramallo y Córdoba, y no lo hay: eso va en barras.

El relevamiento admite un gráfico de líneas por fecha de visita: 25 primeras visitas en marzo y 12 en abril, más las 8 revisitas de junio. Con 45 registros en tres meses, la serie es corta y sirve como ejemplo de construcción, no como análisis de una tendencia.

7.6 El boxplot

El **boxplot**, o diagrama de caja y bigotes, dibuja de una vez casi todo lo de las secciones 3 a 6.

Tiene cinco elementos:

- **La caja** va de Q_1 a Q_3 , así que su largo es el RIC y contiene la mitad central de los datos.
- **La línea de adentro** es la mediana. No está necesariamente en el medio de la caja: si está corrida hacia abajo, la distribución está estirada hacia arriba.
- **Los bigotes** llegan hasta el dato más alejado que todavía cae dentro de $Q_1 - 1,5 \times \text{RIC}$ y $Q_3 + 1,5 \times \text{RIC}$. **Los bigotes terminan en un dato real**, no en el límite calculado.
- **Los puntos sueltos** son los valores atípicos por la regla de la sección 6.1.
- **El eje** con la escala de la variable.

El boxplot del ingreso, con los números de este apunte:

Elemento	Valor
Atípico inferior	0
Bigote inferior	120.000
Q_1	173.500
Mediana	193.000
Q_3	219.500
Bigote superior	260.000
Atípicos superiores	310.000 y 620.000

Detenete en los dos bigotes, porque es donde más se confunde el dibujo con la regla. El límite inferior de la regla es 104.500 y el bigote termina en 120.000, que es el dato más bajo por encima de ese límite. El límite superior es 288.500 y el bigote termina en 260.000, por la misma razón.

Se lee así: la mitad de los hogares está entre 173.500 y 219.500, la mediana está algo corrida hacia abajo dentro de la caja, y hay tres hogares fuera de los bigotes, uno por debajo y dos por encima.

Donde más rinde es **comparando grupos**: tres boxplots de ingreso, uno por localidad, uno al lado del otro, muestran de un vistazo cuál tiene el centro más alto y cuál varía más.

Y lo que el boxplot **no** muestra: la forma de la distribución. Una distribución con dos picos y una con uno solo pueden dar el mismo boxplot. Para la forma hace falta el histograma, y por eso los dos se informan juntos.




Figura 9. Los mismos datos, dos lecturas. El histograma muestra la forma; el boxplot, la posición, la dispersión y los extremos.

8. EL ANÁLISIS DESCRIPTIVO COMPLETO

Las medidas sueltas no describen nada. Lo que describe es el conjunto, y conviene informarlo siempre en el mismo orden.

El resumen de cinco números es el mínimo, y es exactamente lo que dibuja el boxplot: mínimo, Q_1 , mediana, Q_3 y máximo.

El análisis completo de una variable cuantitativa, sobre el ingreso del relevamiento:

Qué	Valor
Casos válidos	35 de 37
Mínimo y máximo	0 y 620.000
Media	203.471
Mediana	193.000
Modo	no tiene: amodal
Q_1 y Q_3	173.500 y 219.500
Desvío standard	86.103
RIC	46.000
Coefficiente de variabilidad	42,32%
Asimetría α_3	2,8714
Kurtosis α_4	16,6556
Atípicos por $1,5 \times \text{RIC}$	0, 310.000 y 620.000

Y el párrafo que hay que poder escribir a partir de esa tabla: *el ingreso de los 35 hogares con dato tiene una mediana de 193.000 y una media de 203.471; la diferencia entre las dos y una asimetría de 2,87 indican una distribución estirada hacia los ingresos altos. La mitad central está entre 173.500 y 219.500, un recorrido de 46.000. Tres hogares quedan fuera del límite de la regla del $1,5 \times \text{RIC}$: uno que declaró cero y dos de ingresos altos, y el de 620.000 es el que más pesa sobre la media, el desvío y la kurtosis. Dos hogares no tienen el dato.*

Fijate en lo que hace ese párrafo. Da el centro con las dos medidas, da la dispersión con las dos medidas, nombra los extremos, y declara el denominador. Ninguna de las cuatro cosas se puede omitir.

9. LAS MEDIDAS DE LA UNIDAD 2 Y LAS DE ESTA

El resumen de la relación entre las dos unidades:

Concepto	Unidad 2, sobre una variable aleatoria	Unidad 4, sobre datos
Qué pesa cada valor	su probabilidad $P(X = x)$	su frecuencia relativa fr_i
Centro	esperanza $E(X)$, μ	media $\bar{x}$
Dispersión	varianza $V(X)$, σ^2	varianza s^2 , con n o con $n - 1$
Acumulada	$F(x) = P(X \leq x)$	F_i y Fr_i
Forma	α_3 y α_4	los mismos, más los de Pearson
Qué describe	lo que se espera	lo que se midió

Las medidas que existen solo en esta unidad son las tres resistentes —mediana, cuartiles y RIC— más el modo. No aparecieron en la unidad 2 porque ahí lo que había era una fórmula, y acá lo que hay es una serie ordenada.

10. SIETE ERRORES FRECUENTES

1. Informar la media de una distribución estirada, y solo la media. Con el ingreso son 203.471 contra una mediana de 193.000, y 22 de los 35 hogares están por debajo de la media.

2. No declarar el denominador. 35 de 37 no es un detalle: es la diferencia entre describir a los hogares con dato y describir a todos.

3. Confundir un cero con un faltante. El 0 del hogar 38 es un ingreso declarado. Descartarlo sube la media de 203.471 a 209.456. El centinela era el 999999 del hogar 9, y ese sí es una ausencia.

4. Mezclar n y $n - 1$ sin decirlo. pandas y numpy dan resultados distintos sobre los mismos datos, y los dos son correctos para preguntas distintas.

5. Truncar el eje de un gráfico de barras. Con el eje empezando en 10, Ramallo parece cinco veces Córdoba en lugar de 1,4 veces.

6. Usar un sectorial donde va un gráfico de barras. Con muchas categorías, con categorías parecidas, con una variable ordinal, o con datos que no suman un total.

7. Calcular sobre la tabla agrupada teniendo los datos sin agrupar. Da 201.429 en lugar de 203.471, sin ninguna ventaja.

11. LISTA DE VERIFICACIÓN

Antes de dar por buena la descripción de una variable:

1. **¿Cuántos casos válidos hay, y por qué los otros no lo son?** Faltantes y centinelas se cuentan y se declaran por separado, y un cero no es ninguno de los dos.
2. **¿Qué tipo de variable es, y en qué escala está medida?** Decide qué medidas y qué gráficos tienen sentido.
3. **¿Informaste el centro con dos medidas?** Media y mediana. Si difieren mucho, explicá por qué.
4. **¿Informaste la dispersión?** Un centro sin dispersión no describe nada.
5. **¿Usaste n o $n - 1$, y lo dijiste?** Depende de si los datos son la población o una muestra.
6. **¿Buscaste valores extremos con los dos criterios?** El z-score supone normalidad y el $1,5 \times \text{RIC}$ no.
7. **¿Con qué método calculaste los cuartiles?** Los que usan pandas y numpy no son los de la fórmula $k(n+1)/4$.
8. **¿El gráfico corresponde al tipo de variable, y el eje empieza en cero?**
9. **¿Alguna conclusión habla de casos que no se midieron?** Si es así, eso es inferencia y todavía no se puede afirmar.