

ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

EJERCITACIÓN · ANÁLISIS DE DATOS

Bloque 2 · Asignatura E8102 — Exploración de datos

Docentes: Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

Asignatura: E8102 — Exploración de datos

Cohorte o comisión: Cohorte 2026

1. LA CONSIGNA

Esta ejercitación repasa la unidad 4, Análisis de datos, con datos reales y con decenas de miles de casos: la Encuesta Permanente de Hogares del INDEC, del segundo trimestre de 2025. Son trece ejercicios cortos en el orden del apunte, más un ejercicio 0 de práctica. Cada uno toma una sección y la aplica a una variable de la encuesta.

Está pensada para la clase asincrónica de tres horas. Los ejercicios 6, 8 y 12 son **opcionales**: se pueden saltar enteros, con su ejemplo, y el resto del notebook funciona igual.

No se entrega y no se corrige, y **no hace falta saber programar**.

Se resuelve en el notebook del bloque, `ejercitacion_bloque_2.ipynb`, que se abre en Google Colab: en colab.research.google.com, Archivo → Subir notebook, y se elige el archivo. El notebook descarga los datos solo, así que hace falta conexión a internet. Cada ejercicio tiene cuatro partes:

1. **Cómo se hace.** Un ejemplo resuelto sobre otra variable, con la explicación de cada instrucción nueva. La celda ya está completa: se ejecuta y se mira el resultado.
2. **Ahora vos.** Una celda casi igual al ejemplo, con huecos marcados COMPLETAR. Cada hueco se llena con poco: un número, el nombre de una columna, de una medida o de una variable que ya existe, o una cuenta corta como $q3 - q1$. Casi siempre la respuesta se copia del ejemplo, cambiando la variable. La sección 3.10 explica cómo se llena un hueco.
3. **Control.** Una celda que dice si cada resultado es correcto, sin mostrarlo.
4. **Pregunta.** En la mayoría de los ejercicios, una pregunta para contestar con tus palabras. No tiene control, porque la respuesta es una interpretación, y es la parte que más importa: en esta asignatura un número sin lectura no describe nada.

Este documento acompaña al notebook. Las secciones 3 y 4 son una guía corta de lo que hace falta de Python y de gráficos, para leer antes o para consultar mientras se resuelve. La sección 5 resume los ejercicios, y la 7 tiene las soluciones, para leer después de intentar cada ejercicio.

La unidad 3 no tiene ejercicios acá: sus distribuciones vuelven a usarse sobre datos en el bloque 3.

2. LOS DATOS

La **Encuesta Permanente de Hogares**, o EPH, es la encuesta con la que el INDEC mide cada trimestre el empleo, los ingresos y las condiciones de vida en 32 aglomerados urbanos. La base de personas del segundo trimestre de 2025 tiene 46.086 personas de 16.169 hogares, y 235 columnas con códigos numéricos.

La ejercitación usa una versión reducida de esa base, con pocas columnas y las categorías escritas en castellano. El notebook la carga sola, en tres tablas:

Tabla	Filas	Una fila es
personas	46.086	una persona encuestada
hogares	16.169	un hogar
trimestres	12	un trimestre, de 2023 a 2025

Las columnas de personas:

Columna	Qué es
id_hogar y componente	el número del hogar y el de la persona dentro del hogar
region	la región: Gran Buenos Aires, Noroeste, Noreste, Cuyo, Pampeana o Patagonia
sexo	varón o mujer
edad	años cumplidos
nivel_educativo	el máximo nivel alcanzado, de sin instrucción a superior o universitario completo
condicion_actividad	ocupado, desocupado, inactivo, menor de 10 años o entrevista individual no realizada
categoria_ocupacional	solo ocupados: patrón, cuenta propia, obrero o empleado o trabajador familiar sin remuneración
horas_semanales	solo ocupados: horas trabajadas en la semana en la ocupación principal
ingreso_ocupacion_principal	solo ocupados: ingreso mensual de la ocupación principal, en pesos

En las personas que no están ocupadas, las tres últimas columnas están vacías, porque la pregunta no les corresponde.

La tabla hogares tiene, entre otras columnas, la region y la cantidad de miembros de cada hogar. La tabla trimestres resume doce encuestas, de 2023 a 2025: cuántas personas se encuestaron, cuántos ocupados hubo, y la mediana y la media del ingreso de la ocupación principal, en pesos de cada momento.

Hay dos cosas que conviene saber antes de empezar.

Los montos y las horas conservan los códigos del INDEC. En el ingreso de la ocupación principal, -9 es la no respuesta y 0 es "sin ingresos": un ocupado que no cobró nada por esa ocupación en el mes de referencia. En las horas semanales, 999 es "no sabe o no responde" y 0 es un ocupado que esa semana no trabajó. Es la distinción de la sección 2.1 del apunte, y el ejercicio 2 trata sobre ella.

Los números describen a los encuestados, no a la población. Cada persona de la EPH representa a muchas otras, y las cifras oficiales se calculan con un factor de expansión que estos archivos no traen. Para los ingresos, el INDEC usa uno que les da peso cero a los -9 y reparte ese peso entre los que respondieron. Lo que se calcula acá es la descripción de una muestra de 46.086 personas, que es lo que corresponde a la unidad 4. La media del ingreso que sale en el ejercicio 5 no es la que publica el INDEC, y no tiene por qué serlo.

3. LO MÍNIMO DE PYTHON

Toda la ejercitación usa una docena de instrucciones, y se repiten. Esta sección las presenta agrupadas por tema. El ejercicio 0 del notebook practica las de 3.1 a 3.5 antes de empezar.

3.1 Celdas y variables

Un notebook está hecho de celdas. Las de texto se leen; las de código se ejecutan con Shift + Enter, y muestran abajo el resultado de su última línea. Si esa línea pone un nombre con =, no se muestra nada, y está bien.

El signo = le pone **nombre** a un resultado, para usarlo después:

```
total = 5 + 7
total * 2
```

La primera línea guarda el 12 con el nombre `total`; la segunda lo usa y muestra 24. Si un resultado aparece como `np.int64(3288)` o `np.float64(35.36)`, el número es el que está entre paréntesis. Ese nombre se llama **variable**, y dura mientras el notebook esté abierto. Por eso los ejercicios se hacen en orden: cada uno usa variables que creó el anterior.

`print(...)` muestra en pantalla lo que va entre paréntesis. Un texto entre comillas acompaña al número para decir qué es: `print("Edad media:", 37.0)`. Muchas celdas escriben los números con `num(valor, 2)`, que los muestra con coma decimal, punto de miles y los decimales que se piden, como el apunte.

3.2 La tabla y una columna

Una tabla, en pandas, se llama `DataFrame`. `personas.head()` muestra sus primeras cinco filas. Una columna se elige con su nombre entre corchetes y comillas:

```
personas["edad"]
```

El nombre tiene que estar escrito exactamente igual que en la tabla: `personas["Edad"]` da error, porque la columna se llama `edad`, en minúscula.

3.3 Las medidas de una columna

Sobre una columna se piden medidas con un punto, el nombre de la medida y paréntesis:

Instrucción	Qué devuelve
<code>.mean()</code>	la media
<code>.median()</code>	la mediana
<code>.mode().iloc[0]</code>	el modo; <code>.mode()</code> devuelve una lista, y <code>.iloc[0]</code> toma el primero
<code>.min()</code> y <code>.max()</code>	el mínimo y el máximo
<code>.std(ddof=0)</code>	el desvío con divisor n ; <code>.std()</code> sin nada divide por $n - 1$
<code>.quantile([0.25, 0.75])</code>	los cuartiles Q_1 y Q_3

Instrucción	Qué devuelve
<code>.sum()</code>	la suma
<code>len(columna)</code>	cuántos valores hay; va adelante y sin punto

Para la asimetría y la kurtosis se usa la librería `scipy.stats`: `stats.skew(columna)` da α_3 , y `stats.kurtosis(columna, fisher=False)` da α_4 . Sin el `fisher=False` devuelve el exceso, $\alpha_4 - 3$, que es la advertencia de la sección 5.3 del apunte.

3.4 Contar categorías

`.value_counts()` cuenta cuántas veces aparece cada valor, de mayor a menor:

```
personas["region"].value_counts()
```

Para una serie de frecuencia hace falta el orden de los valores y no el de las frecuencias, y eso se pide agregando `.sort_index()`. $f_i / f_i.sum()$ divide cada frecuencia por el total y da f_{ri} . Después, `.cumsum()` acumula, que es lo que da las columnas F_i y F_{ri} .

3.5 Quedarse con algunas filas

Una condición entre corchetes deja solo las filas que la cumplen:

```
ocupados = personas[personas["condicion_actividad"] == "ocupado"]
```

Se lee: de personas, las filas donde `condicion_actividad` es igual a "ocupado". El **doble igual** == pregunta; el igual simple = pone el nombre. También se puede preguntar con != (distinto de), <, >, <= y >=.

Una condición sobre una columna da verdadero o falso fila por fila, y eso sirve para contar: `.sum()` cuenta los verdaderos, y `.mean()` da la proporción. `(ocupados["horas_semanales"] == 999).sum()` dice cuántos 999 hay: 33.

3.6 Sacar un centinela

Un centinela se convierte en celda vacía con `.replace(...)`, y las celdas vacías se descartan con `.dropna()`:

```
horas = ocupados["horas_semanales"].replace(999, np.nan).dropna()
```

`np.nan` es la celda vacía. La instrucción cambia solo el 999: los ceros quedan.

3.7 Cortar en intervalos

`pd.cut(columna, bins=bordes, right=False)` pone cada valor en su intervalo. `bordes` es la lista de cortes, y `list(range(10, 101, 10))` la arma: 10, 20, 30, ..., 100. El segundo número de `range` es hasta dónde llegar, y no se incluye, por eso es 101 y no 100.

Una lista va entre corchetes, con los elementos separados por comas: `[0.25, 0.75]`, o `["varón", "mujer"]` si son textos.

El `right=False` es la convención de la asignatura, cerrado a la izquierda y abierto a la derecha. Sin él, pandas hace lo contrario. Es la advertencia de la sección 2.3 del apunte.

3.8 Calcular por grupo

`.groupby(...)` separa las filas por las categorías de una columna, y hace la cuenta en cada grupo:

```
ocupados.groupby("sexo")["edad"].median()
```

Se lee: separará a los ocupados por sexo, y en cada grupo calculará la mediana de la edad.

3.9 Los errores

Un error en rojo no rompe nada: se corrige la celda y se vuelve a ejecutar. Los que más aparecen:

Error	Qué quiere decir
NameError: name 'COMPLETAR' is not defined o KeyError: 'COMPLETAR'	quedó un hueco sin completar
KeyError con el nombre de una columna	el nombre está mal escrito
AttributeError: 'Series' object has no attribute 'COMPLETAR'	quedó sin completar un hueco como <code>.COMPLETAR()</code> : va el nombre de la medida
NameError con el nombre de una variable	la celda que la crea no se ejecutó; se arregla ejecutando las anteriores

3.10 Cómo se llena un hueco

Se borra solo la palabra `COMPLETAR`, y lo que la rodea queda igual:

- `"COMPLETAR"`, entre comillas: va un texto, entre esas mismas comillas.
`personas["COMPLETAR"]` pasa a `personas["edad"]`.
- `.COMPLETAR()`: va solo el nombre de la medida, porque el punto y los paréntesis ya están.
`columna.COMPLETAR()` pasa a `columna.mean()`.
- `COMPLETAR` sin comillas: va un número, el nombre de una variable, una cuenta corta, o `True` o `False`, sin agregar comillas.

En el código, los decimales van con punto y los miles no llevan separador: `0.75` y `13847`, no `0,75` ni `13.847`. Python lee la coma como una separación entre dos números. Este documento escribe los resultados con coma decimal y punto de miles, como el apunte; en el código, no.

4. CÓMO SE ARMA UN GRÁFICO

4.1 El molde

Los gráficos de la ejercitación se hacen con matplotlib, y todos siguen el mismo molde de cuatro pasos:

```
fig, ax = plt.subplots()
ax.bar(categorias, alturas)
ax.set_title("Un título")
plt.show()
```

`categorias` y `alturas` ocupan el lugar de los datos; la sección 4.2 tiene un ejemplo completo.

1. `plt.subplots()` crea un gráfico vacío. `ax` es el lugar donde se dibuja.
2. Una instrucción sobre `ax` dibuja. Cambia según el gráfico: `ax.bar`, `ax.hist`, `ax.plot`.
3. Otras instrucciones lo terminan: `ax.set_title(...)` el título, `ax.set_ylabel(...)` el nombre del eje vertical, `ax.set_ylim(desde, hasta)` dónde empieza y termina ese eje.
4. `plt.show()` lo muestra.

Para dos gráficos uno al lado del otro, `fig, (ax1, ax2) = plt.subplots(1, 2)` crea dos lugares, y cada uno se dibuja por separado. `plt.subplots(2, 1)` los pone uno arriba del otro. Las celdas del notebook agregan otras opciones, como `figsize=(10, 4.5)` para el tamaño, `color=TEAL` para el color o `ax.tick_params(axis="x", rotation=30)` para inclinar los nombres del eje. Solo cambian el aspecto, y no hace falta tocarlas.

4.2 Barras

Primero se cuenta, y después se dibuja una barra por categoría:

```
conteo = ocupados["categoria_ocupacional"].value_counts()
fig, ax = plt.subplots()
ax.bar(conteo.index, conteo.to_numpy())
ax.set_ylim(0, conteo.max() * 1.1)
plt.show()
```

`conteo.index` son los nombres de las categorías y `conteo.to_numpy()` las cantidades. El `set_ylim(0, ...)` hace que el eje empiece en cero, como pide la sección 7.2 del apunte. Si la variable es ordinal, el orden se fija con `.reindex(lista)`, donde la lista tiene las categorías en su orden propio. Una categoría mal escrita no da error: su barra no aparece.

4.3 Histograma

`ax.hist(columna, bins=bordes)` recibe los datos sin contar y los bordes de los intervalos, y cuenta solo. Las barras salen pegadas, porque los intervalos son contiguos.

4.4 Boxplot

El notebook trae dos herramientas para el boxplot. `por_grupo(tabla, columna, grupo, orden)` separa los valores de una columna por categoría, y `caja(ax, grupos, nombres)` dibuja una caja por grupo:

```
grupos = por_grupo(ocupados, "edad", "sexo", ["varón", "mujer"])
fig, ax = plt.subplots()
caja(ax, grupos, ["varón", "mujer"])
plt.show()
```

4.5 Líneas

`ax.plot(x, y, marker="o")` une los puntos con una línea y marca cada uno. Para dos líneas en el mismo gráfico se llama dos veces, cada una con su `label="..."`, y `ax.legend()` muestra los nombres. `ax.set_ylim(0, None)` empieza el eje en cero y deja que matplotlib elija dónde termina.

4.6 Tres cuidados

- **El eje de frecuencias empieza en cero.** Si no, las diferencias se ven más grandes de lo que son.
- **Una variable ordinal va en su orden.** El orden alfabético o el de un código numérico no son el de la variable.
- **Un histograma depende de sus intervalos.** Conviene probar dos o tres cantidades antes de elegir.

5. LOS EJERCICIOS

Ejercicio	Tema	Ejemplo resuelto sobre	Apunte de la unidad 4
0	Primeros pasos	la edad de los varones	—
1	Qué es cada variable	los valores de dos columnas	1.2 y 1.4
2	El denominador: vacíos, centinelas y ceros	las horas	2.1
3	La serie de frecuencia sin agrupar	la edad de los menores de 10 años	2.2
4	La serie con intervalos	la edad de los ocupados	2.3 y 2.4
5	Las tres medidas de posición	las horas	3.1 a 3.4
6	Los cuartiles, a mano y con pandas (opcional)	siete números	3.5
7	Las medidas de variabilidad	la edad de los ocupados	4.1 a 4.5
8	La asimetría y la kurtosis (opcional)	la edad de los ocupados	5.1 a 5.3
9	Los dos criterios de valor extremo	las horas	6
10	El gráfico de barras	la categoría ocupacional	7.1 a 7.3
11	El histograma y el boxplot	la edad, y las horas por sexo	7.4 y 7.6
12	El gráfico de líneas (opcional)	las personas encuestadas	7.5
13	El análisis descriptivo completo	—	8 y 11

5.1 Ejercicio 0 — Primeros pasos

Contar las mujeres encuestadas y calcular su edad media. El ejemplo hace lo mismo con los varones.

5.2 Ejercicio 1 — Qué es cada variable

Asignar una escala de medición a seis columnas: `region`, `sexo`, `nivel_educativo`, `edad`, `horas_semanales` e `ingreso_ocupacion_principal`. Las opciones son nominal, ordinal, de intervalo y de razón.

5.3 Ejercicio 2 — El denominador: vacíos, centinelas y ceros

El ejemplo saca el 999 de las horas. El ejercicio hace lo mismo con el ingreso: contar los -9 y los ceros, y armar `ingreso_valido` sin los -9 y con los ceros. La celda compara la media correcta con dos equivocadas.

Pregunta. ¿Cuál de las tres medias se informa, y con qué denominador? ¿Qué parte de los ocupados queda afuera?

5.4 Ejercicio 3 — La serie de frecuencia sin agrupar

Armar la serie de frecuencia de la cantidad de miembros del hogar, con sus cuatro columnas, sobre la tabla hogares. Leer en las columnas acumuladas la mediana, en la primera fila donde Fr_i llega a 0,5, y cuántos hogares tienen cuatro miembros o menos, en el F_i de la fila del 4.

5.5 Ejercicio 4 — La serie con intervalos

Calcular la regla de Sturges para las horas y agruparlas en intervalos de 10 horas desde 0, cerrados a la izquierda, sin que ningún dato quede afuera. Comparar la media agrupada con la real.

Pregunta. ¿Por qué la media agrupada queda casi dos horas por encima de la real?

5.6 Ejercicio 5 — Las tres medidas de posición

Calcular la media, la mediana y el modo del ingreso, y qué parte de los ocupados gana menos que la media. Elegir cuál de las tres medidas se informa como ingreso típico.

Pregunta. ¿Por qué esa medida, y no las otras dos? ¿Qué tienen en común los valores más repetidos, y por qué el ingreso del relevamiento no tenía modo?

5.7 Ejercicio 6 — Los cuartiles, a mano y con pandas (opcional)

Con los primeros once ingresos de la Patagonia, ubicar los tres cuartiles con la fórmula $k(n+1)/4$ y compararlos con los de numpy.

5.8 Ejercicio 7 — Las medidas de variabilidad

Calcular el rango, el desvío con divisor n , el RIC y el coeficiente de variabilidad del ingreso. Elegir cuál de las tres primeras describe mejor la dispersión.

Pregunta. ¿Cuánto cambia el desvío al pasar de n a $n - 1$? ¿Por qué esa medida para la dispersión? ¿Qué varía relativamente más, el ingreso o las horas?

5.9 Ejercicio 8 — La asimetría y la kurtosis (opcional)

Calcular α_3 , α_4 y los dos coeficientes de asimetría de Pearson del ingreso.

Pregunta. En el relevamiento del apunte, los coeficientes de asimetría de las personas por hogar coincidían en el signo. ¿Coinciden acá? Si no, ¿qué medida de posición produce la diferencia?

5.10 Ejercicio 9 — Los dos criterios de valor extremo

Contar los ingresos que marca el z-score con umbral 3 y los que marca la regla del $1,5 \times \text{RIC}$.

Pregunta. ¿Por qué marcan cantidades tan distintas? ¿Los ceros quedan marcados? ¿Qué se hace con lo que marca cada criterio?

5.11 Ejercicio 10 — El gráfico de barras

Graficar la región ordenada por frecuencia y el nivel educativo en su orden propio, con el eje de frecuencias empezando en cero.

Pregunta. ¿Qué habría pasado si el nivel educativo se hubiera ordenado por el código del INDEC? ¿Para cuáles de `region`, `nivel_educativo` y `categoria_ocupacional` se podría usar un gráfico sectorial, y para cuál no?

5.12 Ejercicio 11 — El histograma y el boxplot

Dibujar el histograma de las horas con los intervalos del ejercicio 4, y un boxplot del ingreso por nivel educativo. Calcular la mediana del ingreso de cada nivel.

Pregunta. ¿Qué muestra el histograma que el boxplot no mostraría? ¿Cómo cambia la mediana con el nivel educativo, y en qué grupo la comparación no es confiable?

5.13 Ejercicio 12 — El gráfico de líneas (opcional)

Graficar la mediana y la media del ingreso a lo largo de los doce trimestres de 2023 a 2025, y calcular cuántas veces creció la mediana.

Pregunta. ¿Por qué acá va un gráfico de líneas? ¿Por qué la media queda siempre arriba? ¿Se puede decir que los ocupados ganan diez veces más que en 2023?

5.14 Ejercicio 13 — El análisis descriptivo completo

Completar la tabla de la sección 8 del apunte para el ingreso de los ocupados de una región, y escribir el párrafo descriptivo.

6. CÓMO VERIFICAR EL RESULTADO

Hay dos controles, y conviene usarlos en este orden.

La celda de control del notebook. Después de cada ejercicio hay una celda **Control** que revisa cada resultado y marca ✓ o ✗. Calcula las respuestas a partir de los datos y no las muestra, así que se puede probar varias veces sin enterarse de la solución. Si un ✗ aparece en algo que viene de un ejercicio anterior, como `ingreso_valido` o `media`, el error está en ese ejercicio.

Las soluciones de la sección 7. Tienen los huecos completos, los números que tienen que salir y una respuesta posible para cada pregunta. Para las preguntas no hay una única redacción correcta: lo que hay que comparar es si tu respuesta usa los mismos números y llega a la misma conclusión.

7. LAS SOLUCIONES

Leé cada solución después de intentar el ejercicio, pasar el control y escribir tu respuesta a la pregunta. Si la lees antes, el hueco se reduce a copiar y la pregunta pierde sentido.

En cada ejercicio va solo lo que se completa. El resto de la celda queda como viene en el notebook.

7.1 Ejercicio 0

```
mujeres = personas[personas["sexo"] == "mujer"]
cantidad_de_mujeres = len(mujeres)
edad_media_mujeres = mujeres["edad"].mean()
```

Hay 23.940 mujeres encuestadas, con una edad media de 38,36 años. Los varones son 22.146, con 35,47.

7.2 Ejercicio 1

Columna	Escala	Por qué
region	nominal	seis categorías sin orden
sexo	nominal	dos categorías sin orden
nivel_educativo	ordinal	las categorías tienen un orden, pero la distancia entre dos niveles no se mide
edad	de razón	el cero es "nada", y 40 años es el doble de 20
horas_semanales	de razón	el cero es no haber trabajado ninguna hora
ingreso_ocupacion_principal	de razón	el cero es no haber cobrado nada

Las tres cuantitativas son de razón, así que admiten todas las medidas de la unidad, incluido el coeficiente de variabilidad. El nivel educativo admite el modo y la mediana, pero no la media.

7.3 Ejercicio 2

```
ingreso = ocupados["ingreso_ocupacion_principal"]
cantidad_centinelas = (ingreso == -9).sum()
cantidad_ceros = (ingreso == 0).sum()
ingreso_valido = ingreso.replace(-9, np.nan).dropna()
media_correcta = ingreso_valido.mean()
```

	Casos	Media
Contando el -9 como un ingreso	20.374	645.076
Descartando también los ceros	16.260	808.290
Correcta: sin el -9, con los ceros	16.709	786.570

Se informa la tercera, y siempre con su denominador: **786.570 pesos de media, sobre los 16.709 ocupados que declararon su ingreso**. Quedan afuera 3.665 ocupados, el 18,0%, que no respondieron. La media describe a los que respondieron. Si los que no respondieron ganan distinto, la media de todos los ocupados encuestados sería otra, y con estos datos no se puede saber. Por eso el denominador va siempre con el resultado.

Los dos errores van en direcciones opuestas. Contar el -9 como un monto suma 3.665 ingresos de casi cero y baja la media 141.495 pesos. Descartar los 449 ceros la sube 21.720 pesos, porque saca a ocupados que no cobraron nada por esa ocupación en el mes de referencia. Es la lección del hogar 38 de la unidad 4, con miles de casos: el centinela se excluye, y el cero se conserva porque es un dato.

7.4 Ejercicio 3

```
fi = hogares["miembros"].value_counts().sort_index()
fri = fi / fi.sum()
Fi = fi.cumsum()
mediana_leida = 3
hogares_de_hasta_4 = 13847
```

Miembros	f_i	fr_i	F_i	Fr_i
1	3.676	0,2273	3.676	0,2273
2	4.308	0,2664	7.984	0,4938
3	3.168	0,1959	11.152	0,6897
4	2.695	0,1667	13.847	0,8564
5	1.317	0,0815	15.164	0,9378
6 a 18	1.005	0,0622	16.169	1,0000

La tabla del notebook sigue fila por fila hasta 18 miembros; acá las últimas filas van juntas.

La mediana es **3**: la mitad de los 16.169 hogares, 8.084,5, se alcanza en la fila del 3, porque F_i pasa de 7.984 a 11.152. Y **13.847 hogares**, el 85,64%, tienen cuatro miembros o menos. Las dos cosas se leen en la columna acumulada, sin ordenar nada.

7.5 Ejercicio 4

```
k_sturges = 1 + 3.322 * np.log10(n)
ultimo_borde = 150
clases_horas = pd.cut(horas, bins=bordes, right=False)
media_agrupada_horas = (marcas * fi_horas.to_numpy()).sum() / n
```

Hay 20.341 ocupados con dato de horas, y Sturges da 15,31, así que sugiere 15 intervalos: los 15 de 10 horas que van de 0 a 150. El último borde tiene que ser 150 y no 140, porque con intervalos abiertos a la derecha el valor 140 no entra en $[130, 140)$, y dos ocupados quedarían

afuera. La clase $[130, 140)$ queda con $f_i = 0$ y no se borra: el hueco dice que nadie declaró entre 130 y 140 horas, y separa a los dos casos de 140 del resto (sección 2.3 del apunte).

La media agrupada da **37,12 horas** contra **35,36** reales. La causa está en cómo se declaran las horas: 3.288 personas dijeron exactamente 40 y 2.232 dijeron 48. Las 3.288 de 40 caen en el borde izquierdo de $[40, 50)$, y la marca de clase las cuenta como 45. Lo mismo pasa con los 30 y los 20. La media real de los 7.256 casos de esa clase es 43,49, no 45. Agrupar supone que los datos se reparten parejo adentro del intervalo, y estos se amontonan en los números redondos. En la edad del ejemplo eso no pasa, y por eso las dos medias casi coinciden.

Si se usa `right=True`, los intervalos pasan a ser $(40, 50]$, y los 3.288 de 40 se mudan a $(30, 40]$. Y los 331 ocupados con 0 horas quedan afuera de todos los intervalos, porque $(0, 10]$ no incluye al 0. El control del ejercicio lo detecta.

7.6 Ejercicio 5

```
media = ingreso_valido.mean()
mediana = ingreso_valido.median()
modo = ingreso_valido.mode().iloc[0]
proporcion_bajo_la_media = (ingreso_valido < media).mean()
ingreso_tipico = mediana
```

La media es **786.570**, la mediana **650.000** y el modo **800.000**, con 1.172 personas. El 57,7% de los ocupados que declararon su ingreso gana menos que la media.

El ingreso típico se informa con la **mediana**, junto con la media. La distribución está estirada hacia la derecha, y la media queda 136.570 pesos por encima de la mediana: la arrastran unos pocos ingresos muy altos, hasta 30.000.000.

El modo existe porque la gente declara su ingreso redondeado. Los seis valores más repetidos son 800.000, 1.000.000, 600.000, 400.000, 500.000 y 700.000, y el 71,4% de los ingresos declarados es múltiplo de 100.000. En el relevamiento había 35 valores, todos distintos, y no se repetía ninguno. El modo de una variable continua dice cómo se redondea al responder, no dónde está el centro.

7.7 Ejercicio 6

```
q1_formula = en_posicion(once, 3)
q2_formula = en_posicion(once, 6)
q3_formula = en_posicion(once, 9)
```

Los once valores ordenados son 500.000, 580.000, 600.000, 750.000, 1.000.000, 1.000.000, 1.100.000, 1.200.000, 1.400.000, 1.800.000 y 4.000.000. Con $n = 11$, las posiciones son $1 \times 12 / 4 = 3$, $2 \times 12 / 4 = 6$ y $3 \times 12 / 4 = 9$.

	Fórmula $k(n+1)/4$	numpy y pandas
Q_1	600.000	675.000
Q_2	1.000.000	1.000.000
Q_3	1.400.000	1.300.000
RIC	800.000	625.000

La mediana coincide; los otros dos no. Con once datos el RIC de la fórmula es un 28% más grande que el de numpy, y por eso un cuartil no se informa sin el método. Con los 16.709 ingresos los dos métodos dan lo mismo: 350.000, 650.000 y 1.000.000.

7.8 Ejercicio 7

```
rango = ingreso_valido.max() - ingreso_valido.min()
desvio_n = ingreso_valido.std(ddof=0)
q1, q3 = ingreso_valido.quantile([0.25, 0.75])
ric = q3 - q1
cv_ingreso = desvio_n / media
dispersion_tipica = ric
```

Medida	Ingreso	Horas
Rango	30.000.000	140
Desvío, divisor n	804.562	16,43
Q_1 y Q_3	350.000 y 1.000.000	24 y 46
RIC	650.000	22
CV	102,29%	46,47%

Pasar de n a $n - 1$ cambia el desvío del ingreso un **0,0030%**: de 804.562 a 804.586. Con 16.709 casos, dividir por 16.709 o por 16.708 da casi lo mismo. Es lo que anticipaba la sección 4.3 del apunte: la corrección importa con 5 casos y desaparece con miles.

El rango depende solo de los dos valores extremos, el 0 que declararon 449 ocupados y el 30.000.000 de una sola persona. Sirve como referencia del recorrido, no como descripción de la dispersión. Para la dispersión del ingreso va el **RIC**: la mitad central de los ocupados que declararon su ingreso está entre 350.000 y 1.000.000. El desvío es más grande que el RIC porque los ingresos muy altos lo inflan.

El ingreso varía relativamente más que las horas: su desvío es mayor que su propia media, y el de las horas es menos de la mitad.

7.9 Ejercicio 8

```
a4 = stats.kurtosis(ingreso_valido, fisher=False)
ap1 = (media - modo) / desvio_n
ap2 = 3 * (media - mediana) / desvio_n
```

Coeficiente	Valor
α_3	8,6365
α_4	197,1160
$Ap_1 = (\bar{x} - \text{modo}) / s$	-0,0167
$Ap_2 = 3(\bar{x} - \text{mediana}) / s$	0,5092

α_3 y Ap_2 son positivos, y Ap_1 es **negativo**. En el relevamiento del apunte coincidían; acá no, aunque la distribución está claramente estirada hacia la derecha.

La diferencia la produce el **modo**. Vale 800.000, apenas por encima de la media de 786.570, y no porque el centro esté ahí: es el número redondo que más gente eligió al responder, como se vio en el ejercicio 5. Ap_1 depende de una medida de posición que en esta variable no es confiable. El apunte ya prefería Ap_2 porque se puede calcular siempre, aun en una serie amodal, y este caso agrega otra razón: el modo puede existir y no representar el centro.

La kurtosis de 197 contra el 3 de la normal dice que la distribución es muy leptocúrtica, como el ingreso del relevamiento en la sección 5.1 del apunte: el peso de la distribución está en las colas. Los diez ingresos más alejados de la media, de 16.709, aportan el 93,9% de la suma de las cuartas potencias.

7.10 Ejercicio 9

```
z = (ingreso_valido - media) / desvio_n
marcados_z = (z.abs() > 3).sum()
limite_superior = q3 + 1.5 * ric
marcados_ric = ((ingreso_valido < limite_inferior) | (ingreso_valido >
limite_superior)).sum()
```

El z tiene que dividir por el desvío con divisor n , el `desvio_n` del ejercicio 7.

El z -score marca **188** ingresos, los que pasan de 3.200.255. La regla del $1,5 \times \text{RIC}$ marca **962**, los que pasan de 1.975.000. El límite inferior de esa regla es -625.000, así que no marca ningún valor bajo.

La diferencia es la de la sección 6.1 del apunte, con más casos. El z -score mide contra la media y el desvío, y los dos ya están inflados por los ingresos altos: con un desvío de 804.562, hay que pasar los 3,2 millones para quedar a tres desvíos. El RIC no usa ni la media ni el desvío. Además, el umbral de 3 viene de la normal, y con una asimetría de 8,64 esta distribución está muy lejos de serlo.

Los ceros no quedan marcados por ningún criterio. Su z-score es $-0,98$: con un desvío más grande que la media, un ingreso de cero no llega a estar ni a un desvío por debajo. Y el límite inferior del RIC es negativo, -625.000 , porque el RIC de 650.000 es grande al lado de Q_1 , que es 350.000 : ningún ingreso puede quedar por debajo. En el relevamiento pasaba lo contrario: un RIC de 46.000 contra un Q_1 de 173.500 daba un límite inferior de 104.500 , y el 0 quedaba por debajo.

Las dos listas son de candidatos a revisar, no de errores. Los 962 son el 5,8% de los ocupados con ingreso, y en una variable tan asimétrica es esperable que la cola sea larga. Un ingreso de $30.000.000$ puede ser un error de carga o un ingreso real, y la única forma de saberlo es volver al dato de origen. Lo que no se puede hacer es borrarlos para que la media se parezca a la mediana.

7.11 Ejercicio 10

```
conteo_region = personas["region"].value_counts()
orden_nivel = ["sin instrucción", "primario incompleto", "primario completo",
               "secundario incompleto", "secundario completo",
               "superior o universitario incompleto", "superior o
universitario completo"]
inicio_eje = 0
```

Si el nivel educativo se hubiera ordenado por el código del INDEC, sin instrucción, que tiene el código 7, habría quedado al final, después del superior completo. El gráfico habría puesto a quienes no fueron a la escuela en el lugar más alto de la escala. Un código numérico no es el orden de una variable ordinal, y el orden se toma del significado de las categorías.

De las tres variables, el sectorial solo descarta del todo al **nivel educativo**, porque es ordinal y el disco no tiene un orden que se lea. Las otras dos tienen categorías excluyentes que suman el total, así que el sectorial es posible. Igual conviene el de barras:

- En region hay seis categorías, y cuatro están entre el 10% y el 16% de las personas. En un disco esas cuatro porciones son difíciles de ordenar a ojo; en barras, ordenadas por frecuencia, el orden se ve enseguida.
- En categoria_ocupacional, patrón y trabajador familiar ocupan el 3,59% y el 0,46%. En un disco son dos líneas finas que no se pueden comparar.

7.12 Ejercicio 11

```
bins_histograma = bordes
con_ingreso = ocupados[ocupados["ingreso_ocupacion_principal"] != -9]
mediana_por_nivel = con_ingreso.groupby("nivel_educativo")
["ingreso_ocupacion_principal"].median()
```

El histograma muestra la **forma**: un pico muy marcado en la clase de 40 a 50 horas, la jornada completa, y una caída brusca en la clase siguiente: de 7.256 ocupados en [40, 50) a 1.337 en [50, 60). El boxplot de las horas daría la mediana de 36 y la caja de 24 a 46, pero no mostraría ese pico.

Nivel educativo	Casos	Mediana del ingreso
sin instrucción	36	450.000
primario incompleto	418	350.000
primario completo	1.713	450.000
secundario incompleto	2.686	500.000
secundario completo	5.397	600.000
superior o universitario incompleto	2.541	600.000
superior o universitario completo	3.918	900.000

Desde primario incompleto, la mediana sube o se mantiene con cada nivel, y con el superior completo da el salto más grande: de 600.000 a 900.000. La caja del superior completo es además la más ancha, con un RIC de 850.000.

El grupo del que hay que desconfiar es **sin instrucción**. Su mediana de 450.000 queda por encima de la de primario incompleto, pero tiene 36 casos contra cientos o miles en los demás. Esa mediana es el promedio de los valores 18 y 19, que son 400.000 y 500.000: con una sola persona menos, pasa a 400.000 o a 500.000. Describe a esos 36 encuestados, y no alcanza para decir que los ocupados sin instrucción ganan más que los de primario incompleto: eso ya sería inferencia, que empieza en la unidad 5.

7.13 Ejercicio 12

```
serie_mediana = trimestres["ingreso_mediano"]
serie_medio = trimestres["ingreso_medio"]
veces = serie_mediana.iloc[-1] / serie_mediana.iloc[0]
```

La mediana pasa de 80.000 en el primer trimestre de 2023 a 800.000 en el cuarto de 2025: se multiplica por **10**.

Va un gráfico de líneas porque el eje horizontal es el tiempo, que tiene un orden real y continuo: entre un trimestre y el siguiente el ingreso siguió existiendo, y la línea que los une tiene sentido. Entre dos regiones no hay nada, y por eso el ejercicio 10 va en barras.

La media queda arriba de la mediana en los doce trimestres. Es la asimetría de los ejercicios 5 y 8 repetida en cada base: en todos los trimestres hay ingresos muy altos que arrastran la media.

Lo que sí se puede decir es que la mediana del ingreso declarado, en pesos corrientes, se multiplicó por 10. No se puede decir que los ocupados ganen diez veces más: cada trimestre se encuesta a personas distintas, y los montos están en **pesos corrientes**, y entre 2023 y 2025 los precios también subieron mucho. Para saber si el ingreso real creció o bajó, habría que dividir

cada monto por un índice de precios. El gráfico muestra la evolución del ingreso en pesos, no la del poder de compra.

7.14 Ejercicio 13

```
casos_validos = len(x)
mediana_region = x.median()
ric_region = q3_region - q1_region
```

Para la Patagonia:

Qué	Valor
Casos válidos	1.937 de 2.324
Mínimo y máximo	0 y 20.000.000
Media	1.104.199
Mediana	980.000
Modo	1.000.000
Q ₁ y Q ₃	600.000 y 1.300.000
Desvío standard (n)	968.777
RIC	700.000
Coeficiente de variabilidad	87,74%
Asimetría α_3	6,6752
Kurtosis α_4	102,5934
Atípicos por $1,5 \times \text{RIC}$	117

Un párrafo posible: *el ingreso de la ocupación principal de los 1.937 ocupados encuestados en la Patagonia que declararon su ingreso tiene una mediana de 980.000 pesos y una media de 1.104.199; la diferencia entre las dos y una asimetría de 6,68 indican una distribución estirada hacia los ingresos altos. La mitad central está entre 600.000 y 1.300.000, un recorrido de 700.000. La regla del $1,5 \times \text{RIC}$ deja afuera a 117 ocupados, todos de ingresos altos, hasta un máximo de 20.000.000. Otros 387 ocupados de la región no declararon su ingreso.*

El párrafo da el centro con dos medidas, la dispersión con dos medidas, los extremos y el denominador. Y habla de los **encuestados**: para decir algo sobre todos los ocupados de la Patagonia hace falta el factor de expansión y la inferencia de la unidad 5.