

ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

ESTIMACIÓN

Unidad 6 · Asignatura E8102 — Exploración de datos

Docentes: Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

Asignatura: E8102 — Exploración de datos

Cohorte o comisión: Cohorte 2026




Figura 1. Un número solo no dice cuánto puede equivocarse. Un tramo sí.

1. INTRODUCCIÓN

1.1 Del dato al parámetro

La unidad 5 dejó los 37 hogares convertidos en una muestra de los 4.000, y dejó planteado el problema: el ingreso promedio de los 4.000 existe, vale lo que vale, y nadie lo midió. Lo único que hay es el promedio de los 35 hogares que declararon ingreso, que da 203.471.

La pregunta de esta unidad es qué se puede afirmar con ese número. Hay dos respuestas, y las dos son correctas.

La primera es el número solo: el ingreso promedio de la población se estima en 203.471. Es una respuesta honesta y está incompleta, porque no dice cuánto puede equivocarse.

La segunda agrega el margen: el ingreso promedio de la población está, con un 95% de confianza, entre 173.462 y 233.480. Es más ancha, y es la que declara su margen.

Esta unidad construye la segunda a partir de la primera.

1.2 Lo que se supone

- La unidad 5 completa, sobre todo la distinción entre parámetro y estadístico de su sección 2.2 y la advertencia de su sección 4.4.
- El teorema central del límite y el error standard de la sección 8 de la unidad 3. Todo el intervalo de la media sale de ahí.
- Las distribuciones chi cuadrado y t de Student de las secciones 9.3 y 9.4 de la unidad 3. Acá se las usa por primera vez.
- El cálculo inverso de la sección 6.7 de la unidad 3: dada un área, encontrar el valor. Es la operación que produce el coeficiente del intervalo.
- El divisor $n - 1$ de la sección 4.3 de la unidad 4.
- El tratamiento de los faltantes de la sección 4.1 de la clase 3 del [T8001](#). El n de cada intervalo de esta unidad es el que ese criterio dejó, y se declara en cada cuenta.

1.3 El alcance de esta unidad

Se estiman tres parámetros: la media, la proporción y la varianza de una población. La diferencia de medias y el cociente de varianzas llegan en la unidad 7, con los tests.

Todo supone muestreo aleatorio simple. Las fórmulas de esta unidad se apoyan en que cada elemento tuvo la misma probabilidad de entrar. Un diseño estratificado o por conglomerados cambia el error standard, y esas fórmulas quedan fuera del programa. Sobre el relevamiento, además, ni siquiera hay sorteo: por la razón que da la sección 4.4 de la unidad 5 se lo usa igual, como ejercicio de método y con el supuesto declarado.

No hay demostraciones algebraicas. El teorema central del límite y las distribuciones t y chi cuadrado de la unidad 3 ya están, y de ellos salen las fórmulas sin más álgebra que un despeje.

1.4 Los datos de esta unidad

Los mismos, ahora como muestra de los 4.000 hogares:

Variable	n	Estadístico	Desvío muestral s
Ingreso	35	$\bar{x} = 203.471$	87.360
Personas por hogar	37	$\bar{x} = 3,7838$	2,0968
Hogares sin gas	37	$\hat{p} = 0,5405$	—

Los desvíos de esta tabla usan el divisor $n - 1$, porque ahora los datos son una muestra. Son los de la columna derecha de la tabla de la sección 4.3 de la unidad 4. Y los n son distintos entre filas porque dos hogares no declararon ingreso.

2. PARÁMETRO, ESTADÍSTICO Y ESTIMADOR

2.1 El tercer término

La unidad 5 separó el parámetro del estadístico. Falta uno más.

Un **estimador** es la regla que se usa para aproximar un parámetro a partir de una muestra: "el promedio de los valores observados". Una **estimación** es el número que esa regla devuelve sobre una muestra concreta: 203.471.

El estimador es el mismo para todas las muestras posibles; la estimación cambia con cada una. La distinción importa porque las propiedades de la sección 3 son propiedades del estimador, no de la estimación: no tiene sentido preguntar si 203.471 es insesgado.

2.2 El estadístico tiene su propia distribución

Antes de sacar la muestra, $\bar{x}$ es una variable aleatoria: depende de qué 35 hogares salgan sorteados. Esa variable tiene una distribución, que se llama **distribución en el muestreo**, y de ella se conocen tres cosas:

$E(\bar{x}) = \mu$	centrada en el parámetro
$\sigma(\bar{x}) = \sigma / \sqrt{n}$	el error standard
forma $\approx$ normal	si n es suficientemente grande

Las dos primeras salen de las propiedades de la esperanza y de la varianza de las secciones 4.4 y 5.6 de la unidad 2, y valen para cualquier n , incluso para $n = 2$, siempre que las extracciones sean independientes; la sección 9 trata el caso en que no lo son. La tercera es el teorema central del límite, y solo vale cuando la muestra es suficientemente grande.

Conocer esa distribución es lo que permite decir cuánto suele apartarse $\bar{x}$ de μ . El intervalo de la sección 5 no es más que esa afirmación, escrita al revés.




Figura 2. Cada muestra posible da un número distinto. El conjunto de esos números tiene su propia forma.

3. LAS PROPIEDADES DE UN BUEN ESTIMADOR

3.1 Las tres propiedades

Para un mismo parámetro puede haber varios estimadores. Si la población es simétrica, su media y su mediana coinciden, y tanto la media como la mediana de la muestra sirven para estimar ese centro. Hay que poder decidir, y tres propiedades ordenan la elección.

Un estimador es **insesgado** cuando su esperanza es el parámetro: $E(\text{estimador}) = \text{parámetro}$. No quiere decir que acierte, quiere decir que no se equivoca sistemáticamente para el mismo lado. La media muestral lo es, y eso sale de la primera línea de la sección 2.2, que vale para cualquier tamaño de muestra.

Un estimador es **consistente** cuando, al crecer la muestra, la probabilidad de que se aparte del parámetro más que cualquier distancia fija tiende a cero. Si es insesgado, alcanza con que su error standard tienda a cero. La media muestral lo es, porque $\sigma/\sqrt{n}$ se achica.

Las dos propiedades son distintas. Un estimador puede ser insesgado y poco útil si su error standard es grande: con $n = 10$, y según la simulación de la sección 3.2, el de la media del ingreso vale 27.191 pesos, y un intervalo construido con eso no sirve para decidir nada.

Entre dos estimadores insesgados del mismo parámetro, el más **eficiente** es el de menor varianza: el que se aparta menos, muestra tras muestra.

3.2 El $n - 1$, demostrado

La sección 4.3 de la unidad 4 afirmó que dividir por n subestima la dispersión y que $n - 1$ lo corrige. Acá se lo puede ver, y alcanza con simular.

Se toman los 35 ingresos como si fueran la población, con $\sigma^2 = 7.413.642.041$. Se sacan 200.000 muestras de tamaño 10 con reposición, con el generador de numpy sembrado en 8102, y se calcula la varianza de cada una de las dos maneras:

Cómo se calcula	Promedio de las 200.000 varianzas	Apartamiento de σ^2
Dividiendo por n	6.668.269.862	-10,05%
Dividiendo por $n - 1$	7.409.188.735	-0,06%

El ejemplo usa $n = 10$ porque el sesgo de la versión con divisor n es un factor $(n - 1)/n$, que para 10 predice exactamente -10%. Dividir por $n - 1$ deshace ese factor, y la columna derecha queda en el ruido de la simulación. Si a continuación se sacan, con el mismo generador, 200.000 muestras de $n = 30$, el sesgo da -3,22% contra el -3,33% que predice 29/30. Si se vuelve a sembrar el generador en lugar de continuarlo, el número cambia en la segunda cifra decimal, y esa es la razón de declarar la semilla y el orden.

La misma simulación deja ver las otras dos propiedades. El promedio de las 200.000 medias muestrales da 203.487, contra una media poblacional de 203.471: la media es insesgada. Y el desvío de esas medias baja de 27.191 con $n = 10$ a 15.730 con $n = 30$: es consistente.

La simulación deja además un cuarto número, que no está en la tabla. El desvío de las 200.000 medianas muestrales es 12.793, contra 27.191 de las medias. Sobre esta población la mediana es más estable, y eso no la hace más eficiente: las dos estiman parámetros distintos, la media poblacional y la mediana poblacional, y la eficiencia solo compara estimadores del mismo parámetro. La ventaja de la media se afirma para poblaciones normales, y esta población tiene una asimetría de 2,87.




Figura 3. Las dos varas difieren en dónde arrancan y en el tramo añadido. Medir desde el centro de los propios datos deja corta la primera.

4. LA ESTIMACIÓN PUNTUAL

La **estimación puntual** es un solo número: el valor del estimador sobre la muestra observada.

Parámetro	Estimador	Estimación
μ del ingreso	$\bar{x}$	203.471
μ de personas por hogar	$\bar{x}$	3,7838
p de hogares sin gas	$\hat{p}$	0,5405
σ del ingreso	s	87.360

Tiene una virtud y un problema.

La virtud es que es lo que se necesita para decidir: un presupuesto se arma con un número, no con un tramo.

El problema es que **la probabilidad de que acierte exactamente es prácticamente nula**. El ingreso promedio de los 4.000 hogares no vale 203.471 exactamente, y una estimación puntual no ofrece ninguna forma de saber si está cerca o lejos. Presentada sola, sugiere una precisión que no tiene.

Por eso se informa siempre acompañada, y eso es el resto de la unidad.

5. EL INTERVALO DE CONFIANZA

5.1 La idea

Un **intervalo de confianza** es un tramo construido a partir de la muestra, con un procedimiento que acierta una proporción conocida de las veces.

Se arma con tres piezas, y siempre las mismas:

$$\text{estimación puntual} \pm \text{coeficiente} \times \text{error standard}$$

- La **estimación puntual** pone el centro.
- El **error standard** dice cuánto suele apartarse el estadístico del parámetro. Es el $\sigma/\sqrt{n}$ de la unidad 3, con σ estimado por s cuando no se lo conoce.
- El **coeficiente** dice cuántos errores standard hay que abarcar para cubrir la confianza pedida. Sale del cálculo inverso de la sección 6.7 de la unidad 3.

Al producto coeficiente $\times$ error standard se lo llama **error máximo admisible**, o margen de error, y se anota e . El intervalo es entonces estimación $\pm e$, y su ancho total es $2e$.

Falta una letra. El **nivel de confianza** se escribe $1 - \alpha$, así que α es la parte que queda afuera: con un 95% de confianza, $\alpha = 0,05$, y esa parte se reparte entre las dos puntas, $\alpha/2 = 0,025$ en cada una.




Figura 4. La marca pone el centro, el segmento suelto pone la unidad, y cuántas copias hay pone el alcance.

5.2 Qué significa el 95%

Este es el malentendido más común de esta unidad.

El intervalo del ingreso es $[173.462 ; 233.480]$. La lectura incorrecta es: "hay un 95% de probabilidad de que el ingreso promedio de los 4.000 hogares esté entre esos dos números".

Es incorrecta porque el ingreso promedio de los 4.000 hogares es un número fijo. O está adentro de ese tramo o no está; no hay nada aleatorio en él. Lo aleatorio fue la muestra, y con ella el intervalo.

El 95% describe al procedimiento, no al parámetro. Si se repitiera el muestreo muchas veces y se construyera el intervalo de la misma forma cada vez, el 95% de esos intervalos contendría al parámetro. El intervalo concreto que salió, o acierta o no, y no se puede saber cuál de las dos.

Si se sortean veinte muestras y se arma el intervalo de cada una, aparecen veinte tramos distintos, todos de ancho parecido y centrados en lugares distintos. Uno de esos veinte, en promedio, no toca el valor verdadero. Eso no exige que en cada tanda fallen exactamente uno: podrían fallar ninguno, dos o más. La ilustración muestra una tanda con una falla para hacer visible la cobertura; no es una regla sobre cada grupo de veinte intervalos.




Figura 5. El 95% describe al procedimiento que produce los tramos. No describe al punto donde está la línea.

5.3 Qué mueve el ancho

Tres cosas.

La confianza. Más confianza, más ancho. Para estar más seguro de no errar hay que abarcar más.

La dispersión. Más variabilidad en la población, más ancho. No hay forma de evitarlo: si los datos varían mucho, la estimación es menos precisa.

El tamaño de la muestra. Más casos, menos ancho: para partir el ancho al medio hay que cuadruplicar la muestra.

De las tres, la única que suele estar bajo control es la tercera.

6. EL INTERVALO PARA LA MEDIA

6.1 Con σ conocido

Es el caso de manual, y casi nunca ocurre: se supone que el desvío de la población se conoce aunque la media no.

$$\bar{x} \pm z \times \sigma / \sqrt{n}$$

El coeficiente z sale de la normal standard. Los tres que se usan siempre:

Confianza	α	z
90%	0,10	1,645
95%	0,05	1,960
99%	0,01	2,576

El 1,96 del 95% es la versión exacta del 2 de la regla de la sección 6.4 de la unidad 3. Ahí el $\mu \pm 2\sigma$ cubría el 95,45%; acá, para cubrir exactamente el 95%, el coeficiente es un poco menor.

6.2 Con σ estimado: la t

El caso real. Si σ no se conoce se lo estima con s , y eso agrega incertidumbre que la normal no contempla:

$$\bar{x} \pm t \times s / \sqrt{n} \quad \text{con } n - 1 \text{ grados de libertad}$$

Lo único que cambia es de dónde sale el coeficiente. La t es más ancha en las colas, así que su coeficiente es siempre mayor que el de la normal, y el intervalo sale más largo. Con muchos grados de libertad los dos coinciden.

Y el supuesto que hay que declarar: la t exige que la población sea aproximadamente normal, o que la muestra sea grande. Con $n = 35$ y una población con asimetría 2,87, como la del ingreso, el teorema central del límite alcanza para que el intervalo sirva como aproximación, y no para tratarlo como un número exacto. La sección 8.6 de la unidad 3 mide cuánto falta: con esta misma población, $n = 30$ deja una asimetría de 0,52 en la media muestral.

6.3 El ingreso del relevamiento

Con $n = 35$, $\bar{x} = 203.471$ y $s = 87.360$:

$$\text{error standard} = s / \sqrt{n} = 87.360 / \sqrt{35} = 14.766$$

$$t(0,975 ; 34 \text{ grados de libertad}) = 2,0322$$

$$e = 2,0322 \times 14.766 \approx 30.009$$

$$\text{IC } 95\% = 203.471 \pm 30.009 = [173.462 ; 233.480]$$

Se lee: **el procedimiento estima el ingreso promedio de los 4.000 hogares en 203.471, con un margen de 30.009 pesos al 95% de confianza.** Con eso queda contestada la primera de las tres preguntas de la sección 1.1 de la unidad 1: el ingreso promedio de 35 hogares sí dice algo del de los 4.000, y lo que dice es este tramo.

El margen es lo que el número solo escondía: ± 30.009 pesos sobre una estimación de 203.471, casi un 15% para cada lado. Con 35 hogares no se puede pedir más precisión.

Y las personas por hogar, con $n = 37$, $\bar{x} = 3,7838$ y $s = 2,0968$:

$$\text{error standard} = 2,0968 / \sqrt{37} = 0,3447$$

$$t(0,975 ; 36) = 2,0281$$

$$e = 0,6991$$

$$\text{IC } 95\% = 3,7838 \pm 0,6991 = [3,0847 ; 4,4829]$$

Con un 95% de confianza, entre 3,08 y 4,48 personas por hogar.

6.4 Las tres confianzas, sobre los mismos datos

Para ver qué cuesta cada nivel de confianza, el mismo ingreso con tres coeficientes:

Confianza	t	e	Intervalo	Ancho
90%	1,6909	24.969	[178.502 ; 228.440]	49.938
95%	2,0322	30.009	[173.462 ; 233.480]	60.018
99%	2,7284	40.289	[163.183 ; 243.760]	80.577

Pasar del 90% al 99% agrega nueve puntos de confianza y alarga el intervalo un 61%. Ese es el canje, y no hay manera de evitarlo con los mismos datos: la única forma de ganar confianza sin perder precisión es agrandar la muestra.

El 95% es una convención que se difundió desde los trabajos de [Ronald Fisher](#) en los años veinte, no un resultado. En contextos donde equivocarse es caro —un ensayo clínico, un control de seguridad— se piden niveles más altos.




Figura 6. El centro es el mismo en los tres. Lo único que se compra con más confianza es más ancho.

7. EL INTERVALO PARA LA PROPORCIÓN

Una proporción es el caso particular de una media sobre una variable que vale 0 o 1, así que la distribución en el muestreo tiene la misma estructura que la de la sección 2.2:

$$E(\hat{p}) = p$$

$$\sigma(\hat{p}) = \sqrt{[p (1 - p) / n]}$$

forma $\approx$ normal, si $n p$ y $n (1 - p)$ son suficientemente grandes

Y de ahí sale el intervalo:

$$\hat{p} \pm z \times \sqrt{[\hat{p} (1 - \hat{p}) / n]}$$

Dos diferencias con la media. El error standard se calcula con la propia estimación $\hat{p}$, porque en una variable de dos valores la dispersión queda determinada por la proporción: es la varianza $p \times q$ de la binomial de la sección 3.6 de la unidad 3. Y el coeficiente sale de la normal, no de la t , porque no hay un σ aparte que estimar.

La condición para usarlo viene de la aproximación normal a la binomial. La sección 7.4 de la unidad 3 pide $n \geq 30$ y $0,1 \leq p \leq 0,9$, y la sección 7.6 de esa unidad avisa que otros manuales usan $n \hat{p} \geq 5$ y $n (1 - \hat{p}) \geq 5$, que es la regla de esta unidad y de la unidad 7.

Sobre los hogares sin gas, que son 20 de 37:

$$\hat{p} = 20/37 = 0,5405$$

$$n \hat{p} = 20 \quad n (1 - \hat{p}) = 17 \quad \text{las dos condiciones se cumplen}$$

$$\text{error standard} = \sqrt{(0,5405 \times 0,4595 / 37)} = 0,0819$$

$$e = 1,96 \times 0,0819 \approx 0,1606$$

$$\text{IC } 95\% = 0,5405 \pm 0,1606 = [0,3800 ; 0,7011]$$

Con un 95% de confianza, entre el 38,0% y el 70,1% de los hogares de las tres localidades no tiene gas.

Con 37 casos, el margen es de 16 puntos porcentuales para cada lado. La unidad 1 preguntaba en su sección 1.1 cuánto puede equivocarse ese 54%: es compatible con un 40% y con un 70%, que son dos situaciones distintas para cualquier decisión de infraestructura.

Ese ancho tiene una consecuencia práctica: para estimar una proporción con precisión razonable hacen falta cientos de casos, no decenas. La sección 10 dice cuántos.

Y una reserva de método. La fórmula de arriba es una aproximación aun cuando se cumplen sus condiciones, y con pocos casos cubre algo menos de lo que declara. La regla $n \hat{p} \geq 5$ es la más permisiva de las que circulan, y varios textos actuales piden 10. Existen versiones más precisas para muestras chicas, que quedan fuera del programa.

8. EL INTERVALO PARA LA VARIANZA

La media y la proporción usan distribuciones simétricas, así que sus intervalos son simétricos. El de la varianza no lo es, y la razón es la de la sección 9.3 de la unidad 3: la varianza nunca es negativa y, si la población es normal, $(n - 1) s^2 / \sigma^2$ sigue una chi cuadrado, que está estirada a la derecha.

Se despeja esa expresión, con $n - 1$ grados de libertad:

$$\frac{(n - 1) s^2}{\chi^2(1 - \alpha/2)} \leq \sigma^2 \leq \frac{(n - 1) s^2}{\chi^2(\alpha/2)}$$

Los denominadores están cruzados: el cuantil grande produce el extremo chico del intervalo. Es la consecuencia de que σ^2 esté en el denominador de la expresión original.

Sobre el ingreso, con $n = 35$ y $s = 87.360$:

$$\chi^2(0,975 ; 34) = 51,9660 \quad \chi^2(0,025 ; 34) = 19,8063$$

$$\text{IC 95\% para } \sigma, \text{ raíz del de } \sigma^2 = [70.663 ; 114.459]$$

Con un 95% de confianza, el desvío del ingreso de los 4.000 hogares está entre 70.663 y 114.459 pesos. Y el intervalo no es simétrico alrededor de 87.360: se extiende 16.697 hacia abajo y 27.099 hacia arriba.

Una advertencia que importa más acá que en los otros dos casos. El supuesto de normalidad no se relaja con n grande, a diferencia de lo que pasa con la media. Sobre el ingreso, que tiene una asimetría de 2,87, este intervalo es poco confiable, y se lo muestra como ejercicio de método.

9. LA CORRECCIÓN POR POBLACIÓN FINITA

Todas las fórmulas anteriores suponen muestreo con reposición, o una población infinita. Cuando la muestra es una parte apreciable de la población, el error standard es menor que el que dan esas fórmulas, y hay un factor que lo corrige:

$$\text{error standard corregido} = (s / \sqrt{n}) \times \sqrt{[(N - n) / (N - 1)]}$$

Observar sin reposición una parte grande de la población deja menos por descubrir. En el extremo, con $n = N$ el factor vale 0 y el intervalo se cierra en un punto, que es lo correcto: un censo no tiene error de muestreo.

Sobre el ingreso, con $n = 35$ y $N = 4.000$:

$$\sqrt{[(4.000 - 35) / 3.999]} = 0,9957$$

$$\text{error standard corregido} = 14.766 \times 0,9957 \approx 14.704$$

Una reducción del 0,43%, que no cambia ninguna conclusión. Y esa es la razón de que casi nunca se aplique: con $n/N = 35/4.000 = 0,0088$, la corrección es despreciable. La regla práctica es la de la sección 7.2 de la unidad 3: si $n/N \leq 0,05$, se ignora.

Cuándo sí importa: si se encuestaran 1.000 de los 4.000 hogares, el factor valdría $\sqrt{(3.000/3.999)} = 0,866$, y el intervalo se angostaría un 13%.




Figura 7. Cuando lo observado se acerca al total, deja de haber algo que estimar y el tramo se cierra.

10. EL TAMAÑO DE MUESTRA

10.1 La pregunta al revés

Hasta acá la muestra estaba dada y el margen salía de ella. En un proyecto real es al revés: se fija el margen que se necesita y se pregunta cuántos casos hacen falta.

Se despeja n de la fórmula del error. Para una proporción:

$$n = z^2 \times p (1 - p) / e^2$$

Tres decisiones antes de poder usarla.

El margen e . Lo fija el uso: para decidir entre dos proveedores alcanza un margen grande; para proyectar una obra, no.

La confianza. Casi siempre 95%, así que $z = 1,96$. Acá el coeficiente sale de la normal. También para una media, sección 10.3, aunque el intervalo después use la t : el tamaño se calcula antes de salir al campo, cuando todavía no hay grados de libertad que contar.

La proporción p . Es el problema, porque es lo que se quiere estimar. La salida es usar el peor caso: $p = 0,5$ es el valor que hace máximo el producto $p(1-p)$, así que produce el n más grande y garantiza el margen sea cual sea la proporción real.

10.2 Los números que explican las encuestas

Con $p = 0,5$ y 95% de confianza:

Margen	n
$\pm 5\%$	385
$\pm 3\%$	1.068
$\pm 2\%$	2.401

Es el orden de los 1.000 o 1.500 casos que la sección 8.4 de la unidad 3 atribuyó a las encuestas nacionales: con 1.068 casos el margen es de 3 puntos, y el tamaño de la población no aparece en la fórmula. Bajar el margen de 3 a 2 puntos cuesta más del doble de casos.

Si además se aplica la corrección de la sección 9, el n se ajusta hacia abajo:

$$n = n_0 / [1 + (n_0 - 1) / N]$$

Para los 4.000 hogares y un margen de 5 puntos, los 385 bajan a 352. Con poblaciones grandes el ajuste es despreciable; con 4.000 hogares, en cambio, ahorra 33 casos sobre 385, un 9%.




Figura 8. El margen baja con la raíz del tamaño: la mitad de margen cuesta cuatro veces más casos.

10.3 Para una media

La misma cuenta, con el error standard de la media:

$$n = (z \times \sigma / e)^2$$

Y la misma dificultad, agravada: hace falta σ , que tampoco se conoce. Se lo estima con un estudio piloto, con un relevamiento anterior o con el recorrido dividido por cuatro.

Sobre el ingreso, usando el $s = 87.360$ del relevamiento como estimación previa:

Margen	n
±30.000	33
±20.000	74
±10.000	294

Los 35 hogares que hay alcanzan para un margen de unos 30.000 pesos, y apretar ese margen a la tercera parte exige casi nueve veces más casos. Es el $\sqrt{n}$ otra vez, desde el otro lado.

El tamaño de muestra se calcula antes de salir al campo, no después. Calcularlo al final sirve para explicar por qué el margen salió como salió, y ya no se puede cambiar nada.

11. NUEVE ERRORES FRECUENTES

- 1. Leer el 95% como una probabilidad sobre el parámetro.** El parámetro es un número fijo. El 95% es la proporción de intervalos que aciertan, sobre repeticiones del procedimiento.
- 2. Informar la estimación puntual sola.** 203.471 sin el margen de 30.009 sugiere una precisión que no existe.
- 3. Usar la normal en lugar de la t con σ estimado.** Con 34 grados de libertad la diferencia es chica, 2,0322 contra 1,96; con 5 grados de libertad es 2,5706 contra 1,96, y el intervalo sale bastante más angosto que lo que corresponde.
- 4. Calcular el tamaño de muestra en proporción a la población.** El N no aparece en la fórmula, salvo por la corrección de la sección 9, que sobre 4.000 hogares descuenta un 9%. Con 4 millones de hogares harían falta 385 casos; con 4.000, aplicando la corrección, 352.
- 5. Confundir el error standard con el margen de error.** El error standard es $s/\sqrt{n}$; el margen es el error standard multiplicado por el coeficiente. Para el ingreso, 14.766 y 30.009.
- 6. Aplicar el intervalo de la varianza sin mirar la normalidad.** Ese supuesto no se arregla con n grande.
- 7. Olvidar que la fórmula supone muestreo aleatorio simple.** Sobre una muestra por conveniencia el intervalo se calcula igual y no significa lo mismo. Es la sección 4.4 de la unidad 5.
- 8. Creer que un intervalo angosto es un intervalo correcto.** Un marco sesgado produce intervalos angostos alrededor del número equivocado, como en el caso del *Literary Digest* de la sección 4.2 de la unidad 5.
- 9. No informar el nivel de confianza.** Un intervalo sin su nivel no se puede interpretar.