

ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

TEST DE HIPÓTESIS

Unidad 7 · Asignatura E8102 — Exploración de datos

Docentes: Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

Asignatura: E8102 — Exploración de datos

Cohorte o comisión: Cohorte 2026




Figura 1. Se supone algo, se mira el dato y se pregunta cuán raro sería ese dato si la suposición fuera cierta.

1. INTRODUCCIÓN

1.1 De estimar a decidir

La unidad 6 contestó "¿cuánto vale el parámetro?" con un tramo. Esta unidad contesta otra pregunta, que en un proyecto aparece más seguido: "¿el dato es compatible con este valor?".

Son distintas y se confunden. Una constructora afirma que el ingreso promedio de la zona es de 180.000 pesos. El relevamiento dio 203.471. La diferencia es de 23.471 pesos, y hay dos explicaciones posibles: o el ingreso promedio real es mayor que 180.000, o es 180.000 y esta muestra de 35 hogares salió alta por azar.

El **test de hipótesis** es el procedimiento que decide entre esas dos explicaciones, y lo hace de una forma muy particular: calculando cuán raro sería el dato observado si la segunda explicación fuera la correcta.

1.2 Lo que se supone

- La unidad 6 completa. El test y el intervalo son la misma cuenta mirada de dos maneras.
- La distribución en el muestreo de la sección 2.2 de la unidad 6 y el error standard de la sección 8.3 de la unidad 3.
- Las tres distribuciones de la inferencia de la sección 9 de la unidad 3, que son la chi cuadrado, la t de Student y la F, más la normal standard de su sección 6.5. Los cinco tests de esta unidad usan esas cuatro distribuciones, y la tabla de la sección 9.6 de esa unidad las relaciona.
- La advertencia de la sección 4.4 de la unidad 5. Todo lo que sigue se calcula sobre una muestra que no fue aleatoria, y eso se declara.

1.3 El alcance de esta unidad

Cinco tests, y todos paramétricos. Media, proporción, varianza, cociente de varianzas y diferencia de medias. Los tests que no suponen una distribución son la unidad 9.

Dos muestras como mucho. Comparar tres o más grupos a la vez es análisis de varianza, que no está en el programa en su versión paramétrica. La versión de rangos sí está, y es el test de Kruskal-Wallis de la sección 5 de la unidad 9.

Nada de esto decide por vos. Un test devuelve un número y una conclusión estadística. Qué hacer con eso es una decisión que depende del costo de equivocarse.

1.4 Los datos de esta unidad

Los mismos del bloque, con una apertura nueva: el ingreso separado por localidad, que es lo que permite los dos tests de comparación.

Grupo	n	$\bar{x}$	s
Ingreso, los 35	35	203.471	87.360
Ramallo	14	215.643	119.670
Córdoba	11	181.500	76.294
Concepción	10	210.600	28.297

Los tres tamaños suman 35 porque $14 + 11 + 10$ son los hogares con ingreso declarado. Las localidades tienen 15, 11 y 11 hogares, y los dos que faltan son los que no declararon el dato.

2. QUÉ ES UN TEST DE HIPÓTESIS

2.1 Las dos hipótesis

Un test enfrenta dos afirmaciones sobre un parámetro.

La **hipótesis nula**, H_0 , es la que se pone a prueba. Es la posición de partida, la que se mantiene mientras no haya evidencia suficiente para abandonarla.

La **hipótesis alternativa**, H_1 , es lo que se sostiene si H_0 cae. Suele ser lo que quien hace el estudio quiere mostrar.

Para el ejemplo de la constructora:

$H_0 : \mu = 180.000$	el ingreso promedio de la población es 180.000
$H_1 : \mu \neq 180.000$	no lo es

Dos reglas de construcción.

El valor de frontera va siempre en H_0 . Muchos textos escriben la nula de un test unilateral como $H_0 : \mu \leq 180.000$, y es correcto: lo que importa es que haya un valor concreto con el que calcular, y ese valor es el borde, 180.000. Este apunte escribe la igualdad, que es la forma más corta de decir lo mismo.

Las dos hipótesis se escriben antes de mirar el resultado. Elegirlas después de ver los datos invalida el test, porque el valor p deja de significar lo que dice significar.

2.2 Por qué la carga de la prueba es asimétrica

Un test no trata a las dos hipótesis por igual. H_0 se sostiene por defecto, y solo se la abandona si los datos son bastante incompatibles con ella. No es una comparación suelta: es la misma asimetría que en un juicio, donde se presume la inocencia y la absolución no prueba la inocencia, sino que no alcanzó la prueba.

De ahí sale la consecuencia en la que más se equivoca quien informa: **no rechazar H_0 no es aceptarla**. Puede ser que sea cierta, y puede ser que la muestra sea demasiado chica para detectar que es falsa. Las dos cosas producen el mismo resultado, y el test no las distingue. Lo que sí las distingue es la potencia de la sección 4.3.

No hay una tercera conclusión disponible. El test tiene una sola salida, rechazar, y su ausencia. Por eso las conclusiones se redactan siempre en la misma forma: "los datos no aportan evidencia suficiente para rechazar que el ingreso promedio sea 180.000", y nunca "el ingreso promedio es 180.000".




Figura 2. Un resultado tiene salida y el otro no tiene ninguna. No hay un segundo extremo del que salga la conclusión contraria.

2.3 El mecanismo

Todos los tests de esta unidad hacen lo mismo, en cinco pasos:

1. Se escriben H_0 y H_1 , y se fija el nivel de significación α .
2. Se supone que H_0 es cierta. Todo lo que sigue vive dentro de ese supuesto.
3. Se calcula un estadístico de prueba, que mide a cuánta distancia quedó lo observado del valor que H_0 afirma.
4. Se ubica ese estadístico en su distribución, que se conoce porque se supuso H_0 .
5. Se decide. Si el estadístico cae en una zona que sería rara bajo H_0 , se la rechaza.

En los tests de la media, de la proporción y de la diferencia de medias, el paso 3 tiene la misma forma:

$$\text{estadístico} = (\text{lo observado} - \text{lo que afirma } H_0) / \text{error standard}$$

Los tests de la varianza y del cociente de varianzas usan un cociente. Lo que cambia entre un test y otro es qué se observa, qué afirma H_0 y qué distribución sigue el resultado.

2.4 Una cola o dos

La forma de H_1 decide dónde está la zona de rechazo.

Un test es **bilateral** cuando H_1 dice "distinto de". Apartarse para cualquiera de los dos lados cuenta como evidencia, así que la zona de rechazo se reparte en las dos colas, $\alpha/2$ en cada una.

Un test es **unilateral** cuando H_1 dice "mayor que" o "menor que". Toda la zona de rechazo va en una sola cola, y por eso el test unilateral detecta más fácil una diferencia en la dirección esperada.

Y de ahí la regla que lo mantiene honesto: **la dirección se elige antes de ver los datos, y por una razón del problema**. Elegir un test unilateral después de ver para qué lado salió la diferencia es duplicar la probabilidad de error de tipo I sin decirlo.

Sobre el ejemplo de la constructora, la diferencia se ve en el resultado. El test bilateral de la sección 5 da un valor p de 0,1212; el unilateral, con $H_1 : \mu > 180.000$, da exactamente la mitad, 0,0606. Con $\alpha = 0,05$ los dos llevan a la misma conclusión, y el segundo queda muy cerca del límite.




Figura 3. La misma área total de rechazo, repartida de dos maneras. Concentrarla en un lado exige menos distancia para rechazar.

3. EL VALOR P

3.1 Qué es

El **valor p** es la probabilidad de obtener un resultado tan alejado como el observado, o más, si H_0 fuera cierta.

Las últimas cuatro palabras son la definición entera. El valor p se calcula adentro del mundo donde H_0 vale; es un área bajo la distribución del paso 4 del mecanismo, la que queda más allá del estadístico observado.

Un valor p chico dice que lo observado sería raro bajo H_0 . Eso deja dos posibilidades: o H_0 es falsa, o es cierta y ocurrió algo poco probable. El test se queda con la primera y acepta equivocarse una proporción α de las veces en que H_0 es cierta.




Figura 4. El tallo hueco es la altura donde cayó el dato, y no es lo que se mide. Lo que se mide es el área llena que queda de ahí para afuera.

3.2 El nivel de significación

El **nivel de significación**, α , es el umbral que se fija antes de calcular: cuán raro tiene que ser el resultado para abandonar H_0 . Es el mismo α de la unidad 6, la parte que queda afuera del nivel de confianza, y la convención es 0,05.

La regla de decisión es directa:

$$\begin{array}{ll} p \leq \alpha & \rightarrow \text{se rechaza } H_0 \\ p > \alpha & \rightarrow \text{no se rechaza } H_0 \end{array}$$

Fijar α antes es lo que hace honesta a la decisión. Mirar el valor p y después elegir el umbral que da el resultado deseado es lo que el T8001 llama "elegir el resultado". Y cada test tiene su propio

α : si se corren muchos sobre hipótesis nulas ciertas, crece la probabilidad de que alguno rechace. Con veinte tests al 5% es 0,64.

3.3 Cuatro cosas que el valor p no es

Son confusiones frecuentes. En 2016 la American Statistical Association publicó una declaración sobre el valor p que trata varias de ellas.

No es la probabilidad de que H_0 sea cierta. Se calcula suponiendo que lo es, así que no puede medir eso. En el marco de esta unidad, H_0 es una afirmación sobre un parámetro fijo y no tiene probabilidad.

No es la probabilidad de que esta decisión esté equivocada. Tampoco lo es α : α es la probabilidad de rechazar H_0 cuando H_0 es cierta, fijada de antemano y sobre repeticiones del procedimiento. Con los elementos de esta unidad, la probabilidad de que esta decisión concreta sea un error no se puede calcular.

No mide el tamaño del efecto. Un valor p de 0,001 no dice que la diferencia sea grande: dice que sería poco probable si H_0 fuera cierta. Con una muestra grande, una diferencia irrelevante da un valor p minúsculo.

Un valor p alto no confirma H_0 . Es la carga asimétrica de la prueba de la sección 2.2.

Un valor p siempre se informa junto con la estimación y su intervalo. El valor p dice si la diferencia se distingue del azar; el intervalo dice de qué tamaño es. Las dos cosas hacen falta, y el número que sirve para decidir es casi siempre el segundo.

4. LOS DOS ERRORES Y LA POTENCIA

4.1 Los dos errores

Se decide sobre una realidad desconocida, así que hay dos formas de equivocarse:

	H_0 es cierta	H_0 es falsa
Se rechaza H_0	Error de tipo I, probabilidad α	decisión correcta, probabilidad $1 - \beta$
No se rechaza H_0	decisión correcta, probabilidad $1 - \alpha$	Error de tipo II, probabilidad β

El **error de tipo I** es rechazar una H_0 cierta: declarar una diferencia que no existe. Es un falso positivo, y su probabilidad es el α que se fijó, si se cumplen los supuestos del test.

El **error de tipo II** es no rechazar una H_0 falsa: no detectar una diferencia que sí existe. Es un falso negativo, y su probabilidad β no se fija: depende del tamaño de la muestra, de la variabilidad y de cuán grande sea la diferencia real.

El ejemplo que ordena los nombres es un control de calidad. H_0 es que el lote está bien. El error de tipo I descarta un lote bueno y cuesta producción. El error de tipo II deja pasar un lote defectuoso y cuesta clientes. Cuál de los dos es más caro depende del problema, y esa es la decisión que fija α .

La distinción y estos nombres son de [Jerzy Neyman](#) y Egon Pearson, que armaron este marco de decisión a fines de los años veinte.

4.2 El canje

Los dos errores se mueven en direcciones opuestas. Bajar α —exigir más evidencia para rechazar— hace más difícil el falso positivo y más fácil el falso negativo. Subirlo hace lo contrario.

Con la muestra fija no se pueden bajar los dos a la vez. Lo que baja los dos juntos es achicar el error standard: agrandar la muestra o aparear, como en la sección 9.6. Eso angosta la distribución del estadístico y separa mejor las dos situaciones.




Figura 5. Lo único que cambia entre los dos paneles es dónde está el corte. Una zona de error se achica y la otra se agranda.

4.3 La potencia

La **potencia** de un test es $1 - \beta$: la probabilidad de rechazar H_0 cuando efectivamente es falsa. Es la capacidad de detectar una diferencia que existe.

Depende de cuatro cosas: el tamaño de la muestra, la variabilidad de la población, el α elegido, y cuán lejos está la realidad de lo que afirma H_0 . La última es la que se olvida: una diferencia grande es fácil de detectar y una chica no, con la misma muestra.

Los números del ejemplo de la constructora lo muestran. El test bilateral con $\alpha = 0,05$ sobre los 35 hogares rechaza $H_0 : \mu = 180.000$ cuando la media muestral cae fuera de $[149.991 ; 210.009]$. Con la aproximación normal para la media muestral, si la media real de la población fuera:

Media real	Potencia	β
200.000	0,2493	0,7507
220.000	0,7507	0,2493
240.000	0,9789	0,0211

Si el ingreso promedio real fuera 200.000, veinte mil pesos por encima de lo que afirma H_0 , este test lo detectaría una de cada cuatro veces. Con 35 hogares y un desvío de 87.360, una diferencia de ese tamaño es muy difícil de detectar.

La variante unilateral rechaza cuando la media supera 204.969, y contra esa misma diferencia de 20.000 pesos tiene una potencia de 0,3682: concentrar la zona de rechazo en un solo lado detecta más.




Figura 6. De arriba hacia abajo, la distribución se desplaza hacia la derecha y aumenta el área sombreada: la potencia. El sombreado siempre empieza en el mismo corte y ocupa la región de rechazo a su derecha.

4.4 Significativo no quiere decir importante

"Estadísticamente significativo" significa una cosa muy acotada: el resultado sería poco probable si H_0 fuera cierta. No significa grande, ni relevante, ni útil.

La confusión va en las dos direcciones.

Significativo y chico. Con decenas de millones de casos por zona, una diferencia de 50 pesos en el ingreso promedio entre dos zonas puede dar un valor p de 0,001. Es real y no sirve para decidir nada.

No significativo y grande. El relevamiento da 215.643 en Ramallo contra 181.500 en Córdoba: una diferencia de 34.143 pesos, que es mucha plata para cualquier decisión. El test de la sección 9 no la declara significativa, y eso no dice que la diferencia no exista: dice que con 14 y 11 hogares el error standard de esa diferencia es de 41.531 pesos, más grande que la diferencia misma.




Figura 7. La separación chica alcanza para distinguir y la grande no. Lo que decide no es la distancia sino el ancho.

5. TEST PARA LA MEDIA

Pone a prueba un valor de μ . El estadístico es el de la sección 2.3, con el error standard de la media, y sigue una t de Student con $n - 1$ grados de libertad:

$$t = (\bar{x} - \mu_0) / (s / \sqrt{n})$$

Supone población aproximadamente normal, o muestra grande. Si σ fuera conocido, el mismo estadístico con σ en lugar de s sigue una normal standard.

El ejemplo de la constructora, con los 35 ingresos:

$$H_0 : \mu = 180.000 \quad H_1 : \mu \neq 180.000 \quad \alpha = 0,05$$

$$t = (203.471 - 180.000) / 14.766 = 1,5895$$

$$\text{grados de libertad} = 34$$

$$\text{valor crítico} = \pm 2,0322$$

$$p = 0,1212$$

1,5895 no llega a 2,0322, y 0,1212 es mayor que 0,05. **No se rechaza H_0 .**

La conclusión, redactada como corresponde: los datos no aportan evidencia suficiente para rechazar que el ingreso promedio de la población sea 180.000. La diferencia observada de 23.471 pesos es compatible con el azar de una muestra de 35 hogares.

Y la advertencia de la sección 4.3, que es parte de la conclusión y no una nota al pie: con esta muestra, el test no habría detectado una diferencia real de 20.000 pesos tres de cada cuatro veces.

6. TEST PARA LA PROPORCIÓN

Pone a prueba un valor de p . El estadístico sigue aproximadamente una normal standard, y el error standard se calcula con la proporción que afirma H_0 , no con la observada:

$$z = (\hat{p} - p_0) / \sqrt{ [p_0 (1 - p_0) / n] }$$

El denominador es la diferencia con el intervalo de la sección 7 de la unidad 6. Ahí el error standard se calculaba con $\hat{p}$, porque no había ninguna afirmación de referencia. Acá hay una, y todo se calcula suponiéndola cierta.

Las condiciones son las de la aproximación normal: $n p_0 \geq 5$ y $n (1 - p_0) \geq 5$.

Sobre los hogares sin gas, contra la afirmación de que son la mitad:

$$H_0 : p = 0,5 \quad H_1 : p \neq 0,5 \quad \alpha = 0,05$$

$$\hat{p} = 20/37 = 0,5405$$

$$n p_0 = 18,5 \quad n (1 - p_0) = 18,5 \quad \text{las condiciones se cumplen}$$

$$z = (20/37 - 0,5) / \sqrt{ (0,25 / 37) } = 0,4932$$

$$p = 0,6219$$

No se rechaza H_0 . Los 20 hogares sin gas de 37 son perfectamente compatibles con una población en la que la mitad no tiene gas.

7. TEST PARA LA VARIANZA

Pone a prueba un valor de σ . El estadístico es el de la sección 9.3 de la unidad 3, y sigue una chi cuadrado con $n - 1$ grados de libertad:

$$\chi^2 = (n - 1) s^2 / \sigma_0^2$$

Exige que la población sea normal, y ese supuesto no se relaja con n grande.

Contra la afirmación de que el desvío del ingreso es de 60.000 pesos:

$$H_0 : \sigma = 60.000 \quad H_1 : \sigma \neq 60.000 \quad \alpha = 0,05$$

$$\chi^2 = 34 \times 87.360^2 / 60.000^2 = 72,0771$$

valores críticos = 19,8063 y 51,9660

$$p = 0,0003$$

72,0771 supera ampliamente a 51,9660. **Se rechaza H_0** . El ingreso de la población varía bastante más de lo que afirma la hipótesis.

Es el único de los cinco tests de esta unidad que rechaza. No es que la diferencia sea más real que las otras: es que 87.360 contra 60.000 es una diferencia grande respecto de la precisión disponible, mientras que 203.471 contra 180.000 no lo es. Es la potencia de la sección 4.3, funcionando a favor.

Con una reserva: el ingreso del relevamiento tiene una asimetría de 2,87, así que el supuesto de normalidad no se cumple y el resultado hay que leerlo con cuidado.

8. TEST PARA EL COCIENTE DE VARIANZAS

Compara la variabilidad de dos poblaciones. El estadístico es el cociente de las dos varianzas muestrales, y sigue una F con $n_1 - 1$ y $n_2 - 1$ grados de libertad:

$$F = s_1^2 / s_2^2$$

Es la distribución de la sección 9.5 de la unidad 3, y las condiciones son las de ahí: las dos poblaciones normales, las dos muestras independientes, y bajo H_0 con la misma varianza. Este apunte fija los dos grupos de antemano —Ramallo en el numerador, Córdoba en el denominador— y usa los dos valores críticos, uno por cola. La otra convención posible es poner siempre la varianza mayor arriba y trabajar con una sola cola, duplicando su valor p; da el mismo resultado y no se puede mezclar con la primera.

Comparando Ramallo con Córdoba:

$$\begin{aligned} H_0 : \sigma^2_{\text{Ramallo}} &= \sigma^2_{\text{Córdoba}} & H_1 : &\text{son distintas} & \alpha &= 0,05 \\ F &= 119.670^2 / 76.294^2 = 2,4603 \\ \text{grados de libertad} &= 13 \text{ y } 10 \\ \text{valores críticos} &= 0,3077 \text{ y } 3,5832 \\ p &= 0,1600 \end{aligned}$$

2,4603 queda entre los dos valores críticos. **No se rechaza H_0 .**

Los desvíos son 119.670 y 76.294, uno el 57% más grande que el otro, y el test no los separa. Con 14 y 11 casos, una varianza se estima con muy poca precisión.

Este test no sirve como paso previo del de la sección 9. Es una práctica muy difundida —correr la F y, según el resultado, elegir qué versión del test de medias usar— y la bibliografía actual la desaconseja por dos razones. Encadenar dos tests no conserva el nivel de significación del segundo. Y la F es muy sensible a la falta de normalidad, justamente el supuesto que sobre estos datos no se cumple. La salida recomendada está en la sección 9.5: usar la versión de Welch siempre.

9. TEST PARA LA DIFERENCIA DE MEDIAS

9.1 El error standard de una diferencia

Compara las medias de dos poblaciones. La hipótesis nula afirma que son iguales, lo que equivale a decir que su diferencia es cero:

$$H_0 : \mu_1 = \mu_2 \quad H_1 : \mu_1 \neq \mu_2$$

El estadístico tiene la misma forma, con la diferencia observada arriba y el error standard de la diferencia abajo. Ese error standard sale de la sección 5.6 de la unidad 2: la varianza de una diferencia de variables independientes es la suma de las varianzas. Restar dos mediciones no cancela la incertidumbre, la acumula.

9.2 La fórmula

Cuando las dos poblaciones tienen la misma varianza, se combinan las dos muestras en una sola estimación del desvío, llamada **desvío combinado**:

$$s_p^2 = \frac{(n_1 - 1) s_1^2 + (n_2 - 1) s_2^2}{n_1 + n_2 - 2}$$
$$t = (\bar{x}_1 - \bar{x}_2) / [s_p \times \sqrt{(1/n_1 + 1/n_2)}]$$

con $n_1 + n_2 - 2$ grados de libertad

Los grados de libertad son $n_1 + n_2 - 2$, y no $n - 1$: se pierde uno por cada media estimada. Es la advertencia de la sección 9.4 de la unidad 3 sobre que el $n - 1$ vale para una sola muestra.

9.3 Ramallo contra Córdoba

$$H_0 : \mu_{\text{Ramallo}} = \mu_{\text{Córdoba}} \quad \alpha = 0,05$$
$$\text{diferencia observada} = 215.643 - 181.500 = 34.143$$
$$s_p = 103.078$$
$$\text{error standard de la diferencia} = 103.078 \times \sqrt{(1/14 + 1/11)} = 41.531$$
$$t = 34.143 / 41.531 = 0,8221$$
$$\text{grados de libertad} = 23$$
$$p = 0,4195$$

No se rechaza H_0 . Una diferencia de 34.143 pesos entre las dos localidades es compatible con el azar de dos muestras de 14 y 11 hogares.

9.4 El intervalo para la diferencia

El valor p dice que la diferencia no se distingue del azar, y no dice de qué tamaño podría ser. Eso lo dice el intervalo, que se arma con las tres piezas de la sección 5.1 de la unidad 6:

$$34.143 \pm 2,0687 \times 41.531 = [-51.772 ; 120.058]$$

Los datos son compatibles con que Córdoba gane 51.772 pesos más que Ramallo, y también con que Ramallo gane 120.058 más. El cero está adentro, y por eso el test no rechaza. Con 14 y 11 hogares no se puede afirmar nada sobre la diferencia, en ninguna de las dos direcciones.

Es el mejor ejemplo de por qué el intervalo se informa junto con el valor p . El $p = 0,4195$ se puede leer mal como "no hay diferencia"; el intervalo no admite esa lectura.

9.5 Cuando las varianzas no son iguales

Si las dos poblaciones no tienen la misma varianza, no se las combina: se usa una variante llamada **test de Welch**, que suma las dos varianzas por separado y ajusta los grados de libertad.

Sobre Ramallo y Córdoba da $t = 0,8666$ con 22,20 grados de libertad y $p = 0,3954$: la misma conclusión. Acá los dos resultados se parecen porque los tamaños son parecidos, y con tamaños muy distintos se separan.

La práctica actual es usar Welch siempre, sin correr antes el test de la sección 8. No pierde casi nada cuando las varianzas sí son iguales, y protege cuando no lo son. Muchas herramientas lo usan por defecto, así que conviene revisar cuál se corrió antes de comparar resultados.

9.6 Cuando las dos mediciones son sobre las mismas unidades

Todo lo anterior supone dos muestras independientes: los hogares de Ramallo no son los de Córdoba. Hay una situación muy común donde eso no se cumple, y usar esta fórmula ahí es el error de aplicación más frecuente del tema.

Si las dos mediciones son sobre las mismas unidades —el mismo hogar antes y después, la misma pieza medida por dos instrumentos— las muestras están **apareadas**. El relevamiento tiene ocho hogares con dos visitas, y comparar la primera contra la segunda es exactamente ese caso.

La salida es simple y no necesita ninguna fórmula nueva. Se calcula la diferencia de cada par, que produce una sola serie de números, y se le aplica el test de la sección 5 contra $H_0 : \mu_d = 0$, con $n - 1$ grados de libertad, donde n es la cantidad de pares.

Aparear, cuando corresponde, casi siempre da más potencia: la variabilidad entre unidades desaparece de la cuenta, y queda solo la del cambio.

10. EL TEST Y EL INTERVALO DICEN LO MISMO

Para la media y para la varianza, los dos procedimientos son la misma cuenta despejada de dos maneras, y eso da un control gratis.

El intervalo del 95% para el ingreso, de la sección 6.3 de la unidad 6, es $[173.462 ; 233.480]$. El valor que afirma H_0 en la sección 5 es 180.000, y está adentro del intervalo. El test bilateral al 5% no rechazó. Con la varianza pasa lo mismo: 60.000 queda fuera del intervalo $[70.663 ; 114.459]$ de la sección 8 de la unidad 6, y el test de la sección 7 rechazó.

Un test bilateral con nivel α sobre la media rechaza $H_0 : \mu = \mu_0$ exactamente cuando μ_0 queda fuera del intervalo de confianza del $1 - \alpha$. Vale porque las dos cuentas usan el mismo estadístico y el mismo error standard.

Con la proporción la equivalencia es solamente aproximada, y la razón está en la sección 6: el test calcula el error standard con p_0 y el intervalo lo calcula con $\hat{p}$. Son dos denominadores distintos, así que las dos reglas pueden discrepar cerca del borde. En el ejemplo de este apunte coinciden: el 0,5 está adentro de $[0,3800 ; 0,7011]$ y el test no rechazó, y esa coincidencia no demuestra la regla general.

De las dos presentaciones, el intervalo informa más. El test devuelve una decisión binaria; el intervalo devuelve la decisión, mirando si el valor está adentro, y además el tamaño de la estimación y su precisión.




Figura 8. La referencia cae adentro del tramo y el marcador cae fuera de las franjas. Las dos figuras dicen lo mismo.

11. LOS CINCO TESTS, JUNTOS

Qué se pone a prueba	Estadístico	Distribución	Grados de libertad	Supone
Una media	$(\bar{x} - \mu_0) / (s/\sqrt{n})$	t de Student	$n - 1$	población normal, o n grande
Una proporción	$(\hat{p} - p_0) / \sqrt{(p_0(1-p_0)/n)}$	normal standard	—	$n p_0 \geq 5$ y $n(1-p_0) \geq 5$
Una varianza	$(n-1) s^2 / \sigma_0^2$	chi cuadrado	$n - 1$	población normal, sin excepción
Un cociente de varianzas	s_1^2 / s_2^2	F	$n_1 - 1$ y $n_2 - 1$	las dos poblaciones normales
Una diferencia de medias	$(\bar{x}_1 - \bar{x}_2) / (s_p \sqrt{1/n_1 + 1/n_2})$	t de Student	$n_1 + n_2 - 2$	normales, independientes, con la misma varianza
Una diferencia de medias, Welch	$(\bar{x}_1 - \bar{x}_2) / \sqrt{(s_1^2/n_1 + s_2^2/n_2)}$	t de Student	aproximados, de Welch	normales o n grandes, independientes

Y el orden de trabajo, frente a un problema nuevo:

1. **Las dos hipótesis y el α** , antes de mirar los datos.
2. **La elección del test**, según qué parámetro se pone a prueba y cuántas muestras hay.
3. **La verificación de los supuestos** de la última columna.
4. **El estadístico y el valor p**.
5. **La decisión**, con la conclusión redactada sin afirmar H_0 .
6. **El intervalo**, junto con el valor p.

Los resultados del bloque, para tener las cinco conclusiones juntas:

Test	Estadístico	p	Decisión
$\mu = 180.000$	$t = 1,5895$	0,1212	no se rechaza
$p = 0,5$	$z = 0,4932$	0,6219	no se rechaza
$\sigma = 60.000$	$\chi^2 = 72,0771$	0,0003	se rechaza
$\sigma^2_R = \sigma^2_C$	$F = 2,4603$	0,1600	no se rechaza
$\mu_R = \mu_C$	$t = 0,8221$	0,4195	no se rechaza

Cuatro de cinco no rechazan, y el que rechaza lo hace con $p = 0,0003$. La potencia frente a diferencias medianas es baja. Y el único rechazo viene del test más sensible a la falta de normalidad, un supuesto que estos datos no cumplen. Frente a una diferencia de 20.000 pesos en la media, este diseño tiene potencia 0,25; frente a un desvío de 87.360 contra 60.000, tiene potencia de sobra. **Con estos tamaños se detecta lo grande y no lo mediano.**

12. DIEZ ERRORES FRECUENTES

1. **Aceptar H_0 .** No rechazar no es aceptar. Con potencia 0,25 frente a una diferencia de 20.000 pesos, un no rechazo dice muy poco.
2. **Leer el valor p como la probabilidad de que H_0 sea cierta.** Se calcula suponiendo que lo es.
3. **Confundir significativo con importante.** 34.143 pesos de diferencia entre Ramallo y Córdoba no son significativos, y su intervalo llega hasta 120.058.
4. **Elegir la dirección del test después de ver los datos.** Duplica la probabilidad de error de tipo I sin declararlo.
5. **Elegir α después de ver el valor p.** Es elegir el resultado.
6. **Informar el valor p solo.** Sin la estimación y el intervalo no se sabe de qué tamaño es lo que se detectó.
7. **Aplicar el test de la varianza o el de la F sin mirar la normalidad.** Esos dos supuestos no se arreglan con n grande.
8. **Usar el test de dos muestras independientes sobre muestras apareadas.** Si las dos mediciones son sobre las mismas unidades, va el test de una muestra sobre las diferencias.
9. **Correr muchos tests y reportar el que dio significativo.** Con veinte tests independientes sobre hipótesis nulas ciertas, se espera en promedio uno con $p < 0,05$, y la probabilidad de que al menos uno lo dé es 0,64. Cuántos se corrieron es parte del resultado.
10. **Interpretar un no rechazo sin la potencia.** Si no se rechazó, hace falta la potencia del test frente a una diferencia que importe en el problema, fijada sin mirar el resultado. Sin eso, el no rechazo no se puede interpretar.