

# ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

## REGRESIÓN Y CORRELACIÓN

### Unidad 8 · Asignatura E8102 — Exploración de datos

**Docentes:** Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

**Asignatura:** E8102 — Exploración de datos

**Cohorte o comisión:** Cohorte 2026




Figura 1. Hasta acá cada columna se describía sola. Acá lo que se mide es si las dos se mueven juntas.

# 1. INTRODUCCIÓN

## 1.1 De una variable a dos

Las siete unidades anteriores midieron una variable por vez. La unidad 4 describió el ingreso con su media, su dispersión y su forma; la unidad 6 lo estimó para los 4.000 hogares; la unidad 7 lo comparó contra un valor y contra otra localidad.

Esta unidad mide dos columnas juntas, y hace dos preguntas distintas.

La primera es de **correlación**: ¿se mueven juntas? ¿Los hogares con más personas tienden a tener más ingreso? Es una pregunta simétrica —da lo mismo cuál se nombra primero— y su respuesta es un número entre  $-1$  y  $1$ .

La segunda es de **regresión**: ¿cuánto cambia una cuando cambia la otra? ¿Cuántos pesos más de ingreso hay, en promedio, por cada persona de más en el hogar? Es una pregunta con dirección, y su respuesta es una recta.

Las dos usan los mismos datos y contestan cosas distintas.




Figura 2. La misma nube, dos preguntas. La correlación resume cómo se mueven juntas; la regresión estima cuánto cambia una por cada unidad de la otra.

## 1.2 Lo que se supone

- Las unidades 1 a 7. Sobre todo la varianza y el desvío standard de la sección 5 de la unidad 2, la distribución t de Student y la F de las secciones 9.4 y 9.5 de la unidad 3, y el mecanismo de un test de la sección 2.3 de la unidad 7.
- La covarianza, que la sección 5.6 de la unidad 2 nombró y dejó para acá: ahí decía que la varianza de una suma lleva un término que depende de cuánto varían juntas las dos variables.
- Los valores extremos y los dos criterios para detectarlos, de la sección 6 de la unidad 4. En esta unidad un solo hogar cambia la mitad de los resultados.
- Los gráficos de la sección 7 de la unidad 4.
- La sección 7.2 de la clase 3 del [T8001](#), que ya cruzó estas dos columnas y dejó la regla de mirar la nube antes de creerle a un coeficiente.

La única operación nueva es un producto de dos desvíos.

## 1.3 El alcance de esta unidad

**Solo relaciones lineales.** Todo lo que sigue mide y ajusta líneas rectas. Una relación curva existe, es frecuente, y las herramientas de esta unidad la describen mal; la sección 4.4 muestra cómo se detecta y la 8.2 cómo se la ve en los residuos.

**La regresión múltiple se presenta y no se desarrolla.** La sección 9 muestra qué cambia al agregar una segunda variable explicativa y qué trampas aparecen. La simple se calcula a mano y con scipy; la múltiple, solo con statsmodels.

**Nada de esto prueba una causa.** Es la advertencia de la sección 4.3.

## 1.4 Las dos variables de la unidad

Las mismas columnas, ahora cruzadas: personas por hogar e ingreso. Se trabaja con los 35 hogares que declararon ingreso, porque para cruzar dos variables hacen falta las dos.

| Variable           | n  | Media   | Desvíos |
|--------------------|----|---------|---------|
| Personas por hogar | 35 | 3,8857  | 2,1112  |
| Ingreso            | 35 | 203.471 | 87.360  |

Los dos números de la primera fila cambiaron. La unidad 6 usó una media de 3,7838 personas y un desvío de 2,0968, con divisor  $n - 1$ , sobre los 37 hogares; acá son 3,8857 y 2,1112 sobre 35, porque los dos hogares sin ingreso quedaron afuera y los dos tenían 2 personas, menos que el promedio. El denominador es una decisión, y cambiarlo cambia el número.

## 2. EL GRÁFICO DE DISPERSIÓN

### 2.1 Lo primero que se mira

El **gráfico de dispersión**, o de nube de puntos, pone una variable en cada eje y dibuja un punto por caso. Es el sexto gráfico de la asignatura, y es el primero que necesita dos variables a la vez.

Se dibuja antes de calcular cualquier coeficiente, y no después.

Por convención, la variable que se quiere explicar va en el eje vertical y la que explica en el horizontal. Acá el ingreso arriba y las personas abajo, porque la pregunta es si el tamaño del hogar ayuda a explicar el ingreso. La convención no es neutral: elegir cuál va dónde ya es una hipótesis sobre qué depende de qué, y esa hipótesis viene del problema, no de los datos.

### 2.2 Qué buscar en la nube

Cuatro cosas, en este orden.

**La dirección.** Si la nube sube de izquierda a derecha la relación es positiva; si baja, negativa; si no se inclina, no hay relación lineal.

**La forma.** Si los puntos se acomodan alrededor de una recta, las herramientas de esta unidad sirven. Si se acomodan alrededor de una curva, no.

**La fuerza.** Cuán apretada está la nube alrededor de esa recta o curva.

**Los puntos sueltos.** Un caso muy alejado del resto, sobre todo en el eje horizontal, puede gobernar todos los resultados. En el relevamiento hay uno, el hogar de 12 personas: los demás van de 1 a 7, así que está solo, lejos, y del lado donde más pesa.




Figura 3. La dirección y la fuerza son dos cosas distintas. Los dos primeros paneles suben; solo uno lo hace de manera apretada.

## 3. LA COVARIANZA

### 3.1 Qué mide

La **covarianza** mide si las dos variables se apartan de su propia media hacia el mismo lado. Es el promedio de los productos de los dos apartamientos:

$$\text{cov}(X, Y) = \sum (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$$

El divisor es  $n - 1$  porque los datos son una muestra, y la covarianza pierde un grado de libertad igual que la varianza.

El signo de la covarianza es el saldo de los signos de cada producto. Un hogar con más personas que el promedio y más ingreso que el promedio aporta un producto positivo, porque los dos factores son positivos. Uno con menos personas y menos ingreso también aporta positivo, porque los dos son negativos y el producto no. Un hogar que se aparta hacia lados distintos aporta negativo.

Si predominan los que se apartan hacia el mismo lado, la suma da positiva. Si predominan los cruzados, negativa. Y si se compensan, cerca de cero.

Para el relevamiento:

$$\text{cov}(\text{personas}, \text{ingreso}) = 145.158$$

Positiva: los hogares con más personas tienden a tener más ingreso.




Figura 4. Cada punto aporta con un signo, según de qué lado de las dos medias cayó. La covarianza es el saldo.

### 3.2 El problema de las unidades

Ese 145.158 tiene un problema grave: no se puede interpretar. Está en personas multiplicadas por pesos, una unidad sin sentido, y su tamaño depende de la escala de las dos variables. Si el

ingreso se expresara en miles de pesos, la covarianza sería 145,158 y la relación sería exactamente la misma.

Y con esto se cierra lo que la sección 5.6 de la unidad 2 dejó pendiente. Ahí las varianzas se sumaban bajo independencia o con covarianza cero, y la regla general quedaba pendiente; es

$$V(X + Y) = V(X) + V(Y) + 2 \operatorname{cov}(X, Y)$$

y el término que faltaba era este. Cuando la covarianza es cero, las varianzas se suman sin más.

Así que la covarianza sirve para el signo y no para la magnitud. Para la magnitud hace falta sacarle las unidades.

## 4. LA CORRELACIÓN

### 4.1 El coeficiente de Pearson

El [coeficiente de correlación lineal](#), o coeficiente de Pearson, es la covarianza dividida por los dos desvíos:

$$r = \text{cov}(X, Y) / (s_x \times s_y)$$

Esa división es la estandarización, aplicada a las dos variables a la vez. Arriba y abajo quedan las mismas unidades, así que  $r$  no tiene ninguna.

Y además está siempre entre  $-1$  y  $1$ , que es otra cosa y no se deduce de la anterior. Sale de que la covarianza nunca supera, en valor absoluto, al producto de los dos desvíos. Los extremos se alcanzan solamente cuando todos los puntos caen exactos sobre una recta que no sea horizontal ni vertical.

Para el relevamiento:

$$r = 145.158 / (2.1112 \times 87.360) \approx 0,7871$$

Lo desarrolló [Karl Pearson](#) a fines del siglo XIX, sobre una idea de [Francis Galton](#), que es también de quien viene la palabra *regresión*.

### 4.2 Cómo se lee

| $r$           | Qué dice                                      |
|---------------|-----------------------------------------------|
| Cerca de 1    | los puntos caen casi sobre una recta que sube |
| Cerca de $-1$ | los puntos caen casi sobre una recta que baja |
| Cerca de 0    | no hay relación lineal                        |

Tres precisiones.

**El signo y la fuerza son cosas distintas.** Un  $r$  de  $-0,9$  describe una relación más fuerte que uno de  $0,4$ , aunque el primero sea negativo.

**No hay un umbral universal.** Un  $r$  de  $0,6$  es alto en ciencias sociales y bajo en una calibración de instrumentos. Lo que decide qué es alto es el problema, no una tabla.

**$r$  no es una proporción.** Un  $r$  de  $0,8$  no dice que se explique el 80% de nada. Lo que sí tiene esa lectura es  $r^2$ .

### 4.3 Correlación no es causalidad

Es la advertencia más importante de la unidad.

Los datos dan  $r = 0,7871$  entre personas e ingreso. Eso no dice que sumar una persona al hogar produzca más ingreso. Hay al menos cuatro explicaciones compatibles con el mismo número:

**Que la primera cause la segunda.** Más personas en edad de trabajar, más ingresos sumados al hogar.

**Que la segunda cause la primera.** Un hogar con más ingreso puede sostener a más personas.

**Que una tercera variable cause las dos.** La etapa del ciclo familiar, la zona, el tipo de vivienda. A esto se lo llama **variable de confusión**, y es la explicación que más seguido se olvida.

**Que sea casualidad del muestreo.** Con 35 casos, un  $r$  alto puede salir sin que haya relación en la población. La sección 7 es la que evalúa cuán creíble es esta.

Lo que decide entre las tres primeras no son los datos: es el diseño del estudio y el conocimiento del problema. Un coeficiente de correlación nunca distingue entre ellas.

**Un estudio observacional, por sí solo, no prueba una causa. El relevamiento observó hogares; no asignó personas a los hogares al azar. Para hablar de causa hace falta un experimento, o un diseño que controle explícitamente las variables de confusión.**




Figura 5. Las dos se mueven juntas porque algo las mueve a las dos. La flecha que va de una a la otra es la que no está.

## 4.4 Lo que $r$ no detecta

Dos situaciones donde el coeficiente engaña, y las dos se ven en el gráfico de dispersión.

**Una relación curva.** Si los puntos se acomodan sobre una parábola con las ramas hacia arriba, suben tanto de un lado como bajan del otro, y  $r$  puede dar casi cero. La relación es perfecta y el coeficiente no la ve, porque solo mide lo que se parece a una recta.

**Dos grupos mezclados.** Dos nubes sin relación interna, ubicadas en diagonal una respecto de la otra, producen un  $r$  alto que no describe a ninguno de los dos grupos.

De ahí la regla: el gráfico primero, el coeficiente después.




Figura 6. En los dos paneles hay una estructura evidente. La recta que mide el coeficiente no la recoge en ninguno.

## 4.5 La correlación de rangos, y el hogar de 12 personas

Hay una tercera situación, y esta es la del relevamiento: un solo punto alejado puede inflar  $r$ .

La **correlación de rangos de Spearman** reemplaza cada valor por su puesto en el orden, y calcula la correlación sobre esos puestos. El orden importa, la magnitud no. La desarrolló [Charles Spearman](#), y vuelve en la unidad 9, donde los tests de sus secciones 3 a 5 trabajan con rangos.

Las dos, sobre los mismos 35 hogares:

|             | Con los 35 hogares | Sin el hogar de 12 personas |
|-------------|--------------------|-----------------------------|
| Pearson $r$ | 0,7871             | 0,5594                      |
| Spearman    | 0,5793             | 0,5403                      |

Un solo hogar de 35 mueve el coeficiente de Pearson de 0,79 a 0,56, y al de Spearman apenas de 0,58 a 0,54. La conclusión: **la asociación entre las dos columnas no depende de ese hogar, y la magnitud que mide Pearson sí.** Los rangos se mueven poco porque la relación está en los 34 hogares restantes; el 0,79 está inflado porque ese caso tiene los dos valores más altos de sus dos columnas y está solo en esa esquina del gráfico.

Es el mismo hogar de la sección 8.4 de la unidad 2, que llevaba la kurtosis de 2,48 a 7,48. Cuanto más alta la potencia, más manda el valor lejano, y una correlación es un promedio de productos.

## 5. EL MÉTODO DE MÍNIMOS CUADRADOS

### 5.1 La recta que mejor ajusta

La correlación dice si hay relación lineal y cuán fuerte. La regresión da la recta:

$$\hat{y} = b_0 + b_1 x$$

$\hat{y}$  es el valor predicho, y el sombrero lo distingue del observado.  $b_0$  es la **ordenada al origen**, donde la recta cruza el eje vertical, y  $b_1$  es la **pendiente**, cuánto sube  $\hat{y}$  por cada unidad de  $x$ .

Hay infinitas rectas posibles. La que se elige es la que hace mínima la suma de los residuos al cuadrado, donde el residuo de cada caso es lo que le erra la recta:

$$e_i = y_i - \hat{y}_i$$

### 5.2 Por qué al cuadrado

Tres razones.

**Los signos se cancelarían.** Sumar los residuos con su signo da cero para cualquier recta que pase por el centro de la nube, así que no sirve para comparar.

**Los errores grandes pesan más.** Un residuo del doble aporta cuatro veces, así que el método evita sobre todo los errores gruesos. Es una decisión, no una necesidad: también vuelve al método sensible a un punto alejado.

**La solución sale en fórmula cerrada.** Con el cuadrado, las  $b$  se despejan y no hay que buscarlas probando. El método lo publicó [Adrien-Marie Legendre](#) en 1805, y [Carl Friedrich Gauss](#) lo había usado antes.




Figura 7. Lo que la recta hace mínimo no es la suma de las distancias sino la de sus cuadrados. Por eso un punto lejano pesa tanto.

### 5.3 Las dos fórmulas

$$b_1 = \text{cov}(X, Y) / s^2_x \quad \text{la pendiente}$$

$$b_0 = \bar{y} - b_1 \bar{x} \quad \text{la ordenada}$$

La segunda dice que la recta pasa siempre por el punto  $(\bar{x}, \bar{y})$ , el centro de la nube. Sea cual sea la pendiente, ese punto está sobre la recta.

Si a  $b_1 = \text{cov} / s^2_x$  se lo multiplica y divide por  $s_y$ , queda  $b_1 = r \times s_y / s_x$ : **la pendiente es la correlación, reescalada a las unidades de las dos variables**. Por eso  $r$  y  $b_1$  tienen siempre el mismo signo, y por eso una correlación sin unidades puede producir una pendiente en pesos por persona.

### 5.4 La recta del relevamiento, y cómo se leen los dos coeficientes

Con  $\text{cov} = 145.158$  y  $s^2_x = 2,1112^2 = 4,457$ :

$$b_1 = 145.158 / 4,457 \approx 32.568$$

$$b_0 = 203.471 - 32.568 \times 3,8857 \approx 76.923$$

$$\hat{y} = 76.923 + 32.568 x$$

**La pendiente.** Por cada persona más en el hogar, el ingreso predicho sube 32.568 pesos. No dice que agregar una persona aumente el ingreso en 32.568. Dice que entre los hogares observados, los que tienen una persona más tienen en promedio 32.568 pesos más.

**La ordenada.**  $b_0 = 76.923$  es el ingreso predicho para un hogar de cero personas, que no existe. No siempre tiene interpretación, y esta es de las que no la tiene: cero está fuera del rango observado, que va de 1 a 12. La ordenada fija la altura de la recta.

Para un hogar de 4 personas, un valor del medio del rango, la recta predice  $76.923 + 32.568 \times 4 \approx 207.193$ , y los ocho hogares de 4 personas del relevamiento tienen un ingreso promedio de 191.750. La recta les erra por unos 15.000 pesos hacia arriba.

## 6. EL COEFICIENTE DE DETERMINACIÓN

### 6.1 La variación se parte en dos

Antes de tener la recta, lo único que explicaba al ingreso de cada hogar era el ingreso promedio, y la variación total respecto de ese promedio es una suma de cuadrados conocida, la de la varianza:

$$SCT = \sum (y_i - \bar{y})^2 \quad \text{variación total}$$

Con la recta, esa variación se parte exactamente en dos partes:

$$SCR = \sum (\hat{y}_i - \bar{y})^2 \quad \text{lo que la recta explica}$$

$$SCE = \sum (y_i - \hat{y}_i)^2 \quad \text{lo que queda sin explicar, los residuos}$$

$$SCT = SCR + SCE$$

Para el relevamiento, en pesos al cuadrado:

|                             | Suma de cuadrados | Proporción |
|-----------------------------|-------------------|------------|
| Total, SCT                  | 259.477.471.429   | 1,0000     |
| Explicada por la recta, SCR | 160.733.620.891   | 0,6195     |
| Residual, SCE               | 98.743.850.537    | 0,3805     |

Las dos últimas suman la primera. Esa igualdad no es aproximada: vale exactamente, y es una propiedad del método de mínimos cuadrados. Con las cifras redondeadas de la tabla, la suma difiere en 1 en la última cifra.




Figura 8. La recta no crea variación: reparte la que ya había en dos partes que cierran.

## 6.2 El coeficiente de determinación

El **coeficiente de determinación** es la proporción de la variación total que la recta explica:

$$r^2 = SCR / SCT$$

En una regresión con una sola variable explicativa es exactamente el cuadrado del coeficiente de correlación. Para el relevamiento,  $0,7871^2 = 0,6195$ .

Se lee así: **el tamaño del hogar explica el 61,95% de la variación del ingreso entre estos 35 hogares**. Es la lectura de proporción que  $r$  no tenía, y es la razón de que se informe  $r^2$  y no  $r$  cuando hay una recta ajustada.

El 38,05% restante es lo que queda sin explicar: todo lo que hace que dos hogares del mismo tamaño tengan ingresos distintos, que es casi todo lo que no está en la tabla.

Sin el hogar de 12 personas,  $r^2$  cae a 0,3130.

## 6.3 El error standard de la estimación

$r^2$  no tiene unidades, así que no dice cuánto se erra en pesos. Eso lo dice el **error standard de la estimación**, que es la dispersión de los residuos:

$$s_e = \sqrt{[SCE / (n - 2)]}$$

El divisor es  $n - 2$  y no  $n - 1$ : se estimaron dos coeficientes, así que se pierden dos grados de libertad.

$$s_e = \sqrt{(98.743.850.537 / 33)} = 54.701 \text{ pesos}$$

Se lee como el desvío standard de la unidad 2, aplicado a los errores: las predicciones de esta recta se apartan de los valores observados típicamente, unos 54.701 pesos. Contra un ingreso promedio de 203.471, eso es mucho, y es la información que el  $r^2 = 0,62$  no daba.

**No lo confundas con el error standard de la media. La sección 6.3 de la unidad 6 calculó  $s/\sqrt{n} = 14.766$  sobre este mismo ingreso, y describe cuánto varía un promedio de muestra en muestra. El  $s_e = 54.701$  describe cuánto se aparta un hogar de la recta. Los dos se llaman error standard, difieren por un factor de casi cuatro y contestan preguntas distintas.**

## 7. LA INFERENCIA SOBRE LOS COEFICIENTES

### 7.1 El modelo, y la recta como estimación

Hasta acá la recta era una descripción de los 35 hogares. Para poder hacer un test hace falta decir qué se supone sobre la población, y ese supuesto tiene forma de modelo:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Se lee: en la población, el ingreso de un hogar es una parte que depende linealmente del tamaño, con parámetros  $\beta_0$  y  $\beta_1$  que no se conocen, más un **error**  $\varepsilon$  que recoge todo lo demás. Las letras griegas marcan lo que no se conoce.

$\varepsilon$  es el error de la población y no se observa; el residuo  $e$  de la sección 5.1 es lo que se puede calcular, y es la estimación de ese error. Los supuestos de la sección 8 son sobre  $\varepsilon$ , y los residuos son lo que se mira para controlarlos.

Los 35 hogares son una muestra, así que  $b_0$  y  $b_1$  son estadísticos: otra muestra habría dado otra recta. De ahí la pregunta de esta sección: ¿la pendiente observada podría ser casualidad del muestreo? Con 35 hogares sin ninguna relación real, el azar igual produce alguna inclinación.

### 7.2 El test sobre la pendiente

Es el test de la media de la sección 5 de la unidad 7, con la pendiente en lugar del promedio. La hipótesis nula afirma que en la población no hay relación lineal, que es decir que la pendiente verdadera es cero:

$$H_0 : \beta_1 = 0 \quad H_1 : \beta_1 \neq 0$$

$$t = b_1 / EE(b_1) \quad \text{con } n - 2 \text{ grados de libertad}$$

$EE(b_1)$  es el **error standard de la pendiente**, y su fórmula explica buena parte del resto de la unidad:

$$EE(b_1) = s_e / \sqrt{[\sum (x_i - \bar{x})^2]}$$

Se lee de tres maneras a la vez. La pendiente se estima mejor cuando los residuos son chicos, porque  $s_e$  está arriba. Cuando hay más casos, porque cada uno suma al denominador. Y cuando los valores de  $x$  están más repartidos, porque lo que suma es la distancia al centro. Esa tercera lectura tiene dos caras. Si muchos casos se reparten a lo largo del rango, el denominador crece repartido y el EE baja, que es bueno. Si uno solo está muy lejos, aporta él casi todo el denominador, y entonces la pendiente queda determinada por ese caso. Es el caso del hogar de 12 personas, lejos de una  $\bar{x}$  de 3,89.

Para el relevamiento, con  $\sum (x_i - \bar{x})^2 = 151,54$ :

$$\begin{aligned} EE(b_1) &= 54.701 / \sqrt{151,54} = 54.701 / 12,31 = 4.444 \\ t &= 32.568 / 4.444 \approx 7,3292 \\ \text{grados de libertad} &= 33 \\ \text{valor crítico} &= \pm 2,0345 \\ p &< 0,0001 \end{aligned}$$

**Se rechaza  $H_0$ .** Es el  $t$  más grande de la asignatura: 7,33 contra un valor crítico de 2,03.

Ese mismo  $t$  sirve para una segunda hipótesis. Poner a prueba  $H_0 : \rho = 0$ , que la correlación de la población es cero, da exactamente el mismo estadístico y el mismo valor  $p$ . El test de la pendiente y el test de la correlación son el mismo test.

Un valor  $p$  así invita a concluir de más. Dice que la relación entre las dos columnas es difícil de atribuir al azar de esta muestra. No dice que sea causal, que es la sección 4.3, ni que sea grande, que es la sección 4.4 de la unidad 7, ni que la recta prediga bien, que es el  $s_e = 54.701$  de la sección 6.3.

### 7.3 El intervalo para la pendiente

Como siempre, el valor  $p$  va acompañado del intervalo:

$$32.568 \pm 2,0345 \times 4.444 = [ 23.527 ; 41.608 ]$$

Entre 23.527 y 41.608 pesos más por cada persona adicional. El cero está bien afuera, que es la otra forma de ver el rechazo, y el intervalo sigue siendo ancho: el extremo alto es 1,77 veces el bajo.

### 7.4 La prueba global y la F

Con una sola variable explicativa hay una segunda vía, que parece distinta y no lo es:

$$F = (SCR / 1) / (SCE / (n - 2)) \quad \text{con 1 y } n - 2 \text{ grados de libertad}$$

Es un cociente entre la variación que la recta explica y la que deja sin explicar, cada una dividida por sus grados de libertad. Si la recta no explicara nada, las dos serían parecidas y  $F$  rondaría 1.

$$F = 53,7169 \quad gl = 1 \text{ y } 33 \quad p < 0,0001$$

Y ahí está la relación que la sección 9.6 de la unidad 3 dejó anotada como control:  $7,3292^2 = 53,72$ . En regresión simple, la  $F$  es el cuadrado de la  $t$ , y las dos dan el mismo valor  $p$ .

La  $F$  se vuelve necesaria en la sección 9, con más de una variable explicativa, porque ahí pregunta algo que ninguna  $t$  individual contesta: si el conjunto de las variables explica algo. Es el uso que la sección 9.5 de la unidad 3 le asignó a esta unidad.

## 8. LOS SUPUESTOS, Y LOS RESIDUOS

### 8.1 Los cuatro supuestos

El ajuste de la recta no supone nada: se puede calcular sobre cualquier par de columnas. La inferencia de la sección 7 sí supone, y son cuatro cosas sobre el error  $\epsilon$  del modelo de la sección 7.1. Como  $\epsilon$  no se observa, lo que se mira son los residuos.

**Linealidad.** La relación verdadera es una recta. Si es curva, todo lo demás sobra.

**Independencia.** Los errores no se relacionan entre sí. Se rompe sobre todo en series de tiempo, donde un valor alto suele venir seguido de otro alto.

**Varianza constante.** La dispersión de los errores es la misma a lo largo de todo el rango de  $x$ . Cuando cambia con  $x$  se habla de **heterocedasticidad**, y aparece seguido en variables de dinero, casi siempre como una dispersión que crece.

**Normalidad.** Hace falta para el test y el intervalo de la sección 7, no para la recta. Con muestras grandes se relaja, por el teorema central del límite.

**Ninguno de los cuatro es sobre la distribución de  $x$  ni sobre la de  $y$  tomada sola.** El ingreso tiene una asimetría de 2,87 y eso no viola ningún supuesto: lo que tiene que comportarse es el error.

### 8.2 Qué mirar en los residuos

El control se hace con un **gráfico de residuos**: los residuos en el eje vertical contra  $x$  o contra  $\hat{y}$  en el horizontal. Lo que se busca es que no se vea ningún patrón: es el único gráfico de la asignatura donde no encontrar nada es el buen resultado.

| Lo que se ve                                                                  | Qué supuesto se rompe                                                |
|-------------------------------------------------------------------------------|----------------------------------------------------------------------|
| Una curva, un arco                                                            | linealidad                                                           |
| Un embudo que se abre                                                         | varianza constante                                                   |
| Ondas o rachas de un mismo signo, con los residuos en el orden de recolección | independencia                                                        |
| Un punto muy separado                                                         | puede indicar colas pesadas o un caso influyente; conviene revisarlo |

Sobre el relevamiento, los residuos pasan el control de normalidad sin problema, y la dispersión crece algo con el tamaño del hogar: la correlación entre el residuo en valor absoluto y las personas es 0,38, con  $p = 0,025$ . Casi toda sale del hogar 39: sin él, baja a 0,04.




Figura 9. Solo el primer panel está bien. En los otros tres, la forma que se ve es el supuesto que se rompió.

### 8.3 Palanca, influencia, y los dos hogares de siempre

La **palanca** de un punto depende solo de su  $x$ : cuán lejos está del promedio de la variable explicativa. Es el apartamiento que cada punto aporta a la suma  $\sum (x_i - \bar{x})^2$  del denominador del  $EE(b_1)$  de la sección 7.2.

La **influencia** es cuánto cambiaría la recta si ese punto se sacara. Un punto tiene influencia cuando junta las dos cosas: mucha palanca y un apartamiento grande respecto de la recta que ajustan los demás puntos. Un punto con mucha palanca que cae justo sobre esa recta no la mueve.

Los dos residuos más grandes:

| Hogar | Personas | Ingreso | Predicho | Residuo  | Palanca | Influencia |
|-------|----------|---------|----------|----------|---------|------------|
| 39    | 12       | 620.000 | 467.734  | +152.266 | alta    | alta       |
| 38    | 2        | 0       | 142.058  | -142.058 | baja    | moderada   |

El hogar 38 es el de ingreso cero, y es sobre todo un residuo grande: con 2 personas está cerca de la  $\bar{x}$  de 3,89, así que tiene poca palanca y casi no inclina la recta. Sin él,  $b_1$  pasa de 32.568 a 30.703.

El hogar 39 junta las dos. Los demás van de 1 a 7 personas; él tiene 12, solo, con un hueco de cuatro valores antes. Es el punto con más influencia del conjunto, y por eso mueve  $r$  de 0,79 a 0,56 y  $r^2$  de 0,62 a 0,31.

**Un punto influyente no se borra, se declara. El T8001 revisó ese hogar y lo conservó en la sección 5.3 de su clase 3, porque un hogar de 12 personas existe. Lo que corresponde es informar la recta con y sin él, y decir cuál se usó.**




Figura 10. Un punto lejos solo en la vertical casi no mueve la recta. Uno lejos en la horizontal, sí.

## 9. LA REGRESIÓN MÚLTIPLE

### 9.1 Más de una variable explicativa

El tamaño del hogar deja el 38% de la variación sin explicar, así que la pregunta obvia es si agregar otra variable ayuda. La **regresión lineal múltiple** hace eso:

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots$$

Cambia la interpretación de cada coeficiente, y el cambio es la parte que más cuesta.  $b_1$  ya no es "cuánto sube  $\hat{y}$  por cada unidad de  $x_1$ ": es cuánto sube manteniendo las demás variables constantes. Es el efecto de  $x_1$  una vez descontado lo que las otras ya explican.

### 9.2 El ejemplo del relevamiento

Se agrega la cantidad de servicios de cada hogar, entre 1 y 4, que sale de contar los de la columna servicios.

| Coeficiente | Valor  | EE     | t    | p        |
|-------------|--------|--------|------|----------|
| Ordenada    | 48.660 | 25.166 | 1,93 | 0,0621   |
| Personas    | 26.593 | 5.546  | 4,79 | < 0,0001 |
| Servicios   | 21.197 | 12.348 | 1,72 | 0,0957   |

$$\begin{aligned} R^2 &= 0,6515 & R^2 \text{ ajustado} &= 0,6298 \\ F \text{ global} &= 29,92 & gl &= 2 \text{ y } 32 & p < 0,0001 \end{aligned}$$

Cuatro lecturas.

**La pendiente de personas bajó**, de 32.568 a 26.593. Parte de la asociación que la recta simple le asignaba al tamaño del hogar se comparte con los servicios, que van juntos con el tamaño.

**Servicios no resulta significativa**, con  $p = 0,0957$ . Su intervalo contiene el cero, así que con 35 casos no se puede afirmar que aporte por encima de lo que aporta el tamaño.

**El  $R^2$  subió y eso no prueba nada**. Pasó de 0,6195 a 0,6515, y el  $R^2$  nunca baja cuando se agrega una variable, aunque sea ruido puro: la recta tiene un grado de libertad más para acomodarse. Por eso se informa el  $R^2$  **ajustado**, que descuenta la cantidad de variables y puede bajar. El ajustado del modelo simple es 0,6079, y el del múltiple 0,6298: subió 0,0218, bastante menos que los 0,0321 del sin ajustar, y esa ganancia chica es coherente con un coeficiente que no alcanza la significación.

**El t de la ordenada casi nunca interesa**. Pone a prueba que el ingreso predicho de un hogar de cero personas y cero servicios sea cero, una hipótesis sobre un punto que está fuera del rango observado. Se informa porque las herramientas lo devuelven, y no se interpreta.

Una precisión sobre el símbolo. En la regresión simple se escribe  $r^2$  minúscula porque es el cuadrado de la correlación entre las dos variables. Con más de una explicativa esa lectura ya no

vale, y se escribe  $R^2$  mayúscula: sigue siendo la proporción de variación explicada, y es el cuadrado de la correlación entre  $y$  y  $\hat{y}$ .

### 9.3 La colinealidad

Una parte de los dos primeros resultados viene de acá. La correlación entre personas y servicios es 0,6275: los hogares más grandes tienden a tener más servicios.

Cuando dos variables explicativas se correlacionan entre sí se habla de **colinealidad**, y produce un efecto que desconcierta: los errores standard se inflan, así que las dos variables pueden resultar no significativas por separado mientras el modelo entero sí lo es. Acá la inflación es moderada: el factor de inflación de la varianza es 1,65, así que el error standard de cada coeficiente crece un 28%.

La lectura correcta no es que los servicios no importen. Es que con 35 casos su efecto, separado del tamaño del hogar, se estima con poca precisión, porque las dos cosas vienen juntas.

### 9.4 Cuántas variables

La tentación es agregar variables hasta que el  $R^2$  quede alto. Con suficientes variables se puede llegar a  $R^2 = 1$  sobre cualquier conjunto de datos, y ese modelo describe el ruido de esa muestra en lugar de la población.

Dos criterios prácticos: mirar el  $R^2$  ajustado y no el  $R^2$ , y exigir que cada variable tenga una razón del problema para estar, no solamente un coeficiente significativo.

## 10. LA PREDICCIÓN, Y HASTA DÓNDE LLEGA

La recta sirve para predecir, con dos límites.

**No se extrapola.** El rango observado de  $x$  va de 1 a 12 personas. Pedirle a la recta el ingreso de un hogar de 20 personas da 728.275 pesos, un número que la recta produce sin ninguna evidencia: no hay un solo dato en esa zona que respalde que la relación siga siendo lineal ahí. Fuera del rango observado, la recta es una fórmula, no un resultado.




Figura 11. La recta se prolonga sin esfuerzo hacia donde no hay ningún dato. Ahí deja de estar respaldada por algo.

**La predicción trae su propio margen.** Los 207.193 pesos de un hogar de 4 personas son el centro de un intervalo, no un valor. Y hay dos intervalos distintos, que se confunden: uno para el promedio de todos los hogares de 4 personas, y otro, bastante más ancho, para un hogar concreto de 4 personas, que además del error de la recta arrastra la dispersión individual de 54.701 pesos. El segundo es el que hace falta para decidir sobre un caso, y las fórmulas de los dos quedan fuera del programa.

Los dos comparten una propiedad que refuerza la advertencia de arriba: se ensanchan a medida que  $x$  se aleja de  $\bar{x}$ . La recta se conoce mejor en el centro de la nube que en sus bordes, por la misma razón que la sección 7.2 le dio al denominador del  $EE(b_1)$ .




Figura 12. El centro es el mismo. Predecir un caso suma la dispersión individual al error de estimar el promedio.

## 11. LA REGRESIÓN, DE PUNTA A PUNTA

Los resultados de la unidad, juntos, y con las dos versiones que la sección 8.3 obliga a informar:

| Medida                          | Con los 35 hogares | Sin el hogar 39  |
|---------------------------------|--------------------|------------------|
| Correlación $r$                 | 0,7871             | 0,5594           |
| Correlación de rangos           | 0,5793             | 0,5403           |
| Pendiente $b_1$                 | 32.568             | 17.384           |
| Ordenada $b_0$                  | 76.923             | 127.821          |
| $r^2$                           | 0,6195             | 0,3130           |
| Error standard de la estimación | 54.701             | 41.670           |
| $t$ de la pendiente             | 7,3292             | 3,8181           |
| Valor $p$                       | < 0,0001           | 0,0006           |
| Intervalo para $b_1$            | [23.527 ; 41.608]  | [8.110 ; 26.658] |

Las dos columnas rechazan la hipótesis de pendiente cero, y describen relaciones de tamaño muy distinto: 32.568 pesos por persona contra 17.384. El resultado cualitativo no depende de ese hogar y la magnitud sí.

Y el orden de trabajo, frente a un par de columnas nuevo:

1. **El gráfico de dispersión**, antes que cualquier cuenta.
2. **La dirección, la forma, la fuerza y los puntos sueltos**, que es la sección 2.2.
3. **El coeficiente de correlación**, y el de rangos si hay valores extremos.
4. **La recta**, con su pendiente leída en las unidades del problema.
5.  **$r^2$  y el error standard de la estimación**, que dicen la proporción y los pesos.
6. **El test y el intervalo de la pendiente**.
7. **El gráfico de residuos**, buscando que no se vea ningún patrón.
8. **La versión sin los puntos influyentes**, informada junto con la otra.

## 12. NUEVE ERRORES FRECUENTES

- 1. Confundir correlación con regresión.** La correlación es simétrica y sin unidades; la regresión tiene dirección y está en pesos por persona.
- 2. Leer una causa en un coeficiente.**  $r = 0,7871$  admite al menos cuatro explicaciones. El test de la sección 7 evalúa la casualidad, y los datos no eligen entre las otras tres.
- 3. Calcular  $r$  sin mirar el gráfico.** Una curva y dos grupos mezclados producen coeficientes que no describen nada.
- 4. Informar  $r$  donde corresponde  $r^2$ .** Un  $r$  de 0,79 no es un 79% de nada. El  $r^2$  es 0,62.
- 5. Interpretar la ordenada fuera del rango.** Los 76.923 pesos son el ingreso predicho de un hogar de cero personas.
- 6. Extrapolar.** Con datos de 1 a 12 personas, la recta no dice nada sobre un hogar de 20.
- 7. Confiar en un  $R^2$  alto de una regresión múltiple.** El  $R^2$  nunca baja cuando se agrega una variable. El que se informa es el ajustado, que acá va de 0,6079 a 0,6298.
- 8. Concluir que una variable no significativa no importa.** Con colinealidad, dos variables que importan pueden resultar las dos no significativas.
- 9. No mirar los residuos.** Es el control principal de linealidad y de varianza constante.