Universidad Nacional de Mar del Plata

Facultad de Ciencias Económicas y Sociales

Facultad de Ingeniería

2026

ESPECIALIZACIÓN EN INTELIGENCIA DE DATOS
para la Gestión Estratégica

TRABAJO FINAL

Bloque 5 · Asignatura E8102 — Exploración de datos

Docentes: Esp. Mariano Morettini y Dr. Lautaro Di Bártolo

Asignatura: E8102 — Exploración de datos

Cohorte o comisión: Cohorte 2026

1. PAUTAS PARA EL TRABAJO FINAL

Para este trabajo hay nueve bases de datos de fuentes abiertas, listas para usar. Con cualquiera de ellas se pueden resolver los siete puntos. La sección 2 las presenta, y todas están en la carpeta de datos del trabajo final. También se puede traer otra base.

Descripción general: Deberá entregarse un informe en el que se apliquen, sobre una base de datos obtenida de una fuente abierta, una serie de técnicas estadísticas abordadas durante el curso. El trabajo puede ser presentado en forma individual o en grupos de 2 personas.

Fecha de entrega: hasta el viernes 13/11/2026 a través del campus virtual.

Formato: el informe deberá realizarse en hoja A4, con tipo de letra Arial Tamaño 11, interlineado 1,5 líneas, con una cantidad máxima de 18 hojas, incluyendo portada, tablas y gráficos.

Contenido: el informe deberá contener los siguientes puntos.

Punto 1 – Introducción y exploración de datos

- Tomar una base de datos de una fuente abierta (indicando el link de donde la obtuvo).
- Identificar tipo de variables (cuantitativas, cualitativas).
- Calcular medidas descriptivas básicas: media, mediana, moda, rango, desviación estándar, sobre las variables que correspondan.
- Realizar histogramas, boxplots, gráficos de dispersión y todo otro gráfico que considere adecuado para la descripción de las variables.
- Presentar tabla descriptiva y gráficos iniciales, con su adecuada interpretación.

Punto 2 – IC y TH

Intervalos de confianza y test de hipótesis para la media

- Seleccionar una variable numérica. Calcular un IC al 95% y al 99% para la media.
- Formular y resolver un test de hipótesis para esa media.
- Redactar una breve síntesis incluyendo la hipótesis planteada, los resultados contrastados y la conclusión.

Test de hipótesis para proporciones

- Seleccionar una variable categórica dicotómica.
- Formular y resolver un TH sobre proporciones de esa variable.
- Presentar gráficamente los resultados y redactar breve interpretación.

Punto 3 – Varianza y diferencias de media

- Comparar la varianza entre dos grupos (ej. Género).
- Realizar un TH sobre la diferencia de medias.
- Realizar una breve redacción con hipótesis, resultados e interpretación.

Punto 4 – Diferencia de proporciones y ANOVA

- Comparar proporciones entre dos grupos.
- Realizar un ANOVA con una variable numérica y un factor categórico.
- Presentar tabla ANOVA con una breve interpretación.

Punto 5 – Regresión y correlación

- Analizar la relación entre dos variables numéricas.
- Calcular coeficiente de correlación.
- Ajustar una regresión lineal simple.
- Presentar gráfico con recta de regresión y con su interpretación.

Punto 6 – Test Chi-cuadrado

- Construir tablas de contingencia con dos variables categóricas.
- Aplicar test Chi-cuadrado de independencia.
- Presentar tabla con una interpretación sobre asociación.

Punto 7 – Tests no paramétricos

Aplicar en la base, según el tipo de variable, al menos uno de los siguientes test, presentando un informe con los resultados obtenidos y las conclusiones:

1. Test de Wilcoxon
2. Test de Kruskal-Wallis
3. Test de Mann-Whitney

2. LAS BASES DE DATOS

Las nueve bases están en esta carpeta de GitHub, que se abre en el navegador sin crear una cuenta:

https://github.com/lautarodibartolo-ae/e8102-exploracion-de-datos/tree/main/bloque-5-trabajo-final/datos

Cada base tiene dos archivos con el mismo nombre: un `.csv` con los datos y un `.md` con su descripción. La descripción dice qué es una fila, qué quiere decir cada columna, qué cuidados pide el análisis, qué columnas sirven para cada punto, y cuál es la fuente original, con su link y su licencia. En la tabla, el nombre de cada base abre su descripción.

Base	De qué se trata	Filas	Wilcoxon
factores_de_riesgo_2018	Encuesta Nacional de Factores de Riesgo 2018 del INDEC: peso, altura, presión arterial y hábitos de cada persona	2.000	sí
agricultura_2022_23	superficie, producción y rendimiento de soja, maíz, trigo y girasol por departamento, en la campaña de la sequía	1.041	sí
arbolado_buenos_aires	altura, diámetro e inclinación de árboles de cinco especies en los parques de la Ciudad de Buenos Aires	2.000	no
pinguinos_palmer	medidas del pico, la aleta y la masa de pingüinos de tres especies en la Antártida	344	no
estudiantes_portugal	notas y situación familiar de alumnos secundarios de dos escuelas de Portugal	649	sí
vinos_portugal	análisis químico y nota de catadores de vinos verdes tintos y blancos de Portugal	6.497	no
corazon_cleveland	estudios cardíacos de pacientes con sospecha de enfermedad coronaria, en Estados Unidos	303	no
bicicletas_washington	viajes diarios en bicicletas compartidas y el clima de cada día, en Washington	731	sí
autos_1970_1982	peso, potencia y rendimiento de modelos de autos de Estados Unidos, Europa y Japón	398	no

La última columna dice si la base tiene dos mediciones sobre las mismas unidades, que es lo que pide el test de Wilcoxon. El punto 7 pide al menos uno de los tres tests no paramétricos, así que una base sin mediciones apareadas sirve igual, con el test de Mann-Whitney o el de Kruskal-Wallis.

Para descargar un CSV, hay que hacer clic en el archivo dentro de la carpeta y después en el botón de descarga, arriba a la derecha (`Download raw file`).

Qué poner en el informe

El link que pide el punto 1 es el de la fuente original, que figura en la descripción de cada base. La descripción dice también qué cambió respecto del original: los nombres de las columnas y las categorías están en castellano, algunas unidades están convertidas al sistema métrico, y algunas bases son una muestra de la original. Esos cambios se mencionan en el informe. Las columnas que sugiere la descripción para cada punto son sugerencias: se pueden elegir otras.

Si traés otra base

Antes de empezar, revisá que la base tenga lo que piden los puntos:

Punto	La base necesita
1 y 2	una variable numérica
2	una variable categórica de dos valores, como sí o no
3	una variable numérica y dos grupos para compararla, como mujeres y varones
4	una variable de dos valores para comparar entre dos grupos, y un factor de tres categorías o más para el ANOVA
5	dos variables numéricas relacionadas
6	dos variables categóricas
7	para el test de Wilcoxon, dos mediciones sobre las mismas unidades; para el de Mann-Whitney o el de Kruskal-Wallis alcanzan los grupos de los puntos 3 y 4

Una base de decenas de miles de filas sirve, pero con tantos datos casi cualquier diferencia da un valor p chico. La sección 4.4 de la unidad 7 explica por qué un resultado significativo no es necesariamente importante.

3. LAS HERRAMIENTAS

El trabajo se resuelve con la herramienta que cada uno prefiera: Excel, R, Python u otra. Los archivos de la carpeta son CSV en UTF-8, separados por comas y con punto decimal; las celdas vacías son datos faltantes.

En R y en Python el CSV se lee directo, con `read.csv("archivo.csv")` en R o `pd.read_csv("archivo.csv")` en Python. En Excel conviene no abrirlo con doble clic: con la configuración regional de Argentina, Excel espera punto y coma entre columnas y coma decimal, y puede leer mal el archivo. Las instrucciones de la carpeta explican cómo importarlo.

Para quien elija Python, este notebook de Google Colab carga una de las bases. No resuelve ningún punto: es un punto de partida.